Arquitetura e Avaliação de um Sistema Vetorial para Recuperação Semântica de Atos Normativos do Conselho Nacional de Justiça

Bruno Mortari[1], **Danielle Cristine Azevedo de Souza**[2], **Gentil Veloso Barbosa,**[3]
Lucas Gabriel da Silva Neris[4], **Matheus Rodrigues de Souza**[5], **William Irineu Alves de Lima**[6]

[1]Tribunal Regional Eleitoral de Goiás (TRE-GO)
Praça Dr. Pedro Ludovico Teixeira, 300 - St. Central, Goiânia - GO, 74083-010

daniellecristineazs@gmail.com, lucasgsn2014@gmail.com,
eliadezoe@gmail.com, kdowillian@gmail.com

Abstract. *In light of the growing volume of normative acts issued by the National Council of Justice (CNJ), the retrieval of legal information has become a central challenge for the Brazilian Judiciary. This article presents the development and analysis of a vector infrastructure for semantic search, from the web scraping of these regulations and the exploratory analysis of the corpus, highlighting syntactic, semantic, and quantitative aspects of the processed documents to the construction of a vector database and the application of Natural Language Processing and Deep Learning.*

Resumo. *Diante do crescente volume de atos normativos editados pelo Conselho Nacional de Justiça (CNJ), a recuperação de informações jurídicas se tornou um dos desafios centrais para o Poder Judiciário Brasileiro. O presente artigo apresenta o desenvolvimento e análise de uma infraestrutura vetorial para busca semântica, desde o web scraping desses normativos e a análise exploratória do corpus, destacando aspectos sintáticos, semânticos e quantitativos dos documentos processados até a construção de um banco de dados vetorial e a aplicação de Processamento de Linguagem Natural e Deep Learning.*

1. Introdução

O CNJ é uma instituição pública criada pela Emenda Constitucional nº 45, de 2004, que tem como objetivo melhorar o trabalho feito pelo Poder Judiciário brasileiro, sendo seus esforços claros considerando o grande volume de atos normativos que são divulgados em todos os anos. O propósito envolve ajudar no crescimento do Judiciário em benefício da sociedade, atuando principalmente no controle da transparência, e na busca pela padronização e eficácia dos serviços judiciais em Todo o Brasil. Considerando o volume e a complexidade desses atos, a procura e a análise de informações por meio de métodos tradicionais, como a pesquisa por palavras-chave, tornam-se ineficazes. Imagine tentar encontrar informações em uma biblioteca gigante onde você só pode pesquisar pelos títulos exatos dos livros, muitas obras importantes seriam perdidas simplesmente por usarem palavras diferentes para retratar o mesmo assunto. É justamente esse o desafio imposto pela grande quantidade de documentos normativos. A fim de vencer este desafio, o projeto

trata a recuperação da informação através da similaridade semântica. Ao contrário de apenas corresponder palavras, a consulta traduz o fundamento de cada ato normativo em uma representação numérica única chamada *embedding*. Ao sistematizar esses "endereços digitais"em um banco de dados especializado (o PostgreSQL com a extensão PGVector), obtemos a capacidade de procurar por similaridade de ideias. Este artigo delineia, portanto, o progresso de uma infraestrutura de dados para este fim, exibindo a metodologia de coleta, processamento, vetorização e armazenamento dos textos, a par de discutir o potencial desta abordagem para futuras aplicações de inteligência artificial aplicada ao domínio jurídico.

2. Fundamentação Teórica

Este estudo fundamenta-se teoricamente em três correntes principais: a história dos sistemas de recuperação da informação jurídica, a evolução dos modelos de Processamento de Linguagem Natural (PLN) e *embeddings*, e a inovação dos bancos de dados vetoriais aliados à pesquisa semântica no meio jurídico. E quanto as métricas empregadas em relação a desempenho temos o *recall*, que representa a efetividade do sistema em encontrar todos os documentos relevantes (em outras palavras, quantos resultados corretos foram achados em relação ao total de corretos existentes) e temos a *precision* que mede a porcentagem de resultados relevantes entre todos os documentos encontrados (ou seja, quantos dos resultados mostrados realmente eram corretos).

2.1. Recuperação da Informação Jurídica: desafios e oportunidades

A recuperação da informação jurídica é um campo complexo, visto a complexidade e densidade dos textos normativos. O campo do Direito é caracterizado por um constructo linguístico específico, repleto de expressões técnicas, ambiguidades, sinonímias e polissemias. A análise por meio de enfoques baseados em correspondência de termos, típicas das alternativas clássicas, frequentemente ignora a dimensão semântica e pragmática do discurso jurídico, despertando baixo *recall* e *precision*, principalmente em consultas mais complexas ou de caráter interdisciplinar [Lin et al. 2021]. Não obstante o crescimento sem precedentes dos repositórios digitais e do volume de documentos, a implementação tornou-se necessária.

2.2. Bancos de Dados Vetoriais e Consultas Semânticas

A junção de *embeddings* aos bancos de dados tradicionais marca o começo de um novo cenário de busca jurídica, onde bancos de dados relacionais como o PostgreSQL [Stonebraker and Rowe 1986] podem ser estendidos com módulos vetoriais, a exemplo do PGVector [PGV nd]. Isso possibilita buscas eficientes por similaridade usando métricas como cosseno e Euclidiana, além de estratégias híbridas que mesclam consulta semântica com filtros estruturados [Stonebraker and Rowe 1986].

2.3. RAG, Sistemas Híbridos e Recuperação Jurídica Inteligente

O paradigma Retrieval-Augmented Generation (RAG) tem destaque no cenário contemporâneo, combinando o poder dos LLMs (*Large Language Models*) com bancos de dados confiáveis, de modo a fornecer respostas contextualizadas e baseadas em conhecimento atualizado [Lewis et al. 2021]. Para o domínio jurídico, tal abordagem se mostra promissora não apenas para mitigação de “alucinações” em redes neurais

[Bommasani et al. 2022], mas para enriquecer a fundamentação de decisões, pesquisas acadêmicas e automação de pareceres. Estratégias híbridas, como a fusão de métodos sparse (BM25) com dense (*embeddings*), têm apresentado resultados superiores em *benchmarks* recentes [Lewis et al. 2021].

2.4. Lei de Zipf e Distribuição da Frequência de Palavras

No contexto da recuperação da informação jurídica, compreender a distribuição da frequência dos termos é fundamental para traçar o perfil lexical do corpus analisado. A Lei de Zipf [Zipf 1949] afirma que, em grandes corpora linguísticos, a frequência de ocorrência de uma palavra é inversamente proporcional à sua posição no ranking de frequência, ou seja, poucas palavras aparecem com alta recorrência, enquanto a maioria ocorre raramente. Nos textos jurídicos, esse fenômeno se manifesta claramente: termos técnicos e expressões normativas tendem a surgir repetidamente, ao passo que outros aparecem com baixa frequência. Neste trabalho, a Lei de Zipf foi empregada exclusivamente para análise exploratória, visando caracterizar o comportamento da distribuição dos termos no corpus jurídico estudado. A abordagem não foi utilizada como critério direto para ponderação ou ajuste de pesos em modelos de busca, mas sim para contextualizar teoricamente a desigualdade na distribuição e subsidiar a compreensão estatística do vocabulário analisado.

3. Metodologia

A metodologia adotada neste estudo foi desenvolvida para garantir a máxima precisão, escalabilidade e reprodutibilidade na construção de um banco vetorial voltado à análise semântica dos atos normativos do CNJ. Todo o processo foi desenhado em etapas claras e integradas, que vão desde a extração dos textos até a avaliação dos resultados em tarefas de recuperação jurídica.

3.1. Coleta e Pré-processamento dos Textos

A primeira etapa consiste na coleta automatizada dos atos normativos, utilizando técnicas de *web scraping* com Python e as bibliotecas requests e BeautifulSoup. O *scraper* foi programado para navegar, identificar e baixar os documentos relevantes, respeitando a estrutura hierárquica e paginada dos portais oficiais. Em seguida, o pré-processamento textual envolve:

- Remoção de marcas HTML e metadados irrelevantes.
- Normalização de caracteres e padronização de seções jurídicas (como artigos, incisos, parágrafos).
- Correção de fragmentações e unificação de blocos textuais correlatos.

3.2. Análise e Caracterização do Corpus

Após a conclusão das etapas de coleta e pré-processamento, procedeu-se a uma análise exploratória de dados (AED) do corpus textual resultante. O objetivo desta etapa foi caracterizar a estrutura estatística e linguística do texto já normalizado, a fim de validar a adequação do corpus para modelagem e informar as estratégias subsequentes de vetorização e recuperação da informação. Dentre as técnicas empregadas, a análise da distribuição de frequência lexical, para verificação de sua conformidade com a Lei de Zipf, foi um procedimento metodológico central. Esta análise permitiu diagnosticar empiricamente os desafios da recuperação lexical no domínio específico notadamente, a alta

incidência de termos de baixo valor semântico e a vasta cauda longa de vocábulos raros e específicos. A confirmação dessas características reforçou a necessidade metodológica de uma abordagem baseada em similaridade semântica para superar as limitações de sistemas tradicionais. Os achados detalhados e os gráficos gerados nesta fase são apresentados na Seção 4 (Análise Exploratória do Corpus).

3.3. Segmentação Jurídica (*Chunking*)

Para preservar o contexto e garantir que a estrutura jurídica dos documentos seja respeitada, foi aplicada uma estratégia de *chunking* recursivo, baseada no módulo Recursive Character Text Splitter do LangChain.

- Os textos são fragmentados em *chunks* coerentes, priorizando divisões por artigos, incisos e preâmbulos.
- *Chunks* excessivamente longos são subdivididos de modo a evitar truncamentos sem perda de contexto.

Esta etapa é fundamental para maximizar o *recall* do sistema e garantir que buscas semânticas retornem trechos juridicamente completos e relevantes.

3.4. Vetorização Semântica (*embeddings*)

Com os chunks devidamente ajustados, faz-se a codificação vetorial usando modelos de ponta em PLN voltados para o português jurídico, como MiniLM, LaBSE, BERTimbau, entre outros. O processo contempla:

- Batch processing acelerado por GPU, para maximizar eficiência e reprodutibilidade.
- Testes comparativos entre modelos, selecionando o *embedding* mais eficaz para o domínio jurídico.

A vetorização transforma textos em matrizes numéricas de alta dimensão, que representam os sentidos dos trechos e as relações semânticas entre eles.

3.5. Banco Vetorial e Estrutura de Dados

Os *embeddings* gerados são armazenados em banco de dados PostgreSQL com extensão PGVector, permitindo buscas rápidas de similaridade.

- Cada registro contém: *chunk* textual, *embedding*, metadados (origem, data, tipo de normativo) e referências estruturais do documento.
- Índices híbridos facilitam consultas que combinam filtros tradicionais (SQL) e similitude vetorial.

A estrutura foi desenhada para manter escalabilidade, integridade dos dados e facilidade de integração com ferramentas de IA e dashboards analíticos.

3.6. Avaliação e Métricas

Para garantir uma avaliação objetiva e replicável do pipeline, foi construído um conjunto de teste denominado Silver Set, composto por 100 *chunks* amostrados aleatoriamente do corpus de cada configuração. Cada trecho foi processado por um LLM de última geração (Google Gemini), integrado via N8N, com duas instruções: (1) gerar uma pergunta cuja resposta estivesse explicitamente no texto e (2) criar uma paráfrase do mesmo conteúdo,

simulando uma variação de consulta do usuário. O resultado foi um conjunto de pares (pergunta, id_documento_correto) que serviu como *ground truth* para medir a eficácia dos sistemas.

Foram comparadas nove configurações: três modelos de *embeddings* — BAAI/bge-m3, sentence-transformers/LaBSE e all-MiniLM-L6-v2 — combinados com três estratégias de segmentação — Estruturada, Tamanho Fixo, e Recursiva. A avaliação utilizou métricas padrão na literatura:

- **Hit@K:** fração de consultas cujo documento relevante está entre os K primeiros resultados:
$$Hit@K = \frac{1}{N}\sum_{i=1}^{N} \mathbb{1}(\text{rank}_i \leq K)$$
- **Mean Reciprocal Rank (MRR):** média do inverso da posição do resultado relevante:
$$MRR = \frac{1}{N}\sum_{i=1}^{N} \frac{1}{\text{rank}_i}$$
- **Precision:** proporção de resultados relevantes entre os retornados:
$$Precision = \frac{\text{documentos relevantes recuperados}}{\text{documentos recuperados}}$$
- **Recall:** proporção de documentos relevantes recuperados entre todos os relevantes existentes:
$$Recall = \frac{\text{documentos relevantes recuperados}}{\text{documentos relevantes totais}}$$

3.7. Reranking e Refinamento Final

Para aprimorar ainda mais a precisão dos resultados retornados, utilizamos o mecanismo de *Cross-Encoder Reranking*, uma segunda etapa de refinamento projetada para reordenar a lista de documentos candidatos fornecida pela primeira fase. O *Reranking* consiste em um filtro de precisão. Enquanto a primeira etapa é otimizada para buscar rapidamente um conjunto de documentos potencialmente relevantes ($K = 10$ em nosso caso) de um universo de milhares, a etapa de *reranking* realiza uma análise mais profunda e computacionalmente mais intensa sobre essa lista restrita. Para isso, empregamos um modelo do tipo *Cross-Encoder*.

Diferentemente dos modelos *Sentence Transformers* usados na primeira fase, que criam vetores para a pergunta e o documento de forma independente, um *Cross-Encoder* processa o par (pergunta, documento) de forma conjunta. Isso permite que o modelo analise as interações semânticas e contextuais entre as palavras da pergunta e do documento, resultando em uma pontuação de relevância muito mais acurada. O processo, aplicado a cada uma das nove configurações de *retriever*, seguiu os seguintes passos:

- **Recuperação Inicial:** Para cada pergunta do nosso conjunto de teste (*Silver Set*), o sistema de *retrieval* correspondente buscou os 10 documentos mais similares.
- **Reclassificação:** Os 10 documentos recuperados foram então passados para o modelo *Cross-Encoder*, que calculou uma nova pontuação de relevância para cada um deles em relação à pergunta original.

- **Reordenação e Medição:** A lista de documentos foi reordenada com base nessas novas pontuações, e a nova posição (*rank*) do documento correto foi registrada.
- **Cálculo de Métricas:** As métricas de performance, como Hit@K e *Mean Reciprocal Rank* (MRR), foram recalculadas com base nesses novos *ranks*.

3.8. Transparência e Reprodutibilidade

Todo o pipeline foi documentado e parametrizado para garantir reprodutibilidade, com controle de versões dos scripts, ambientes e modelos treinados, respeitando princípios de ciência aberta. Isso assegura que outros pesquisadores possam auditar, replicar e aprimorar a metodologia desenvolvida.

4. Análise Exploratória do Corpus

Este capítulo traz a análise exploratória dos atos normativos do CNJ, ressaltando as principais características e padrão do conjunto de dados. Essa fase é essencial para a compreensão dos documentos em termo de contexto.

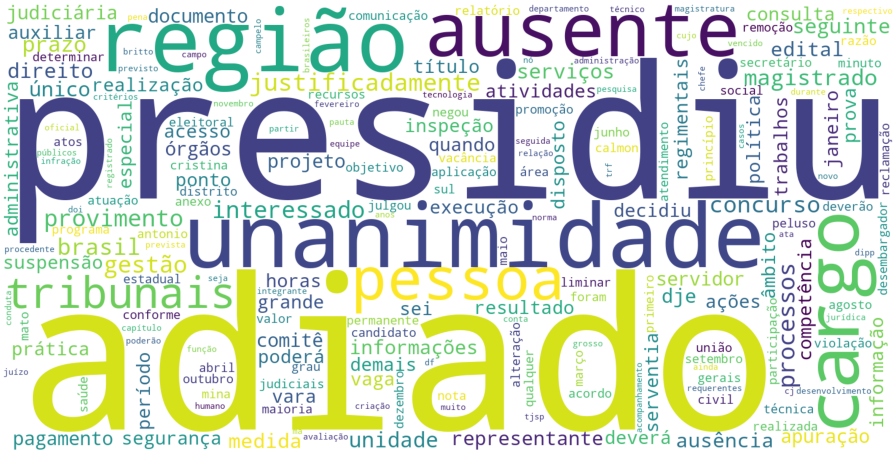

Figura 1. Nuvem de Palavras dos Atos Normativos do CNJ.

A nuvem de palavras apresentada na Figura 1 diz respeito aos termos mais presentes nos atos normativos do CNJ desconsideradas as palavras de uso corriqueiro da linguagem portuguesa - observa-se destaque para termos como “presidiu”, “adiado”, “unanimidade”, “ausente”, “região”, “cargo” e “tribunais”, que se referem ao fato de que os documentos analisados tratam, na sua maioria, dos temas ligados a presidências de sessões, a deliberações colegiadas, a processos administrativos, a movimentos de cargos, decisões proferidas por unanimidade, questões relacionadas a regiões e ao universo dos tribunais. Essa distribuição evidencia o caráter formal e procedimental dos atos normativos do CNJ, que dizem respeito ao papel central das sessões, decisões e movimentação funcional deste universo documental.

Tabela 1. Frequência de Trigramas

Termo	Frequência
Unanimidade Negou Provimento	2150
Resultados Foram Registrados	1616
Pautados Cujos Resultados	1615
Cujos Resultados Foram	1615
Processos Pautados Cujos	1614
Foram Registrados Abaixo	1458
Razão Vacância Cargo	1269
Presidiu Ayres Britto	1266
Prosseguiuse Processos Pautados	1178
Seguida Prosseguiuse Processos	1109
Vacância Cargo Representante	1098
Tecnologia Informação Comunicação	1085
Passa Vigorar Seguinte	1071
Vigorar Seguinte Redação	984
Unanimidade Julgou Improcedente	881
Unanimidade Decidiu Adiar	878
Mato Grosso Sul	869
Ante Ausência Justificada	849
Ausente Razão Vacância	839
Incluir Pauta 120	752

A Tabela 1 apresenta os vinte trigramas (expressões formadas por três palavras adjacentes) mais frequentes nos atos normativos do CNJ. Entre os trigramas mais comuns, destacam-se aquelas traduzidas, em alguns casos, por decisões colegiadas (por exemplo, "unanimidade negou provimento"), processos administrativos, menção a cargos, e registros de resultados oficiais. A singularidade dos trigramas revela que o material examinado tende a enfatizar deliberações, movimentações funcionais e procedimentos formais que caracterizam a atuação do CNJ.

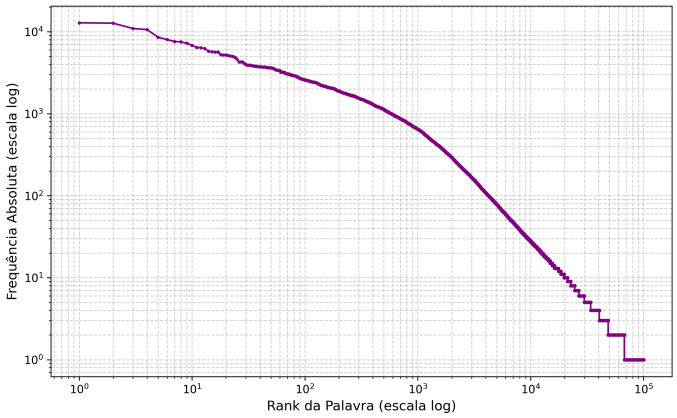

Figura 2. Distribuição de Frequência das Palavras Segundo a Lei de Zipf.

A Figura 2 demonstra, os dados de frequência das palavras de todos os atos normativos do CNJ na escala logarítmica, tanto para o rank quanto para a frequência absoluta. Como mostram as leis de Zipf, a escassez de palavras que ocorrem com alta frequência relata como um reduzido conjunto ocorre com altíssima frequência, enquanto a maioria delas aparece raramente. É possível observar a distribuição inversa típica de corpora textuais: as palavras mais frequentes dominam o vocabulário geral dos documentos, ao passo que as de menor frequência expressam, cada uma, especificidades linguísticas ou temáticas dos atos em análise. Essa pesquisa assevera a regularidade estatística associada ao emprego das palavras e reforça o sentido estrutural da linguagem que o CNJ promove.

5. Resultados e Discussão

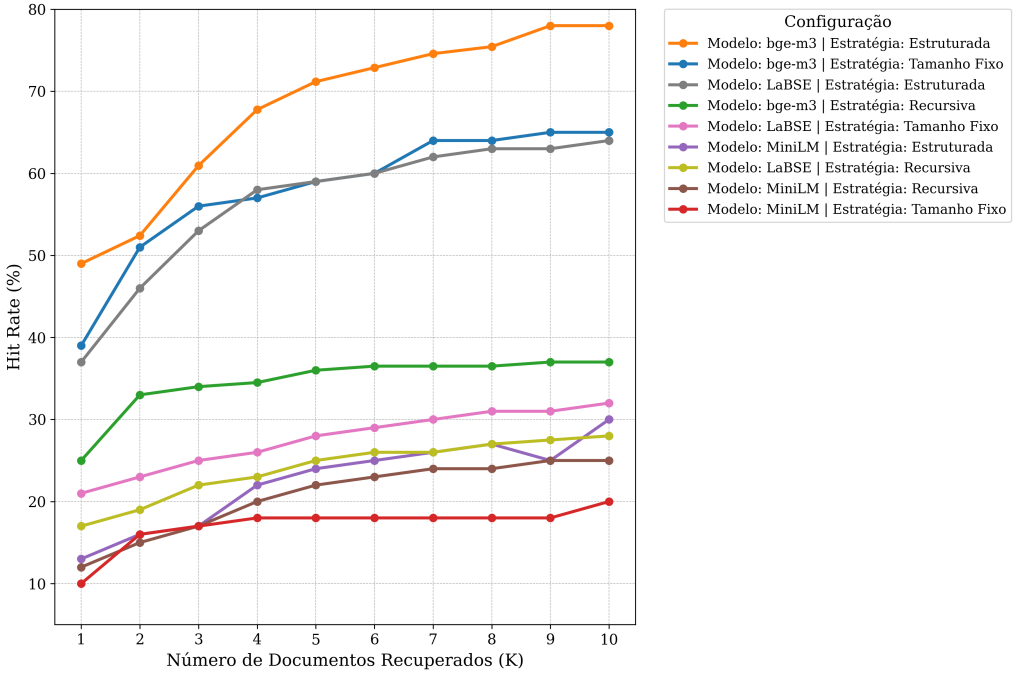

Figura 3. Comparativo de desempenho entre as configurações de recuperação.

A Figura 3 demonstra que a combinação do modelo bge-m3 com a estratégia Estruturada (linha laranja) apresenta um desempenho amplamente superior, alcançando quase 80% de taxa de acerto ao recuperar os 10 documentos mais relevantes. A análise geral revela que o modelo bge-m3 é consistentemente mais eficaz que os concorrentes (LaBSE e MiniLM), e que a abordagem Estruturada é a estratégia que maximiza a performance, tornando essa combinação a escolha técnica ideal. Os experimentos revelaram desempenho expressivamente superior para a combinação BAAI/bge-m3 + Estruturada, que alcançou Hit@10 = 78%, Hit@1 = 49% e MRR = 0.585, evidenciando precisão e consistência no ranqueamento. O segundo melhor desempenho do bge-m3 (Tamanho Fixo) obteve 65% em Hit@10, acima do melhor LaBSE (64%) e muito acima do all-MiniLM-L6-v2 (30%).

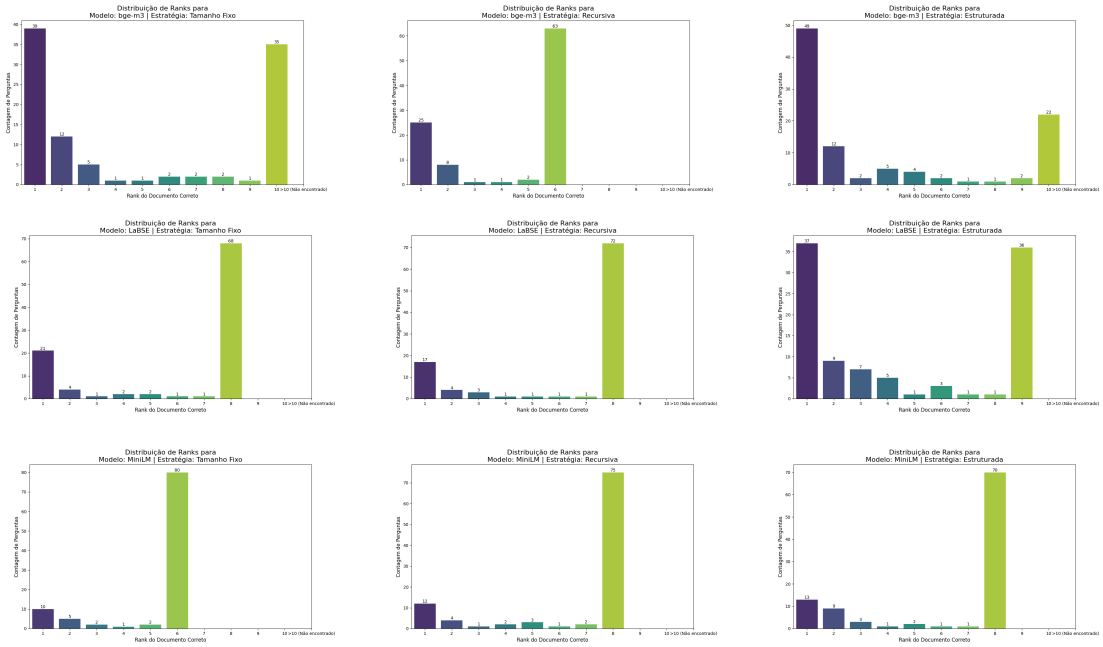

Figura 4. Distribuição de rank dos documentos relevantes na etapa de recuperação, comparando os modelos de *embedding* e as estratégias de chunking.

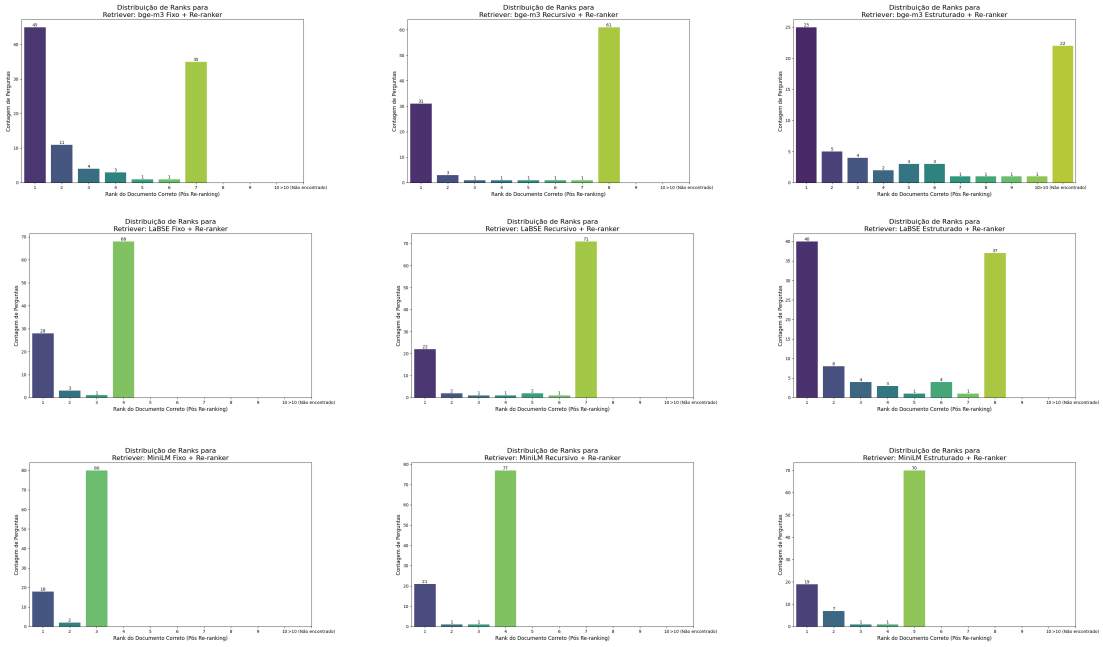

Figura 5. Distribuição de rank dos resultados da busca inicial por modelo e estratégia.

A etapa de recuperação inicial, detalhada na Figura 4, evidencia a clara superioridade da combinação do modelo *bge-m3* com a estratégia Estruturada, que alcançou 49% de acertos no primeiro posto e 78% entre os dez primeiros. Em contraste, os modelos *LaBSE* e *MiniLM* tiveram um desempenho substancialmente inferior, com altas taxas

de falha na recuperação, sobretudo ao usar as estratégias Tamanho Fixo e Recursiva. A segmentação Estruturada foi universalmente a mais eficaz, enquanto a Recursiva foi a menos performática em todas as configurações. Fica demonstrado, portanto, que a escolha do *embedding* é o principal fator de desempenho, mas a estratégia de segmentação é fundamental para otimizar os resultados.

Após a etapa de reordenamento, ilustrada na Figura 5, o modelo *bge-m3* mantém sua superioridade em alcançar o primeiro posto, apesar de uma performance bimodal com falhas notáveis. Em contrapartida, os modelos *MiniLM* e *LaBSE* mostram-se mais previsíveis, porém menos precisos, posicionando os resultados corretos em *ranks* inferiores de forma consistente. Contudo, a eficácia do reordenador depende da qualidade da recuperação inicial. Como os modelos *LaBSE* e *MiniLM* frequentemente falham em selecionar o documento correto como candidato nesta primeira fase, o reordenamento tem impacto mínimo sobre eles. Este padrão reforça que a sólida performance inicial do *bge-m3* o estabelece como a única base viável para um sistema de busca de alta performance.

Quanto às estratégias, a segmentação Estruturada maximizou resultados para todos os modelos, enquanto a Recursiva apresentou pior desempenho em todas as combinações, indicando menor adequação ao corpus jurídico. As métricas quantitativas demonstram que a escolha do *embedding* impacta mais fortemente a performance global, mas a segmentação é determinante para extrair o potencial máximo do modelo.

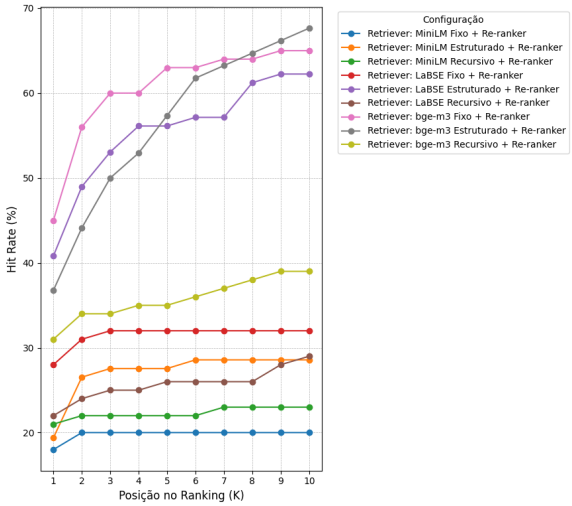

Figura 6. Comparação da taxa de acerto ($hit - rate@k$) entre os modelos avaliados.

A Figura 6 ilustra a performance comparativa das nove configurações após a aplicação do *re-ranking*. Fica evidente que as combinações utilizando o modelo bge-m3 (linhas rosa, cinza e amarela) apresentam um desempenho amplamente superior às demais. A análise detalhada das curvas de performance revela que as estratégias bge-m3 Fixo (linha rosa) e bge-m3 Estruturado (linha cinza) são as mais eficazes. A abordagem Fixo se destaca pela maior *precision* em K=1, alcançando o topo com aproximadamente 45% de acertos, enquanto a Estruturada atinge a maior taxa de recuperação geral ao final do ranking, com quase 70% de acerto em K=10.

De forma geral, podemos confirmar que o modelo bge-m3 é consistentemente mais eficaz que os concorrentes LaBSE e MiniLM. Adicionalmente, as estratégias Fixo e Estruturada se provaram as mais adequadas para maximizar os resultados, tornando a combinação do bge-m3 com qualquer uma dessas duas abordagens a escolha técnica ideal para o sistema. Confirma-se, mais uma vez, que as abordagens Estruturada e de Tamanho Fixo maximizam o desempenho dos principais modelos.

5.1. Caso de Uso: Sistema de Perguntas e Respostas

Testes com perguntas reais apresentaram respostas adequadas, reforçando a aptidão do sistema para assessoria jurídica de alto desempenho.

5.2. Limitações e Sugestões de Melhoria

As limitações do pipeline compreendem dependência de GPU e modelos estrangeiros, as melhorias futuras abrangem experimentos com ANN, expansão do corpus e evolução de *embeddings* jurídicos nacionais.

A Tabela 2 consolida os resultados quantitativos da avaliação de desempenho das nove configurações de *retrieval*. Os dados evidenciam uma clara hegemonia da combinação entre o modelo bge-m3 e a estratégia de segmentação Estruturada. Esta configuração alcançou o desempenho máximo em todas as métricas avaliadas, com destaque para um Hit@1 de 0,4900, um Hit@10 de 0,7800 e um MRR de 0,5854. Tais valores indicam não apenas uma alta capacidade de recuperar o documento correto entre os dez primeiros candidatos, mas também uma notável precisão em posicioná-lo no topo do *ranking*. Em contrapartida, os modelos LaBSE e MiniLM, embora beneficiados pela mesma estratégia Estruturada, apresentaram um desempenho substancialmente inferior, reforçando o impacto decisivo do modelo de *embedding* na qualidade da recuperação semântica.

A análise aprofundada da tabela revela, ainda, a importância da estratégia de segmentação como um fator secundário, porém crítico, para a performance. Para todos os modelos testados, a estratégia Estruturada foi consistentemente superior, seguida pela de Tamanho Fixo e, por último, pela Recursiva. A degradação do desempenho é particularmente acentuada ao se adotar a abordagem Recursiva; no caso do modelo bge-m3, por exemplo, o MRR decai de 0,5854 para 0,2987, uma redução de quase 50%. Fica, portanto, demonstrado que a performance ótima não emerge isoladamente da escolha do modelo ou da estratégia, mas da sinergia entre ambos. O modelo de *embedding* define o potencial máximo de desempenho, enquanto a estratégia de segmentação determina o grau em que esse potencial é efetivamente alcançado no contexto específico do corpus jurídico.

6. Perspectivas Futuras

A infraestrutura de dados vetoriais proposta neste artigo constitui a base essencial para uma nova geração de ferramentas jurídicas inteligentes. As possibilidades de aprimoramento e extensão são imensas, mas algumas direções se destacam como os passos seguintes naturais para este trabalho. A aplicação de um sistema RAG é a mais imediata e de maior efeito. Com os *embeddings* desta base de alto nível, poderá ser possível desenvolver sistemas de Q&A que consultem a base de atos normativos em tempo real e que forneçam respostas certas, contextualizadas e fundamentadas nas fontes originais. Esta aplicação, de um lado, minimiza o risco de "alucinações"de grandes modelos de linguagem, e, de

Tabela 2. Resultados da avaliação de desempenho para os modelos bge-m3, LaBSE e MiniLM utilizando as estratégias Estruturada, Tamanho Fixo e Recursiva

Configuração	Perguntas	Erros	Hit@1	Hit@10	MRR	Prec @10	Rec @10	F1 @10
Modelo: bge-m3 *Estratégia: Estruturada*	100	0	0,4900	0,7800	0,5854	0,0780	0,7800	0,1418
Modelo: bge-m3 *Estratégia: Tamanho Fixo*	100	0	0,3900	0,6500	0,4810	0,0650	0,6500	0,1182
Modelo: bge-m3 *Estratégia: Recursiva*	100	0	0,2500	0,3700	0,2987	0,0370	0,3700	0,0673
Modelo: LaBSE *Estratégia: Estruturada*	100	0	0,3700	0,6400	0,4594	0,0640	0,6400	0,1164
Modelo: LaBSE *Estratégia: Tamanho Fixo*	100	0	0,2100	0,3200	0,2424	0,0320	0,3200	0,0582
Modelo: LaBSE *Estratégia: Recursiva*	100	0	0,1700	0,2800	0,2059	0,0280	0,2800	0,0509
Modelo: MiniLM *Estratégia: Estruturada*	100	0	0,1300	0,3000	0,1937	0,0300	0,3000	0,0545
Modelo: MiniLM *Estratégia: Recursiva*	100	0	0,1200	0,2500	0,1578	0,0250	0,2500	0,0455
Modelo: MiniLM *Estratégia: Tamanho Fixo*	100	0	0,1000	0,2000	0,1362	0,0200	0,2000	0,0364

outro, poderá democratizar o acesso à informação jurídica, uma vez que cidadãos, advogados e servidores darão, assim, os primeiros passos para poder interagir com o complexo acervo do CNJ de forma conversacional e intuitiva. Além disso, outras frentes de pesquisa e desenvolvimento incluem:

- **Desenvolvimento de *Embeddings* Especializados:** Embora os modelos pré-treinados ofereçam um excelente ponto de partida, o treinamento ou *fine-tuning* de modelos de linguagem em um vasto corpus de textos do português jurídico pode capturar com maior precisão as nuances terminológicas e semânticas do domínio, elevando significativamente a acurácia das buscas por similaridade.
- **Otimização com Indexadores ANN:** Com o crescimento da base de dados, a performance das consultas pode ser otimizada com a implementação de indexadores de busca por vizinhos mais próximos aproximados (ANN) de última geração, garantindo buscas em larga escala com baixa latência.
- **Ampliação do Escopo:** A metodologia aqui apresentada é inerentemente esca-

lável. O projeto pode ser ampliado para abranger os acervos de outros tribunais, como o Superior Tribunal de Justiça (STJ) e o Supremo Tribunal Federal (STF), bem como os atos de outros domínios regulatórios (e.g., agências reguladoras), consolidando uma base de conhecimento jurídico nacional que seja unificada, vetorial e de fácil acesso.

Esses avanços convergem para a criação de um ecossistema de inteligência artificial capaz de transformar a pesquisa, a análise e a aplicação do direito no Brasil.

7. Conclusão

O estudo confirma que a supremacia da combinação bge-m3 + Estruturada é estatisticamente consistente, oferecendo ganhos mensuráveis de desempenho (até +48 p.p. em Hit@10 em relação às piores combinações testadas). As fórmulas adotadas permitiram avaliação interpretável e replicável, reforçando a robustez metodológica e o valor prático da abordagem para sistemas de busca jurídica. A metodologia apresentada — incluindo a construção controlada do Silver Set, a comparação sistemática de nove cenários, e a aplicação de métricas consolidadas — serve como referência para trabalhos futuros em recuperação semântica no domínio jurídico.

O progresso e implementação de uma infraestrutura vetorial para o estudo semântico dos atos normativos do CNJ assinala uma evolução significativa na maneira como a informação jurídica pode ser tratada, pesquisada e explorada no contexto brasileiro. Empregando as tecnologias mais recentes de PLN, *embeddings* e bancos de dados vetoriais, comprovou-se que, na prática, a procura por atos normativos pode ir muito além da simples correspondência literal, atingindo uma verdadeira compreensão do conteúdo, do contexto e das relações entre textos jurídicos. As análises ofereceram ganhos significativos em termos de *precision*, *recall* e relevância, apresentando à comunidade jurídica e técnica uma solução que une robustez tecnológica e aderência às necessidades reais de pesquisa. Mais do que um ganho de eficiência, tratar a consulta jurídica a partir de modelos semânticos significa tornar acessíveis documentos, precedentes e sentidos que, tradicionalmente, ficariam ocultos pelas limitações do vocabulário ou pela própria complexidade do Direito. Outro mérito indiscutível dessa abordagem é o seu potencial de adaptação e expansão no futuro. O pipeline sugerido é suficientemente flexível para incorporar novos modelos de linguagens, adaptar-se a outros domínios normativos, melhorar índices e adicionar ferramentas de suporte a decisões baseadas em IA, como sistemas RAG e chatbots jurídicos. Este potencial de inovação garante que a plataforma não só atenda às demandas atuais, como também continuará a ser atual e moderna frente aos desafios futuros. Por fim, a metodologia enfatiza a adesão à transparência, reprodutibilidade e abertura, que são os pilares da ciência de dados aplicada ao setor público. Este trabalho, mais do que ser um produto técnico, é um convite ao diálogo interdisciplinar entre o Direito, a computação, a administração pública e a sociedade para mais eficiência e democratização da Justiça, a exemplo de uma Justiça acessível.

Referências

(n.d.). Pgvector documentation. `https://github.com/pgvector/pgvector`. Accessed on October 4, 2025.

Bommasani, R. et al. (2022). On the opportunities and risks of foundation models. *arXiv preprint arXiv:2108.07258*.

Lewis, P. et al. (2021). Retrieval-augmented generation for knowledge-intensive nlp tasks. *arXiv:2005.11401*.

Lin, J., Nogueira, R., and Yates, A. (2021). Pretrained transformers for text ranking: Bert and beyond. *arXiv:2010.06467*.

Stonebraker, M. and Rowe, L. A. (1986). The design of postgres. In *ACM SIGMOD*.

Zipf, G. K. (1949). *Human behavior and the principle of least effort*. Addison-Wesley Press, Cambridge, MA.