UNIVERSIDADE FEDERAL DO TOCANTINS

PROGRAMA DE PÓS-GRADUAÇÃO EM GOVERNANÇA E TRANSFORMAÇÃO DIGITAL

Bruno mortari

FRAMEWORK PARA CHECAGEM DE FATOS UTILIZANDO INTELIGÊNCIA ARTIFICIAL: MÉTODOS, IMPLEMENTAÇÃO E PROVA DE CONCEITO

Palmas, TO

2025

Bruno mortari

FRAMEWORK PARA CHECAGEM DE FATOS UTILIZANDO INTELIGÊNCIA ARTIFICIAL: MÉTODOS, IMPLEMENTAÇÃO E PROVA DE CONCEITO

Dissertação apresentada ao Programa de Pós-Graduação em Governança e Transformação Digital da Universidade Federal do Tocantins (UFT), como requisito à obtenção do grau de Mestre(a).

Orientador(a): Prof. Dr. Gentil Veloso Barbosa

Palmas, TO
2025

À Deus, pai da verdade.
À família, sempre presentes nas minhas ausências.
Aos orientadores, por iluminarem o caminho.

Resumo

A proliferação de notícias falsas representa um dos maiores desafios da era digital, afetando a confiança pública, o processo democrático e o ecossistema informacional. Esta dissertação propõe um framework para checagem de fatos automatizada utilizando técnicas de Inteligência Artificial (IA). O trabalho está ancorado em uma ampla revisão conceitual e metodológica sobre desinformação, identificando seus tipos, motivações, estratégias de disseminação e os principais vieses cognitivos explorados. A proposta do framework contempla tarefas essenciais como extração multimodal de recursos, detecção de alegações, recuperação de evidências e classificação com explicações interpretáveis. A metodologia inclui a integração de modelos de linguagem natural, análise semântica e ferramentas de RAG (Retrieval-Augmented Generation) para construção de um sistema adaptável e robusto. Para isso, o estudo analisa as práticas das principais agências de checagem de fatos no mundo, buscando obter o máximo de fidelidade à tarefa do checador de fatos. O objetivo final é fornecer suporte tecnológico escalável e confiável a jornalistas, plataformas digitais e usuários na identificação de conteúdos enganosos, promovendo um ambiente digital mais ético e confiável. A validação da proposta é feita por meio de uma prova de conceito que demonstra a viabilidade do sistema em contextos reais.

Palavras-chave: Desinformação; Inteligência Artificial; Checagem de Fatos; Notícias Falsas; Framework Automatizado

Abstract

The proliferation of fake news represents one of the greatest challenges of the digital age, affecting public trust, the democratic process, and the information ecosystem. This dissertation proposes a framework for automated fact-checking using Artificial Intelligence (AI) techniques. The work is anchored in a broad conceptual and methodological review of disinformation, identifying its types, motivations, dissemination strategies, and the main cognitive biases exploited. The proposed framework includes essential tasks such as multimodal resource extraction, claim detection, evidence recovery, and classification with interpretable explanations. The methodology includes the integration of natural language models, semantic analysis, and RAG (Retrieval-Augmented Generation) tools to build an adaptable and robust system. To this end, the study analyzes the practices of the main fact-checking agencies in the world, seeking to obtain maximum fidelity to the fact-checker's task. The ultimate goal is to provide scalable and reliable technological support to journalists, digital platforms, and users in identifying misleading content, promoting a more ethical and trustworthy digital environment. The proposal is validated through a proof of concept that demonstrates the viability of the system in real contexts.

Key-words: Disinformation;Artificial Intelligence;Fact-Checking;Fake News;Automated Framework

Conteúdo

Lista de Ilustrações **8**

Lista de Abreviaturas e Siglas **9**

1 Introdução **11**
1.1 Problema de Pesquisa 12
1.2 Justificativa 13
1.3 Objetivos 14
1.4 Entidades de Verificação de fatos 15
1.5 Agências e suas metodologias 15

2 Revisão Bibliográfica **19**
2.1 Conceito de Desinformação 19
2.2 Tipologia de notícias enganosas 22
2.2.1 Propaganda Enganosa 22
2.2.2 Clickbait 23
2.2.3 Sátira 24
2.2.4 Erros de edição 25
2.2.5 Conteúdo Patrocinado 25
2.2.6 Notícias tendenciosas 26
2.2.7 Teoria da Conspiração 27
2.2.8 Pseudociência 27
2.3 Métodos de detecção 28
2.3.1 Detecção a partir do conteúdo da notícia 28
2.3.2 Detecção baseada no conhecimento 29
2.3.3 Detecção baseada no estilo 29
2.3.4 Detecção manual 29
2.3.5 Detecção baseada na análise de dados 29
2.3.6 Detecção baseada em Propagação 30
2.3.7 Detecção baseada em dados multimodais 30
2.4 Identificação das alegações 30
2.5 Recuperação de evidências 33

3 Evolução Teórico-prática em IA **34**

4 Metodologia **38**
4.1 Modulação 39
4.1.1 Extração de recursos multi-modal 39

4.1.2 Detecção de Alegações 41
4.1.3 Recuperação de Evidências 42
4.1.4 Predição da Veracidade e Explicação 46
4.2 Avaliação 49
4.2.1 Seleção do conjunto de dados 49
4.2.2 Pré-processamento dos dados 50
4.2.3 Execução da avaliação 50
4.2.4 Resultados Esperados 52
4.2.5 Custos Estimados 52

5 Referências **53**

Lista de Figuras

1 Linha do tempo - eventos relevantes sobre desinformação - adaptado[PM18] 12
2 Processo de checagem de fatos traduzido [Mon25] 18
3 Propaganda enganosa 23
4 *Clickbait* 24
5 Sátira 24
6 Erro de edição 25
7 Conteúdo Patrocinado 26
8 Notícia tendenciosa 26
9 Teoria da conspiração 27
10 Pseudociência 28
11 Arquitetura Modular do Framework 38
12 Módulo I: Extração de recursos multi-modal 40
13 Módulo II: Detecção de Alegações 41
14 Módulo III: Recuperação, avaliação e refinamento 43
15 Módulo IV: síntese final, classificação e explicação 46

IA Inteligência Artificial (also appears as AI)

UFT Universidade Federal do Tocantins

PPGGTD Programa de Pós-Graduação em Governança e Transformação Digital

RAG Retrieval-Augmented Generation

GPT Generative Pre-trained Transformer

a.C. Antes de Cristo

OMS Organização Mundial da Saúde

IFCN International Fact-Checking Network

EFCSN European Fact-checking Standards Network

API Application Programming Interface

NER Named Entity Recognition (Reconhecimento de Entidades Nomeadas)

BERT Bidirectional Encoder Representations from Transformers

XLM-R Cross-lingual Language Model (RoBERTa based)

mBERT Multilingual BERT

AraBERT BERT model for Arabic

BERTweet BERT model for Tweets

DistilBERT Distilled version of BERT

LLM Large Language Model (Grande Modelo de Linguagem)

LLM-AUGMENTER System name/acronym

MOCHEG Dataset name/acronym

CLIP Contrastive Language–Image Pre-training

FL Federated Learning (Aprendizado Federado)

FedAvg Federated Averaging

IGMV Indicador Gasto médio do voto

TSE Tribunal Superior Eleitoral

LISA Local Indicators of Spatial Association

IBGE Instituto Brasileiro de Geografia e Estatística

PLN Processamento de Linguagem Natural

OCR Optical Character Recognition

VP Verdadeiros Positivos (True Positives)

FP Falsos Positivos (False Positives)

VN Verdadeiros Negativos (True Negatives)

FN Falsos Negativos (False Negatives)

TPR Taxa de Verdadeiro Positivo (True Positive Rate) / Recall

FPR Taxa de Falso Positivo (False Positive Rate)

ROC Receiver Operating Characteristic

AUC Area Under the Curve

SVM Support Vector Machines

CNN Redes Neurais Convolucionais (Convolutional Neural Networks)

EAVI European Association for Viewers Interests

BBC British Broadcasting Corporation

FEVER Fact Extraction and VERification (Dataset name)

URL Uniform Resource Locator

ID Identifier

PT-BR Português do Brasil

DBpedia Knowledge base name/acronym

1 Introdução

A disseminação de informações falsas é um fenômeno que remonta a tempos antigos. O relato bíblico de Nabote, descrito no livro de 1 Reis 21, datado por volta do reinado do rei Acabe de Israel, que governou entre 874 a.C. e 853 a.C., ilustra um dos primeiros registros históricos do impacto da desinformação.

"Puseram-se, pois, dois homens malignos diante dele, e testemunharam contra Nabote perante o povo, dizendo: Nabote blasfemou contra Deus e contra o rei. Então o levaram para fora da cidade, e o apedrejaram, e ele morreu." (1 Reis 21:13)

Nessa passagem, Jezabel ordena que falsas testemunhas acusem Nabote de blasfêmia, resultando injustamente em sua condenação e morte, com o propósito de se apropriar de sua vinha, após sua recusa de ceder a herança de seus pais ao rei Acabe. Esse episódio reflete uma prática que persiste até os dias atuais: a criação e propagação de informações falsas para manipular opiniões, influenciar decisões e atender a interesses políticos e econômicos.[Ell97]

A proliferação de desinformações, conhecida popularmente como *fake news*, tornou-se um dos desafios mais prementes na era da transformação digital. Embora a sua propagação não seja um fenômeno novo, a ascensão das redes sociais e dos meios de comunicação digitais amplificou exponencialmente seu alcance e impacto [AG17]. Nesse contexto, o debate acadêmico tem-se concentrado na compreensão das dinâmicas de sua propagação, seus impactos sociais e as estratégias para sua detecção e mitigação.

Em uma breve história das *fake news* e desinformação [PM18], os autores apresentam um módulo de aprendizagem para jornalistas e educadores e exploram a história da desinformação, mostrando que a fabricação de informação não é um fenômeno novo. Desde campanhas de propaganda na Roma Antiga até a invenção da imprensa e a proliferação de boatos como o Grande Embuste da Lua, a disseminação de informações falsas tem evoluído com a tecnologia.

O advento do rádio, da televisão e, mais recentemente, da internet e das redes sociais, multiplicou drasticamente os riscos e a escala da desinformação, incluindo sátiras, noticiosas mal interpretadas e propaganda computacional. O guia também destaca casos contemporâneos de manipulação informacional com consequências políticas e sociais significativas, como interferências eleitorais e crises diplomáticas. Além disso, aborda a reação global ao problema, incluindo iniciativas de combate à desinformação e debates sobre a regulamentação de plataformas online. Em última análise, o módulo visa fornecer um contexto histórico para entender e abordar a crise da "desordem informacional"no século XXI.

Segue uma figura representando a linha do tempo contendo eventos relevantes da desinformação até 2018:

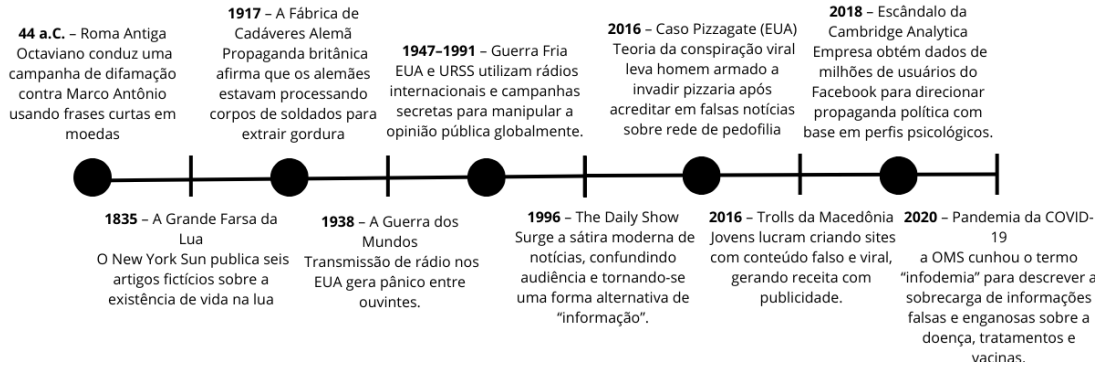

Figura 1: Linha do tempo - eventos relevantes sobre desinformação - adaptado[PM18]

Estes são apenas alguns exemplos de incontáveis casos de fins trágicos envolvendo a desinformação. Diante deste quadro, é primordial que os estudiosos se concentrem em desenvolver técnicas eficazes para sua detecção e combate. Apesar deste estudo se delimitar à checagem de fatos automatizada, muitas outras frentes devem ser atacadas para, ao menos, amenizar os efeitos da desinformação, tais como: Educação do público para a formação de um pensamento crítico, compreensão da psicologia da crença e da partilha, compreensão das motivações por trás da desinformação, regulamentação e políticas, colaboração multissetorial e regulação das plataformas de mídia social.

1.1 Problema de Pesquisa

A checagem de fatos representa um considerável desafio para a sociedade contemporânea, especialmente em um cenário digital onde as informações circulam rapidamente e sem barreiras geográficas. O problema central desta pesquisa está na necessidade de identificar e checar fatos, utilizando-se de inteligência artificial para desenvolvimento de um framework eficaz.

Esta problemática abrange desafios significativos que exigem soluções inovadoras. Inicialmente, há a dificuldade em definir e caracterizar precisamente esse fenômeno. O fato da desinformação pode variar desde informações totalmente fabricadas até conteúdos parcialmente enganosos, muitas vezes criados com a intenção deliberada de manipular a opinião pública. Essa multiplicidade de formas dificulta a detecção automatizada e exige modelos adaptáveis a diferentes contextos e tipos de desinformação. [DCFG21]

Além disso, as *fake news* se tornam mais convincentes devido ao uso de mecanismos de persuasão que exploram elementos emocionais e psicológicos. A credibilidade das notícias falsas é reforçada por estratégias que combinam apelos à autoridade, argumentos lógicos aparentemente coerentes e manipulação emocional. Esse aspecto torna o combate à desinformação ainda mais desafiador, pois um sistema automatizado precisa reconhecer tanto padrões linguísticos quanto contextuais para avaliar a veracidade de uma notícia. [GPA20]

Outro ponto crítico é o impacto social e político. A desinformação tem sido usada para influenciar eleições, enfraquecer a confiança nas instituições democráticas e propagar teorias conspiratórias. A rapidez com que essas notícias se espalham nas redes sociais torna a detecção e a mitigação um desafio tecnológico significativo, demandando soluções que combinem processamento de linguagem natural, análise de redes sociais e aprendizado de máquina. [MFE+19]

No campo metodológico, o processo de detecção enfrenta dificuldades devido à diversidade de formatos e plataformas. A combinação de texto, imagens e vídeos exige abordagens multimodais, capazes de integrar diferentes tipos de dados para uma análise mais precisa. Ademais, os modelos de IA devem ser robustos o suficiente para minimizar ruídos, identificar relações semânticas relevantes e adaptar-se às particularidades das postagens em redes sociais, que são frequentemente informais e repletas de gírias e abreviações. [SSC+19]

A tarefa do jornalista no trabalho de checagem de fatos consiste fundamentalmente em investigar e avaliar a veracidade de alegações, com o objetivo de informar o público de maneira precisa. Inicialmente, o jornalista deve monitorar diversas fontes de informação para identificar alegações que demandam verificação, priorizando aquelas que são verificáveis e de maior interesse público ou potencial impacto. Em seguida, o processo envolve a coleta de evidências de múltiplas fontes, a análise aprofundada e contextualização das alegações para entender seu significado completo, e a determinação da veracidade através de um julgamento embasado nas evidências encontradas. [MAMP22]

Um aspecto crucial do trabalho é a produção de justificativas claras e transparentes para as conclusões alcançadas, explicando o raciocínio e as evidências que sustentam a avaliação de veracidade. Os jornalistas devem manter a imparcialidade em sua análise e ser transparentes sobre seus métodos e fontes. O processo pode envolver revisão e colaboração, e o objetivo final é disseminar os resultados da checagem de forma acessível ao público, corrigindo informações errôneas e promovendo o pensamento crítico. A seleção e verificação de alegações são consideradas aspectos centrais do fact-checking. [MAMP22]

1.2 Justificativa

A disseminação de informações falsas, um fenômeno com raízes históricas profundas com exemplos ao longo da história [PM18], transformou-se em um dos desafios mais críticos da sociedade contemporânea na era digital. A ascensão das redes sociais e dos meios de comunicação digitais amplificou exponencialmente o alcance, a velocidade e o impacto da desinformação [AG17], transcendendo barreiras geográficas e tornando a verificação da veracidade um problema de escala global.

O processo tradicional de checagem de fatos, realizado por jornalistas e organizações especializadas, embora essencial e minucioso [MAMP22], enfrenta limitações significati-

vas diante do volume avassalador e da velocidade vertiginosa com que a desinformação se espalha online. A diversidade de formatos (texto, imagem, áudio, vídeo) e a natureza muitas vezes informal e ruidosa das postagens em redes sociais (gírias, abreviações) impõem desafios metodológicos adicionais [SSC+19].

Neste cenário, torna-se imperativa a busca por soluções tecnológicas inovadoras e escaláveis que possam auxiliar no processo de identificação, verificação e mitigação da desinformação. A IA emerge como uma ferramenta promissora para enfrentar essa "desordem informacional". A capacidade da IA de processar grandes volumes de dados, reconhecer padrões complexos, analisar conteúdos multimodais e operar em alta velocidade oferece um potencial significativo para complementar e escalar os esforços de checagem de fatos.

Portanto, esta pesquisa se justifica pela necessidade urgente de desenvolver ferramentas mais eficazes para combater a desinformação na era digital. A proposição de um framework baseado em IA para a checagem de fatos visa abordar diretamente os desafios de escala, velocidade, complexidade e multimodalidade inerentes ao problema. Ao buscar automatizar e otimizar etapas cruciais do processo de verificação – desde a extração de recursos e detecção de alegações até a recuperação de evidências e classificação final com explicação –, este estudo pretende contribuir com uma solução robusta e adaptável, capaz de fornecer suporte valioso a jornalistas, plataformas digitais e ao público em geral na identificação e combate às informações falsas, fomentando um ecossistema informacional mais saudável e confiável.

1.3 Objetivos

O objetivo central desta pesquisa é propor um framework baseado em inteligência artificial para checagem de fatos, perfazendo as várias tarefas do profissional, combinando métodos de RAG Multimodal, análise comparativa via similaridade e modelos de interpretabilidade.

Para alcançar o objetivo geral, esta pesquisa estabelece os seguintes objetivos específicos:

- Extrair recursos multimodais da notícia a ser checada: O framework deve ser capaz de reconhecer os tipos de dados envolvidos na matéria e extrair a informação;
- Detectar as alegações verificáveis: o sistema irá identificar as principais alegações de uma notícia relevantes e verificáveis;
- Recuperar evidências: através de consulta web, evidências para construção de uma base de conhecimento devem ser extraídas;
- Classificar a notícia: por fim, o framework deve ser habilitado para classificar a notícia em um dos tipo de notícia e explicar a sua decisão, destacando os principais termos que levaram à decisão.

1.4 Entidades de Verificação de fatos

A International Fact-Checking Network (IFCN), lançada em 2015 pelo Poynter, reúne a crescente comunidade de verificadores de fatos ao redor do mundo. A rede defende a integridade da informação na luta global contra a desinformação, apoiando os verificadores por meio de networking, capacitação e colaboração. **site**

O status de signatário da IFCN pode ser concedido a organizações legalmente registradas que se dedicam à verificação de fatos, publicando relatórios imparciais sobre a precisão de declarações de figuras públicas, instituições proeminentes e afirmações amplamente divulgadas, com foco em questões de interesse público. **site**

A European Fact-checking Standards Network (EFCSN) é a voz dos verificadores de fatos europeus que defendem e promovem os mais altos padrões de verificação de informações e alfabetização midiática, com o objetivo de combater a desinformação em benefício do público. **site**

O Código Europeu de Padrões para Organizações Independentes de Verificação de Fatos é um conjunto de critérios que garante que as organizações dedicadas à verificação de desinformação sigam os mais altos padrões de metodologia, ética e transparência para servir ao interesse público.**site**

1.5 Agências e suas metodologias

Um dos pilares nas metodologias utilizadas entre as agências de checagem concentra-se na detecção e seleção de alegações. Este processo geralmente começa com o monitoramento ativo de diversas plataformas, como redes sociais, meios de comunicação tradicionais e aplicativos de mensagens (Reuters [Reu25], Chequeado [Che25d], CFN [dFN25], Facta [Fac25a], hibrid.info [hib25]), complementado frequentemente pela receção de sugestões do público (First Check [Che25b], Africa Check [Che25a], Factcheck.Vlaanderen [Vla25], Comprova [Com25]). A seleção do material a ser verificado baseia-se em critérios como viralidade, relevância, interesse público, potencial de dano ou impacto social (Reuters [Reu25], CFN [dFN25], Aos Fatos [Fat25], Infoveritas [Inf25], AFP [AFP25]), focando em alegações factuais verificáveis e excluindo, geralmente, opiniões ou previsões (Aos Fatos [Fat25], Factcheck.Vlaanderen [Vla25], Facta [Fac25a]). Algumas organizações, como a Factcheck.Vlaanderen [Vla25], mencionam o uso de IA para auxiliar na identificação de conteúdos de alto alcance com potencial desinformativo.

Outra abordagem refere-se ao processo de investigação e verificação. Uma vez selecionada uma alegação, a prática comum envolve investigar a sua origem (Reuters [Reu25], Chequeado [Che25d], CFN [dFN25]) e reunir evidências através da consulta a múltiplas fontes, com forte preferência por fontes primárias e oficiais (Reuters [Reu25], Chequeado [Che25d], Factcheck.ge [Fac25b], Facta [Fac25a], dpa-Faktencheck [dDPA25]). A verificação cruzada da informação [Che25c, Fac25b, dDPA25, Com25] e a consulta a especialistas

são passos frequentes (Reuters [Reu25], First Check [Che25b], Africa Check [Che25a], Infoveritas [Inf25]). Ferramentas digitais como pesquisa reversa de imagens, análise de metadados e geolocalização são empregadas para analisar conteúdos multimédia (First Check [Che25b], Chequeado [Che25d], Greece Fact Check [Che25c], dpa-Faktencheck [dDPA25]). A contextualização da informação é considerada crucial (Chequeado [Che25d], Africa Check [Che25a], AFP [AFP25]), e algumas agências tentam contactar o autor da alegação (Africa Check [Che25a], Factcheck.Vlaanderen [Vla25], Factcheck.ge [Fac25b]). Embora conscientes da mídia sintética [Reu25] e usando ferramentas para análise auxiliar [Che25c], as fontes indicam que a IA não é, em geral, usada como ferramenta central no julgamento da verificação em si [Reu25, Fat25, Vla25, Fac25a].

Finalmente, o terceiro conjunto de práticas metodológicas abrange a publicação, classificação e transparência. Após a investigação, os resultados são publicados detalhadamente (Reuters [Reu25], CFN [dFN25], Africa Check [Che25a]), frequentemente acompanhados de um sistema de classificação ou veredicto, como "Falso", "Enganoso", "Verdadeiro", "Sem Contexto", ou variações destes (Reuters [Reu25], Chequeado [Che25d], CFN [dFN25], Aos Fatos [Fat25], Infoveritas [Inf25], Factcheck.ge [Fac25b], Facta [Fac25a], AFP [AFP25], hibrid.info [hib25]). A transparência é um princípio fundamental, manifestado pela citação explícita das fontes, muitas vezes com links ativos (Reuters [Reu25], CFN [dFN25], Facta [Fac25a], dpa-Faktencheck [dDPA25], AFP [AFP25]), detalhamento da metodologia [Fat25, Com25, hib25] e políticas de correção de erros [Fat25, Che25a]. Muitas organizações implementam processos de revisão interna por pares ou editores antes da publicação para garantir a precisão (CFN [dFN25], Infoveritas [Inf25], Facta [Fac25a], dpa-Faktencheck [dDPA25], Comprova [Com25]).

Em seu estudo detalhado, *Fact-Checking Journalism and Political Argumentation: A British Perspective* [Bir19], o autor oferece uma análise metodológica robusta das práticas de checagem de fatos no contexto britânico. Utilizando a eleição geral antecipada de 2017 como um estudo de caso central, a pesquisa foca na produção das três principais organizações de fact-checking do Reino Unido: Channel 4 FactCheck, BBC Reality Check e a independente Full Fact. A metodologia é notável por ir além de uma simples descrição, buscando entender como as normas e práticas jornalísticas de verificação se manifestam e evoluem em um ambiente político complexo, marcado por debates sobre "pós-verdade", termo que descreve circunstâncias em que fatos objetivos são menos influentes na formação da opinião pública do que apelos à emoção e à crença pessoal.

A abordagem metodológica combina análise de conteúdo quantitativa e qualitativa com referenciais teóricos da análise do discurso político e da teoria da argumentação. O autor examina sistematicamente o corpus completo de artigos de checagem de fatos relacionados à eleição publicados por essas organizações, codificando tipos de alegações, fontes utilizadas, vereditos (explícitos e implícitos), e a presença de viés ou busca por equilíbrio. Crucialmente, a análise se estende aos tweets promocionais e ao engajamento do público

(respostas, retweets, curtidas) nas plataformas de mídia social, além de comparar a produção de fact-checking com a cobertura em programas de notícias tradicionais e debates televisionados, permitindo uma avaliação da função e do impacto da checagem de fatos na argumentação política mais ampla. Segue uma tabela com o resumo do processo de checagem de fatos segundo o autor:

Tabela 1: Resumo do Processo de Checagem de Fatos

Fase	Descrição
1. Seleção da Alegação	Identificação de afirmações feitas por políticos, partidos, mídia, etc., com base em relevância, dúvida pública, potencial de desinformação ou proeminência no debate.
2. Verificação e Pesquisa	Consulta a fontes primárias, estatísticas oficiais (ex: ONS), relatórios de especialistas (ex: IFS, NAO), pesquisa acadêmica e, idealmente, corroboração entre múltiplas fontes.
3. Análise e Interpretação	Avaliação do contexto da alegação, metodologia das fontes, uso (enganoso ou não) de dados corretos, desambiguação de definições e identificação de limitações ou vieses. Este passo distingue a checagem da simples verificação.
4. Formulação do Veredito/Explicação	Apresentação das conclusões, frequentemente em formato narrativo no Reino Unido (em vez de escalas), indicando se a alegação é correta, incorreta, enganosa, necessita de contexto, é mista, ou através de artigos "explicadores"que detalham a complexidade do tema.
5. Publicação e Disseminação	Divulgação dos resultados em plataformas online dedicadas (blogs, websites) e promoção via mídias sociais (ex: Twitter), com integração limitada na grande mídia tradicional.

Em um trabalho de referência, o autor [Bor23] desenvolveu um guia prático e reflexivo sobre o processo de checagem editorial de fatos (fact-checking) no jornalismo e em outras formas de mídia não ficcional. Ele combina fundamentos teóricos, experiências reais e orientações práticas para quem deseja aprender ou aprimorar essa habilidade. O autor ainda distingue checagem editorial (verificação antes da publicação, por alguém externo à redação do texto) da checagem política (focada em declarações públicas). O estudo também explora os desafios de checar informações em um mundo digital saturado por desinformação, destacando o papel da checagem na manutenção da credibilidade jornalística. A seguir segue o passo a passo descrito pela metodologia:

- **Preparação e leitura crítica**: Ler o texto a ser checado como um todo. Identificar cada afirmação factual (nomes, datas, locais, números, citações, estatísticas, etc.). Separar o que é fato verificável do que é opinião ou interpretação.

- **Coleta de fontes**: Reunir as fontes originais do autor (entrevistas, relatórios, artigos científicos, etc.). Identificar se as fontes são primárias (diretas) ou secundárias (indiretas). Verificar a confiabilidade e autoridade de cada fonte.

- **Verificação dos fatos**: A verificação de fatos requer abordagens distintas conforme o tipo de informação: nomes próprios devem ter sua grafia e função conferidas oficialmente; datas e eventos precisam ser confirmados com registros confiáveis; números e estatísticas exigem checagem em fontes primárias ou bases de dados; citações devem ser validadas contra gravações ou publicações originais; imagens necessitam da verificação de metadados e contexto; e, por fim, analogias ou conceitos devem ser avaliados quanto à sua lógica e consistência interna.

- **Registro e Organização**: Manter documentação clara de onde cada fato foi checado. Utilizar uma cópia anotada do texto, com links e referências para cada afirmação. Armazenar backups físicos e digitais.

- **Discussão**: Alertar para inconsistências ou pontos frágeis. Recomendar reescritas, exclusões ou reformulações. Trabalhar colaborativamente, mas com postura crítica e rigorosa.

A Universidade Monash, em seu site [Mon25], sintetiza em uma imagem as principais etapas do processo de checagem de fatos. A metodologia é formulada em seis passos: Estabelecer a alegação, pesquisa, checar os fatos, rever os fatos, debate rigoroso e o julgamento.

Figura 2: Processo de checagem de fatos traduzido [Mon25]

2 Revisão Bibliográfica

Esta seção compreende a revisão bibliográfica dos estudos referentes ao processo de checagem manual de fatos, iniciando pelo conceito de desinformação e sua tipologia, seguido pelos principais métodos de detecção.

2.1 Conceito de Desinformação

O conceito de desinformação pode ser compreendido de maneira mais restrita ou mais ampla, dependendo da definição adotada. Em uma perspectiva restrita, *fake news* refere-se a conteúdos deliberadamente fabricados, verificavelmente falsos e criados com a intenção explícita de enganar os leitores. Esse conceito enfatiza a falsidade factual e a imitação do formato de veículos jornalísticos legítimos, sem, no entanto, seguir suas normas editoriais e processos de verificação. Exemplos clássicos incluem notícias falsas criadas para aumentar o tráfego na internet ou desinformações motivadas por interesses políticos. [ZZ21] [SSW+17]

Por outro lado, uma abordagem mais ampla do termo fake news considera um espectro maior de fenômenos relacionados à desinformação, incluindo boatos, propagandas, sátiras e *clickbaits*. Nessa visão, não apenas as informações comprovadamente falsas são relevantes, mas também conteúdos enganosos, sensacionalistas ou carregados emocionalmente, ainda que a intenção de manipular não seja o único fator determinante. Além disso, o termo tem sido instrumentalizado politicamente para deslegitimar veículos de comunicação tradicionais, sendo utilizado por figuras públicas para desacreditar notícias desfavoráveis. Essa abordagem também considera o impacto e a velocidade da disseminação de informações nas redes sociais, bem como a influência dos mecanismos de amplificação algorítmica. [DCFG21]

A distinção entre os conceitos restrito e ampliado de *fake news* reside na ênfase dada à intencionalidade e ao escopo da desinformação. Enquanto a definição mais restrita foca na produção deliberada de notícias falsas que imitam o jornalismo legítimo, a abordagem ampliada incorpora diversos tipos de conteúdo impreciso ou manipulador, além de incluir conceitos relacionados, como *misinformation* - informação incorreta sem intenção de enganar e *disinformation* - informação deliberadamente falsa para manipulação. A ausência de uma definição única e amplamente aceita do termo contribui para a contínua controvérsia em torno de sua aplicação, tornando essencial a análise criteriosa do contexto em que é empregado.

Em uma abordagem acadêmica, *Fake news*, de acordo com o Cambridge Dictionary, é definida como "histórias falsas que são criadas e espalhadas na Internet com o objetivo de influenciar a opinião pública e aparentar ser verdadeiras". Refere-se a informações falsas que são intencionalmente fabricadas e disseminadas com o propósito de enganar o público,

frequentemente projetadas para se assemelhar a notícias legítimas. Certas plataformas de conteúdo se tornaram um terreno fértil para espalhar não apenas informações falsas, mas também diferentes tipos de conteúdo, como sátira, propaganda e rumores, tornando cada vez mais difícil para as pessoas distinguirem entre notícias reais e falsas. [HA21]

Para [SSW+17], o conceito de fake news refere-se a notícias falsas que são intencionalmente criadas e verificavelmente falsas, com o objetivo de enganar ou induzir o público ao erro. Esta definição busca destacar dois aspectos essenciais que caracterizam as fake news: autenticidade, onde a notícia deve ser falsa de forma comprovável; e intenção, pois tem como propósito enganar os leitores.

Conforme [ALL23], *fake news* são informações falsas ou enganosas que imitam o formato de notícias reais e podem ser disseminadas por diferentes atores, incluindo governos, organizações políticas, jornalistas, criminosos, teóricos da conspiração e indivíduos com interesses variados. Elas se distinguem da mera desinformação ou erro jornalístico porque são criadas e propagadas de forma intencional para manipular a opinião pública, criar desordem, obter ganhos financeiros ou promover viés ideológico. Embora haja debate sobre a inclusão da sátira no conceito de fake news, a principal característica desse fenômeno é a intenção deliberada de enganar ou confundir.

Para os autores [ZZ21], desinformações são conteúdos noticiosos que contêm informações falsas ou desatualizadas, podendo ser completamente ou parcialmente incorretos. Elas podem assumir diferentes formas, incluindo artigos que apresentam conhecimento obsoleto ou declarações falsas em partes do conteúdo textual ou visual. Essa definição amplia o conceito tradicional de fake news, enfatizando a necessidade de abordagens mais sofisticadas para sua detecção, como o uso de grafos de conhecimento dinâmicos e modelos de classificação mais flexíveis.

De forma mais categórica, os autores [AG21] definiram *fake news* como um termo abrangente que engloba diversas formas de informações enganosas ou manipuladas, incluindo desinformação, *misinformation*, notícias fabricadas, sátiras, paródias, rumores e boatos. Embora algumas dessas formas possam ter intenções humorísticas ou benevolentes, como a sátira e a paródia, outras são deliberadamente criadas para desinformar, confundir, manipular a opinião pública, causar impacto político ou gerar lucro financeiro.

Em um estudo de caso voltado para o Twitter, o autor definiu as fake news como informações falsas ou enganosas que imitam o formato de notícias reais, utilizando elementos da narrativa jornalística para dar credibilidade ao conteúdo. Elas se caracterizam por três aspectos essenciais: (1) a emulação da linguagem e dos componentes noticiosos do jornalismo, (2) a falsidade total ou parcial da narrativa e (3) a intenção deliberada de enganar ou manipular percepções. Diferente de sátiras ou boatos, as fake news são criadas intencionalmente para desinformar, influenciando opiniões e decisões, especialmente em contextos como eleições e debates políticos. [RG19]

Os estudos costumam identificar os seguintes componentes presentes em uma desin-

formação, conforme descrito abaixo:

- **Intencionalidade**: caracterizada pela apresentação deliberada de alegações que são tipicamente falsas ou enganosas, travestidas como notícias. Diferentemente de erros factuais ou imprecisões não intencionais, a desinformaçao é criada com o objetivo consciente de induzir o público ao erro. [MFE+19]

- **Engano Sistêmico** *por design*: A expressão "*por design*"ressalta que o engano não é acidental, mas sim intrínseco ao sistema de produção e disseminação da fake news. Isso implica que as fontes e canais utilizados são projetados para manipular os processos cognitivos do público, explorando suas vulnerabilidades e vieses. [Gel18]

- **Mimetismo de Fontes Legítimas**: Para ganhar credibilidade e facilitar o engano, a má notícia frequentemente imita o formato, o estilo e as convenções de organizações de mídia legítimas. Essa estratégia de mimetismo visa confundir o público e levá-lo a acreditar na veracidade das informações falsas. [Gel18]

- **Exploração de Vieses Cognitivos**: A disseminação destas notícias é potencializada pela manipulação dos vieses cognitivos dos consumidores, tais como:

  a) Viés de confirmação: As pessoas tendem a buscar, interpretar e lembrar informações que confirmam suas crenças preexistentes, ignorando ou rejeitando evidências contrárias. Isso faz com que aceitem quaisquer informação que reforcem suas opiniões, sem questionar sua veracidade.

  b) Efeito de repetição (ilusão da verdade) : Quanto mais uma informação é repetida, mais as pessoas tendem a acreditar nela, independentemente de sua veracidade. São frequentemente compartilhadas diversas vezes, o que reforça a sensação de que são verdadeiras.

  c) Excitação afetiva: Notícias falsas costumam apelar para emoções fortes, como medo, raiva ou indignação, porque emoções intensas aumentam o engajamento e a disseminação da informação sem verificação.

  Ao explorar essas vulnerabilidades, os seus criadores conseguem influenciar a opinião pública e garantir a propagação contínua da desinformação.

- **Objetivos escusos**: Os criadores de desinformação podem ter diferentes objetivos, que vão desde ganhar dinheiro através de cliques em anúncios online até influenciar a opinião pública para fins políticos ou ideológicos. A busca por lucro ou poder, em detrimento da precisão e da veracidade, é uma característica central. [**?**]

- **Amplificação Algorítmica**: São beneficiadas pela lógica dos algoritmos de redes sociais e mecanismos de busca, que priorizam conteúdos sensacionalistas e altamente

engajadores. Isso faz com que informações falsas tenham maior alcance e viralizem mais rapidamente do que conteúdos verificáveis. [VRA18]

- **Segmentação de Audiência**: Os disseminadores frequentemente utilizam estratégias de microsegmentação, direcionando desinformação para públicos específicos com base em seus interesses, ideologias e padrões de comportamento online. Isso maximiza a influência das mensagens falsas. [AG17]

- **Narrativa Simplificada e Polarização**: Suas narrativas costumam ser simples, que dividem o mundo entre "nós"e "eles", reforçando sentimentos de pertencimento e hostilidade contra um grupo adversário. Essa estrutura maniqueísta favorece a aceitação da desinformação, pois reduz a complexidade dos eventos. [LBB+18]

- **Descontextualização e Edição Manipulativa**: Se baseiam em fatos reais apresentados fora de contexto ou manipulados por meio de edições, cortes e modificações visuais. Isso dá uma aparência de autenticidade ao conteúdo falso, tornando sua identificação mais difícil. [WD17]

- **Uso de Testemunhos e Pseudociência**: Para aumentar a credibilidade, frequentemente incluem declarações de supostos especialistas ou citações pseudocientíficas. Essas estratégias apelam à autoridade e dificultam o questionamento do conteúdo enganoso. [SSW+17]

2.2 Tipologia de notícias enganosas

Esta seção busca explorar e definir os diferentes tipos de notícias enganosas, com base na categorização apresentada pela European Association for Viewers Interests (EAVI), que identifica distintos formatos de informações enganosas. A compreensão dessas categorias é essencial para uma análise crítica do impacto e das motivações por trás da disseminação de informações falsas. [EAV20]

Segue abaixo uma lista com outros exemplos de modalidades de notícias enganosas, além da desinformação anteriormente conceituada:

2.2.1 Propaganda Enganosa

De forma neutra, propaganda é definida como forma propositada e sistemática de persuasão que visa influenciar com fins ideológicos, políticos ou comerciais, as emoções, atitudes, opiniões e ações de públicos-alvo através da transmissão controlada de informação parcial, que pode ou não ser factual, através de canais diretos e de mídia. [Lor97]

De forma resumida, é a tarefa de criar e direcionar a opinião pública. Quando a propaganda é enganosa, ela carrega uma forma de desinformação.

A propaganda, assim como a publicidade, pode se basear em fatos, mas com tendência a promover uma perspectiva particular. O objetivo da propaganda é convencer, em vez de informar. A propaganda visa moldar percepções e manipular cognições para obter uma resposta que promova a intenção desejada do propagandista. Identificar uma mensagem como propaganda sugere algo negativo e desonesto, com sinônimos como mentiras, distorção e manipulação. A desinformação política é frequentemente chamada de propaganda, com o objetivo de influenciar a percepção pública sobre questões, indivíduos ou visões de mundo. [Kal18]

A propaganda é utilizada por governos, corporações e organizações sem fins lucrativos para influenciar atitudes, valores e conhecimentos. Ela frequentemente apela às emoções e pode ser tanto benéfica quanto prejudicial, dependendo do contexto e da intenção por trás de sua disseminação. Segue abaixo um exemplo de propaganda considerada enganosa pelo consumidor.

Figura 3: Propaganda enganosa

2.2.2 Clickbait

Clickbait é uma técnica de publicidade utilizada para atrair a atenção dos usuários, frequentemente empregando manchetes sensacionalistas ou notícias que direcionam o usuário para anúncios. O objetivo é aumentar os cliques nos anúncios, gerando mais receita. [BM21]

Os sites de notícias falsas usam manchetes *clickbait* para aumentar a popularidade de suas obras, muitas vezes apelando às emoções dos leitores. As suas manchetes criam uma lacuna de informação entre o título e o entendimento do leitor, levando-o a buscar mais informações. Ele também pode ser usado como técnica para facilitar objetivos de *phishing*, induzindo o usuário a fornecer informações confidenciais.

A seguir é apresentada uma imagem com o seguinte título, em português: Homem tenta abraçar um leão selvagem, você não vai acreditar no que vai acontecer depois!. A imagem cria uma expectativa por parte do leitor, induzindo-o a continuar a leitura. Porém, ao clicar, a sequência é frustrante, ora encaminhando o usuário para um labirinto de *links*, ora o texto da manchete ser uma história diferente do anunciado.

Figura 4: *Clickbait*

2.2.3 Sátira

Segundo [SBAB22], sátira é um tipo de notícia que visa o entretenimento, onde o significado do conteúdo é distorcido ou mal interpretado de forma humorística.

As sátiras são escritas de tal forma que pessoas com certos interesses e um senso de humor específico consigam entender a piada. No entanto, esse texto pode facilmente se tornar viral, com outros grupos de pessoas interpretando a história como completamente verdadeira. [BRD20]

Ela pode ser considerada uma forma de gênero literário mais voltada ao estilo propriamente dito. A representação tem por objetivo a crítica a instituições políticas, à moral cidadã, aos costumes e hábitos culturais. Sua principal característica é a forte presença da ironia, e uma carga pesada de sarcasmo. Mesmo que ela não tenha como objetivo maior induzir às risadas, o estilo, no entanto, acaba alcançando tal feito, se aproximando da comédia.

É devido a isso que muitas adoções satíricas têm por objetivo atingir artistas, pessoas de alta relevância em meio social e, claro, políticos. Ela é usada como um instrumento de protesto, crítica e, consequentemente, piada. [**?**] A seguir uma sátira a respeito da violência no Brasil em contraposição à guerra em outro país.

Figura 5: Sátira

2.2.4 Erros de edição

Erros cometidos por organizações de notícias estabelecidas podem prejudicar a marca, ofender ou resultar em litígios. Organizações respeitáveis geralmente publicam retratações ou pedidos de desculpas. Se um erro de edição resultar na disseminação de informações falsas, ele poderia ser considerado uma forma de desinformação.[NKV21]

Um erro de edição refere-se a uma falha ou equívoco ocorrido durante o processo de edição de um conteúdo, seja ele textual ou visual. Isso pode incluir erros de digitação, gramática, formatação incorreta, legendas errôneas em imagens ou vídeos, cortes inadequados, ou a inclusão ou exclusão acidental de informações. Segue um recorte de retratações sobre erros de edição de um jornal impresso.

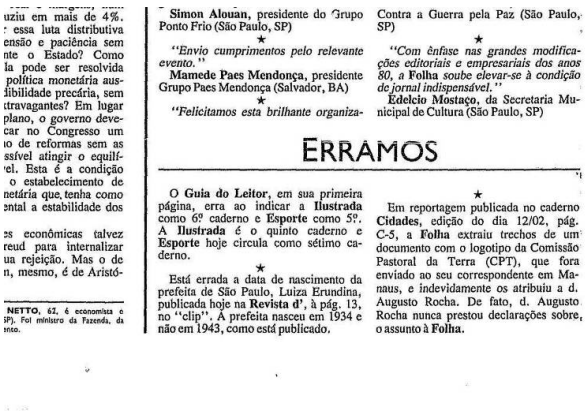

uziu em mais de 4%.
: essa luta distributiva
ensão e paciência sem
nte o Estado? Como
la pode ser resolvida
política monetária aus-
ibilidade precária, sem
ıtravagantes? Em lugar
plano, o governo deve-
car no Congresso um
ıo de reformas sem as
ssível atingir o equilí-
'el. Esta é a condição
o estabelecimento de
netária que, tenha como
ental a estabilidade dos

es econômicas talvez
reud para internalizar
ua rejeição. Mas o de
n, mesmo, é de Aristó-

NETTO, 62, é economista e
SP). Foi ministro da Fazenda, da
nto.

Simon Alouan, presidente do Grupo Ponto Frio (São Paulo, SP)

★

"Envio cumprimentos pelo relevante evento."

Mamede Paes Mendonça, presidente Grupo Paes Mendonça (Salvador, BA)

★

"Felicitamos esta brilhante organiza-

Contra a Guerra pela Paz (São Paulo, SP)

★

"Com ênfase nas grandes modificações editoriais e empresariais dos anos 80, a **Folha** *soube elevar-se à condição de jornal indispensável."*

Edelcio Mostaço, da Secretaria Municipal de Cultura (São Paulo, SP)

ERRAMOS

O **Guia do Leitor**, em sua primeira página, erra ao indicar a **Ilustrada** como 6º caderno e **Esporte** como 5º. A **Ilustrada** é o quinto caderno e **Esporte** hoje circula como sétimo caderno.

★

Está errada a data de nascimento da prefeita de São Paulo, Luiza Erundina, publicada hoje na **Revista d'**, à pág. 13, no "clip". A prefeita nasceu em 1934 e não em 1943, como está publicado.

★

Em reportagem publicada no caderno **Cidades**, edição do dia 12/02, pág. C-5, a **Folha** extraiu trechos de um documento com o logotipo da Comissão Pastoral da Terra (CPT), que fora enviado ao seu correspondente em Manaus, e indevidamente os atribuiu a d. Augusto Rocha. De fato, d. Augusto Rocha nunca prestou declarações sobre o assunto à **Folha**.

Figura 6: Erro de edição

2.2.5 Conteúdo Patrocinado

Conteúdo patrocinado refere-se a materiais de publicidade que são apresentados no formato de reportagens genuínas. Isso ocorre quando profissionais de relações públicas adotam as práticas ou a aparência de jornalistas para inserir mensagens de marketing ou outras mensagens persuasivas na mídia noticiosa. Um exemplo disso é a publicidade nativa, que se assemelha a artigos de notícias, mas é paga por um patrocinador. A obscuridade de suas origens pode levar o público a acreditar que as notícias produzidas são totalmente livres de viés. [Kal18]

Este tipo de conteúdo é uma forma de publicidade que se assemelha a material editorial. Pode criar conflitos de interesse para organizações de notícias genuínas e confundir os consumidores, que podem não identificar o conteúdo como publicidade. A seguir um exemplo de links patrocinados.

Figura 7: Conteúdo Patrocinado

2.2.6 Notícias tendenciosas

Notícias tendenciosas são aquelas que apresentam uma perspectiva ou viés específico, favorecendo um determinado ponto de vista, pessoa, grupo ou ideologia. Essa parcialidade pode se manifestar na forma como as notícias são enquadradas, quais histórias são enfatizadas e quais são omitidas. [Bar17] Nesta perspectiva, uma notícia tendenciosa pode ser considerada um tipo de *fake news* caso a tendência for usada intencionalmente para apresentar informações falsas ou enganosas com o objetivo de manipular a opinião pública ou promover uma agenda específica.

Oswald de Andrade já disse "A gente escreve o que ouve, não o que houve". A notícia não é o real, o fato. Ela é uma representação, um conjunto de versões que formam um recorte do acontecimento. É impossível ser totalmente isento ou imparcial, porque até as suas fontes vão puxar a sardinha pra si. O que acontece na prática, é que esse quebra-cabeça visto em diferentes veículos mostra um determinado ângulo de ver aquele fato, carregando interesses das fontes, dos editores do jornal, dos proprietários, dos anunciantes, que nem sempre somos capazes de ver. [dF16]

Figura 8: Notícia tendenciosa

2.2.7 Teoria da Conspiração

Uma teoria da conspiração é uma explicação unificada para algum evento que difere da história oficial e tipicamente apresentada por um pequeno grupo de conspiradores que agem em segredo. Em alguns casos, a teoria ganha notoriedade pública, tais como: a ideia de que o governo dos EUA destruiu as Torres Gêmeas no 11 de setembro, que alienígenas caíram no Novo México, que Oswald não foi o único atirador no assassinato de JFK, que o Holocausto é uma fabricação de sionistas e que cientistas conspiraram para falsificar dados em apoio à mudança climática. [McB20]

Em outras palavras, uma teoria da conspiração é definida como "uma teoria que explica um evento ou conjunto de circunstâncias como resultado de uma trama secreta de conspiradores geralmente poderosos". Teorias da conspiração são tipicamente disseminadas como parte de uma campanha de desinformação para desacreditar um rival. [LaG18] A seguir, uma imagem retratando a teoria de que o planeta Terra seria plana.

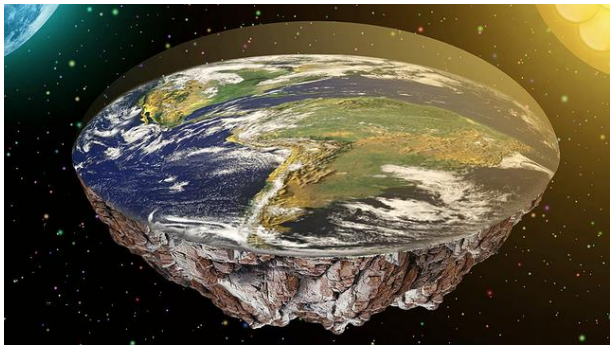

Figura 9: Teoria da conspiração

2.2.8 Pseudociência

A pseudociência refere-se a crenças, práticas ou teorias que se apresentam como científicas, mas não seguem os métodos rigorosos da ciência. Caracteriza-se pela falta de falseabilidade, ou seja, suas afirmações não podem ser testadas ou refutadas, além de carecerem de evidências empíricas robustas e não passarem pela revisão por pares. Muitas vezes, utiliza-se de uma linguagem científica ambígua para criar a aparência de legitimidade, mas sem respaldo de pesquisas válidas. A pseudociência também tende a se apegar a crenças, mesmo diante de evidências contrárias, e não demonstra progresso científico significativo, permanecendo estagnada ao longo do tempo. [Bun84]

Exemplos de pseudociência incluem crenças em fenômenos paranormais, como telepatia e fantasmas. O impacto da pseudociência é significativo, pois pode colocar em risco a saúde das pessoas, ao fazer com que optem por tratamentos não comprovados, além de contribuir para a desinformação e erosão da confiança na ciência legítima. Essas práticas também frequentemente resultam em exploração financeira, especialmente em contextos onde indivíduos são induzidos a pagar por soluções pseudocientíficas para problemas reais.

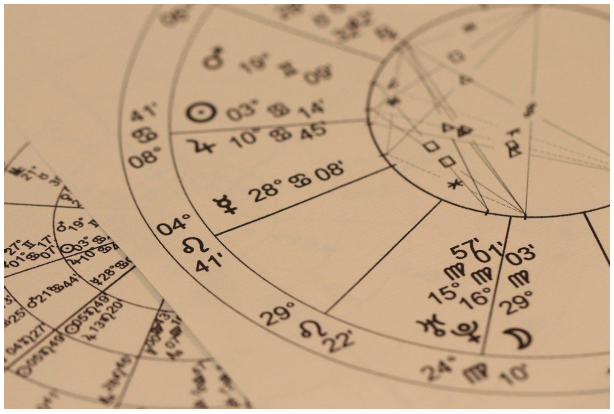

Figura 10: Pseudociência

2.3 Métodos de detecção

A ciência na detecção de *fake news* é uma área de pesquisa interdisciplinar que combina técnicas de ciência da computação, linguística, psicologia, ciências sociais e outras. A seguir, exploramos cada categoria de métodos de detecção de forma detalhada, destacando suas características, aplicações e limitações.

2.3.1 Detecção a partir do conteúdo da notícia

No contexto na análise do conteúdo da notícia, pode-se dividir em dois métodos: análise linguística e sintática e análise semântica.

A análise linguística e sintática foca nos componentes fundamentais da linguagem, como palavras, frases e estruturas gramaticais. Técnicas como *bag-of-words* e *n-grams* são utilizadas para extrair padrões de texto que possam indicar a presença de desinformação. Por exemplo, a frequência de certas palavras ou expressões pode ser um indicativo de sensacionalismo ou manipulação [SSW+17]. Além disso, a análise sintática pode identificar inconsistências na estrutura das frases, que são comuns em notícias falsas. Apesar de sua eficácia em capturar padrões superficiais, essa abordagem pode ser limitada em casos onde a linguagem é intencionalmente elaborada para parecer legítima.

Sob outra abordagem, a análise semântica vai além da estrutura superficial do texto, examinando o significado das palavras e frases. Essa abordagem busca inconsistências entre o título e o conteúdo da notícia, bem como a presença de afirmações contraditórias ou exageradas. Técnicas como *embeddings* de palavras (Word2Vec, BERT) são utilizadas para capturar o contexto semântico do texto, permitindo uma análise mais profunda [ZZ21]. A análise semântica é particularmente útil para identificar notícias que distorcem fatos reais, mas pode ser desafiadora em casos onde a desinformação é sutil ou baseada em informações parcialmente verdadeiras.

2.3.2 Detecção baseada no conhecimento

Este método verifica a veracidade das alegações presentes em uma notícia, comparando-as com fatos conhecidos e fontes confiáveis. Recursos externos, como bases de dados de *fact-checking* e outras bases de conhecimento (Wikidata, DBpedia), são utilizados para validar as informações [DCFG21]. A análise baseada em conhecimento é eficaz para detectar notícias que contêm afirmações falsas ou enganosas, mas depende da disponibilidade e qualidade das fontes de referência. Além disso, pode ser limitada em casos onde as alegações são novas ou não foram previamente verificadas.

2.3.3 Detecção baseada no estilo

A análise baseada em estilo examina a intenção por trás da notícia, buscando identificar características que possam indicar uma tentativa de enganar o público. Isso inclui o uso de linguagem sensacionalista, exageros e apelos emocionais. Técnicas de análise de estilo podem identificar padrões de escrita, como o uso excessivo de adjetivos ou a repetição de certas frases [Gel18]. Essa abordagem é útil para detectar notícias que buscam manipular emocionalmente o leitor, mas pode ser menos eficaz em casos onde o estilo de escrita é neutro ou profissional.

2.3.4 Detecção manual

A detecção manual envolve a verificação de fatos por especialistas, comumente por meio de *crowdsourcing*. Embora preciso e confiável, a detecção manual é limitada pela escalabilidade, já que não consegue acompanhar a rápida disseminação de fake news nas redes sociais [Wan17]. Além disso, a subjetividade humana pode introduzir vieses na análise.

2.3.5 Detecção baseada na análise de dados

No contexto da detecção baseada na análise de dados, pode-se dividir em quatro métodos principais: análise de cluster, *outliers*, similaridade semântica e aprendizado de máquina.

A análise de cluster agrupa notícias com base na similaridade de conteúdo, identificando grupos homogêneos que podem indicar a presença de fake news. Técnicas como k-means e hierarchical clustering são utilizadas para agrupar notícias com base em características como palavras-chave, tópicos e estilo de escrita [SSC+19]. Essa abordagem é útil para identificar padrões de disseminação de fake news, mas pode ser limitada pela qualidade dos dados e pela escolha dos parâmetros de clustering.

A análise de outliers detecta comportamentos anormais em conjuntos de dados, identificando notícias ou autores que se desviam significativamente da norma. Técnicas estatísticas, como o *Z-score* e o *Isolation Forest*, são utilizadas para identificar outliers que

podem indicar a presença de fake news [MFE+19]. Essa abordagem é eficaz para detectar notícias que são claramente diferentes das demais, mas pode ser menos eficaz em casos onde a desinformação é sutil ou bem elaborada.

A análise de similaridade semântica detecta conteúdo quase duplicado, identificando a reutilização de informações em diferentes notícias. Técnicas como *cosine similarity* e *Jaccard index* são utilizadas para comparar o conteúdo de notícias e identificar possíveis plágios ou manipulações [ZZ21]. Essa abordagem é útil para detectar notícias que copiam conteúdo de outras fontes, mas pode ser limitada em casos onde o conteúdo é significativamente alterado.

Modelos de aprendizado de máquina, como *Naive Bayes*, SVM (*Support Vector Machines*) e Redes Neurais Convolucionais (CNNs), são utilizados para classificar notícias como verdadeiras ou falsas com base em características extraídas do conteúdo. Esses modelos são treinados em grandes conjuntos de dados e podem capturar padrões complexos que indicam a presença de fake news [HA21]. Apesar de sua eficácia, esses modelos dependem da qualidade e diversidade dos dados de treinamento e podem ser vulneráveis a ataques adversariais.

2.3.6 Detecção baseada em Propagação

A análise de propagação investiga como as notícias se espalham nas redes sociais, utilizando informações sobre o comportamento dos usuários e a estrutura das redes. Técnicas como análise de cascatas de compartilhamento e modelagem de grafos são utilizadas para identificar padrões de disseminação que são comuns em fake news [VRA18]. Essa abordagem é útil para detectar notícias que se espalham rapidamente e de forma suspeita, mas pode ser limitada pela complexidade das redes sociais e pela falta de dados completos.

2.3.7 Detecção baseada em dados multimodais

A análise multimodal examina notícias que combinam texto, imagens e vídeos, analisando esses diferentes tipos de dados em conjunto para identificar fake news. Técnicas de visão computacional e processamento de linguagem natural são utilizadas para analisar imagens e texto, respectivamente, enquanto modelos de deep learning são utilizados para integrar essas informações [SSC+19]. Essa abordagem é particularmente eficaz para detectar notícias que utilizam manipulações visuais, como deepfakes, mas pode ser complexa e exigir grandes volumes de dados para treinamento.

2.4 Identificação das alegações

A tarefa de extrair alegações representa uma etapa fundamental no processo de checagem de fatos. O seu objetivo é identificar, em uma vasta coleção de textos de entrada, as declarações factuais verificáveis e relevantes. Em sua recente pesquisa[PZ24], os autores

apontam que este componente tem o propósito de isolar as afirmações que necessitam de verificação, eliminando as demais sentenças, economizando tempo, recursos e checagens de fato desnecessárias.

Segundo [ZAZ21], a detecção automatizada de alegações age como um filtro inicial, diminuindo significativamente o volume de conteúdo que checadores de fatos humanos precisam analisar manualmente. Este processo fornece a entrada essencial para todas as outras fases do *pipeline* como um todo. Uma identificação precisa das alegações é crucial para o sucesso das etapas posteriores, como a priorização (determinar quais alegações verificar primeiro com base em critérios como importância ou potencial de dano), a recuperação de evidências relevantes que possam apoiar ou refutar a alegação, a predição da veracidade da alegação com base nas evidências encontradas, e até mesmo a geração de explicações para o veredicto final.

Apesar de sua importância crítica, a detecção de alegações enfrenta desafios significativos. A definição conceitual precisa de uma alegação verificável ainda é um tópico de discussão e pesquisa [KPBZ21]. Existe um grande esforço para treinar modelos de IA, apesar das limitações de disponibilidade de dados. Os *datasets* mais utilizados para a detecção de alegações no contexto da checagem de fatos variam dependendo do tipo de alegação que se pretende detectar e do idioma. No entanto, alguns dados se destacam por sua relevância e uso frequente na literatura [KT20]:

- FEVER (Fact Extraction and VERification): Este é um dataset em grande escala de alegações extraídas de páginas da Wikipédia. É amplamente utilizado para tarefas de detecção de alegações verificáveis e para a verificação de fatos em geral. Os modelos de IA são frequentemente fine-tuned neste dataset para aprender a identificar alegações que podem ser suportadas ou refutadas por evidências.

- LIAR: Este dataset contém 12.8K alegações fact-checked retiradas da API do PolitiFact, juntamente com metadados como o orador, suas afiliações políticas e o meio de publicação. Foi um dos primeiros datasets de tamanho suficiente para o treinamento de modelos de machine learning para a checagem de fatos. Os modelos são treinados para classificar a veracidade das alegações e, implicitamente, para reconhecer o que constitui uma alegação.

- CheckThat! datasets: Esta é uma série de datasets multilíngues lançados desde 2018, focados em priorização de alegações (check-worthiness, harmfulness, attention-worthiness) e detecção de alegações verificáveis. Os idiomas incluem árabe, búlgaro, holandês, inglês, turco e espanhol. Os modelos, principalmente variações do BERT (como XLM-R, mBERT, AraBERT, BERTweet, DistilBERT), são comumente fine-tuned nesses datasets para identificar se um tweet ou outra forma de texto contém uma alegação verificável ou se merece ser verificada. Técnicas de data augmentation, como back translation, são frequentemente empregadas durante o treinamento.

- ClaimBuster: Um grande dataset de alegações factuais check-worthy em inglês, anotado manualmente. É usado para treinar modelos para identificar alegações que justificam a verificação de fatos [ZAZ21].

- ClaimRank dataset: Compilado a partir do resultado da checagem de fatos de debates políticos por nove organizações, disponível em inglês e árabe. Os modelos são criados para prever se uma alegação seria destacada por pelo menos uma ou por uma organização específica, usando diversas características da sentença e seu contexto [KPBZ21]

Em suma, a detecção de alegações é o alicerce sobre o qual todo o processo de checagem de fatos automatizado é construído. Conforme o estudo [PZ24] separa o processo em três estágios:

- Reinvidicação: Em primeiro lugar, separa as informações factuais, afirmações ou alegações em detrimento das opiniões, informações triviais ou sem verificação;

- Verificabilidade: Realiza a separação dos fatos verificáveis dos não verificáveis, tais como intimidade ou experiência pessoal;

- Relevância: No último estágio, é priorizado as afirmações das alegações mais dignas de atenção, que possuem maior impacto prejudicial e de interesse público.

Em seu estudo recente [PZ25], os autores projetaram um modelo de detecção de alegações através de recursos extras com o intuito de resolver problemas de multi-linguagem, além de outras limitações. Os autores utilizam a técnica de Reconhecimento de Entidades nomeadas (NER) para aumentar a precisão de detecção das alegações. Os autores utilizaram como prompt de detecção o texto abaixo:

> Instruction: Evaluate whether the input text contains information or claims that can be verified through fact-checking. If the statement presents assertions, facts, or claims, respond with `Yes`. If the statement is purely opinion-based, trivial, or does not contain any verifiable information or claims, respond with `No`.
>
> Input Sentence: `<input sentence>`
>
> Response: `<Yes/No>`

As principais limitações identificadas são da indisponibilidade do conjunto de dados para treinamento e avaliação dos modelos, definição de escopo no processo de detecção, aspectos multilinguisticos, vieses, dentre outros. Algumas limitações encontradas na técnica são de caráter temporal. Os dados de treinamento com escopo temporal limitado: os modelos são treinados com base em dados de um determinado período. O aspecto temporal pode afetar a relevância de um fato, por exemplo.[PZ25] A veracidade, prioridade e similaridade de uma alegação podem mudar com o tempo.

2.5 Recuperação de evidências

No contexto de checagem de fatos, a recuperação de evidências refere-se ao processo de identificar e extrair informações relevantes de um conjunto de documentos ou da web para verificar a veracidade de uma alegação. Este é um passo fundamental nos sistemas automatizados de checagem de fatos, pois a qualidade das evidências recuperadas influencia diretamente a capacidade de determinar com precisão se uma alegação é verdadeira ou falsa. Em resumo, a recuperação de evidências é um componente crítico da checagem de fatos, envolvendo a busca e seleção de informações que podem ajudar a verificar a precisão de uma alegação. [CGMS23]

Originalmente, a técnica RAG foi criada para combater o problema de alucinações dos modelos generativos. Segundo [KCM+24], para o contexto de checagem de fatos, o método é útil para a coleta de evidências. Em relação à multimodalidade, o autor aborda uma LLM multimodal para adicionar contexto à alegação. Os autores introduziram um componente RAG multimodal durante a recuperação de evidências, usando legendas de imagens correspondentes para fornecer ao LLM metainformações relevantes.

Neste contexto, as perguntas de verificação de fatos geradas pelas técnicas de raciocínio baseadas em LLM ou aumentadas por RAG servem como entrada para o módulo de recuperação de evidências multimodais. Ele ajuda a responder a cada pergunta, recuperando trechos de texto relevantes de sites e analisando ainda mais os detalhes associados à imagem. Para recuperação de evidências baseadas em texto, usaram a ferramenta de pesquisa DuckDuckGo fornecida pela LangChain3, recuperando os 10 principais resultados da API e usando-os para responder as perguntas.

Em outra abordagem, o trabalho[PGH+23] propõe o sistema LLM-AUGMENTER, o qual permite que o LLM gere respostas a partir de dados externos. O sistema ainda revisa iterativamente *prompts* de consulta visando melhorar as respostas do modelo usando feedback gerado por funções de utilidade, em uma espécie de aprendizado por reforço.

Em se tratando de recuperação multimodal, os autores [YSS+23] criaram um conjunto de dados MOCHEG que consiste em milhares de informações rotuladas acerca de sua veracidade vinculadas a outros milhares de textos e imagens como evidências. Em seguida, experimentaram várias arquiteturas neurais na tarefa de recuperação de evidências multimodais e geração de explicações.

Em um trabalho acerca de prompting multimodais, [GDJ+22] o trabalho propõe o TaI (Textos como Imagens) prompting, uma nova técnica de ajuste fino para modelos visão-linguagem como o CLIP, que aprende prompts utilizando descrições textuais em vez de imagens. A importância do TaI (Textos como Imagens) prompting para a recuperação de evidências multimodais reside fundamentalmente na sua habilidade de aprender um forte alinhamento entre representações textuais e visuais utilizando principalmente dados textuais facilmente acessíveis.

3 Evolução Teórico-prática em IA

Em consonância com o contexto da dissertação, que envolve a desenvolvimento de um framework com o uso de inteligência artificial objetivando detectar notícias maliciosas, alguns estudos foram realizados em assuntos correlacionados.

1. Detector de texto sintético para português brasileiro usando arquitetura Transformers

O artigo apresenta um estudo sobre o desenvolvimento de um detector de texto sintético para português brasileiro, utilizando a arquitetura Transformers. O objetivo principal é distinguir textos gerados por modelos de linguagem de textos escritos por humanos, através do ajuste fino de modelos pré-treinados em um conjunto de dados criado especificamente para essa finalidade. O estudo destaca a crescente necessidade de detectar textos sintéticos devido aos riscos associados à disponibilidade de dados gerados por IA, como notícias falsas e plágio. Para suprir a limitação de dados e modelos em português brasileiro, os autores desenvolveram um conjunto de dados misto, compilando textos humanos de diversas fontes e gerando textos sintéticos correspondentes com vários LLMs. Os modelos FacebookAI/xlm-roberta-base e neuralmind/bert-base-portuguese-cased foram treinados e avaliados, alcançando uma precisão de aproximadamente 100%.

O estudo contribui com um dataset misto em português brasileiro aberto e um modelo de detecção RoBERTa ajustado para o português brasileiro. O conjunto de dados foi construído com textos humanos de fontes variadas, incluindo dados do Kaggle, poemas de autores brasileiros, dumps da Wikipédia e notícias. Textos sintéticos foram gerados a partir de diferentes LLMs, utilizando técnicas de engenharia de prompt para garantir a consistência e o uso do português brasileiro. O processo de ajuste fino envolveu a limpeza e normalização dos dados, além do uso de técnicas como taxa de aprendizado variável e *early stopping* para evitar o sobreajuste.

2. PalanqueIA: A Retrieval-Augmented Generation Chatbot for Government Plans in the Brazilian Electoral Landscape

O artigo citado apresenta um chatbot chamado PalanqueIA, que utiliza técnicas de Recuperação Aumentada de Geração e modelos de linguagem para auxiliar candidatos, analistas e formuladores de políticas públicas no desenvolvimento de propostas políticas. O sistema acessa um banco de dados com milhares de propostas políticas de candidatos, permitindo aos usuários consultar propostas existentes, explorar alternativas e obter sugestões para novas políticas. O objetivo principal é democratizar o acesso à informação e fomentar a participação cidadã. A prova de conceito do PalanqueIA demonstrou

a capacidade de aperfeiçoar a consulta inicial do usuário, consultar uma base de dados vetorial com mais de 1,7 milhão de fragmentos de propostas políticas, fornecer respostas relevantes e contextualizadas e gerar propostas de governo criativas a partir de outras pré-existentes.

O PalanqueIA emprega uma arquitetura modular com front-end, back-end e endpoints para acessar LLMs e o banco de dados vetorial. O sistema utiliza técnicas como a otimização da consulta inicial, geração de embeddings com o modelo sentence-transformers/all-MiniLM-L6-v2, e a busca de fragmentos vizinhos para melhorar a precisão das respostas. Além disso, o PalanqueIA implementa dois modos de geração de conteúdo: "Pesquisa", que retorna projetos reais de planos de governo, e "Criação", que gera uma proposta estruturada baseada na consulta inicial e em planos de governo semelhantes. Os LLMs Meta Llama 3.1 405B e FacebookAI/xlm-roberta-large-finetuned-conll03-english são utilizados para a expansão da consulta e a geração de respostas.

3. Aprendizado Federado e Inteligência Artificial no Sistema Judiciário Brasileiro: Uma Abordagem de Colaboração Interinstitucional e Preservação do Sigilo

O artigo aborda a aplicação de Aprendizado Federado (Federated Learning - FL) e Inteligência Artificial no sistema judiciário brasileiro, visando a colaboração interinstitucional e a preservação do sigilo de dados sensíveis. O estudo propõe um sistema distribuído que utiliza o FL como alternativa ao treinamento centralizado de modelos de IA, destacando a capacidade dessa abordagem para reduzir custos, mitigar vieses regionais e fomentar a cooperação entre órgãos judiciais. O objetivo é equilibrar a inovação tecnológica com a conformidade legal, abrindo caminho para soluções colaborativas e sustentáveis no âmbito do sistema judiciário.

As principais técnicas e conceitos explorados no artigo incluem o FL horizontal, que permite o treinamento de modelos sem a necessidade de centralizar os dados, preservando a confidencialidade e a segurança das informações. O algoritmo FedAvg combina a descida de gradiente estocástica realizada localmente com a média dos modelos no servidor central. A metodologia de pesquisa é experimental, comparando os resultados do processo de avaliação em métodos de treinamento centralizado versus FL, utilizando um classificador de documentos judiciais.

4. Relação entre gastos eleitorais e votos nas urnas: análise de correlação e modelagem regressiva

O artigo examina a relação entre gastos eleitorais e o desempenho eleitoral nas eleições de 2022 para o cargo de Governador no Brasil. Através de uma análise de correlação de

Spearman, o estudo encontrou uma forte correlação positiva (0,86) entre a quantidade de votos nominais válidos e as despesas de campanha pagas. O objetivo é quantificar o custo declarado de uma eleição brasileira, calculando o Indicador Gasto médio do voto (IGMV), e avaliar a capacidade de predição de votos a partir da despesa paga e outras variáveis preditoras. O estudo conclui que os gastos de campanha são fundamentais para o entendimento da explicabilidade dos resultados eleitorais.

As principais técnicas utilizadas no artigo incluem a análise de correlação de Spearman para associação entre votos e gastos, a modelagem regressiva Ridge Bayesiana para avaliar as variáveis que explicam o percentual de votos, e o cálculo do IGMV para avaliar o custo médio de uma eleição. Os dados foram extraídos do Portal de Dados Abertos do TSE e transformados utilizando a biblioteca pandas em Python, aplicando a transformação de Box-Cox para estabilizar a variância. O estudo também considera variáveis como idade, gênero, grau de instrução, estado civil, cor/raça, ocupação e reeleição.

5. Democracia Inclusiva: Uma Análise Da Participação De Eleitores Com Deficiência E Eleitores Analfabetos Nas Eleições Brasileiras No Período De 2012 A 2024

O artigo analisa a participação de eleitores com deficiência e analfabetos nas eleições brasileiras de 2012 a 2024, com o objetivo de avaliar a inclusão eleitoral desses grupos. O estudo identifica barreiras físicas, informacionais e institucionais que dificultam o exercício do direito ao voto, e investiga as taxas de abstenção, revelando que são significativamente superiores às do eleitorado em geral. A análise espacial revela concentrações de abstenção em determinadas áreas, destacando a necessidade de políticas públicas mais eficazes para promover a inclusão eleitoral e fortalecer a representatividade democrática. O artigo propõe medidas como acessibilidade nos locais de votação, materiais informativos inclusivos e campanhas de conscientização.

As principais técnicas empregadas no artigo incluem análise estatística descritiva, testes de tendência temporal (Teste Mann-Kendall) e análise espacial (Índice de Moran e clusterização LISA). A pesquisa utiliza dados públicos do TSE e IBGE para examinar a evolução das taxas de comparecimento e abstenção entre eleitores em geral, com deficiência e analfabetos. O Teste de Mann-Kendall é usado para identificar tendências monotônicas nas taxas de abstenção. O Índice de Moran e a clusterização LISA são aplicados para identificar padrões de concentração territorial da abstenção. O estudo também realiza uma análise descritiva das taxas de comparecimento e abstenção, estratificando os grupos-alvo e considerando as regiões brasileiras.

6. Plataforma NATIVA IA

A NATIVA IA é uma plataforma inovadora destinada à criação de protótipos de agentes baseados em inteligência artificial, desenvolvida a partir da aplicação do processo de design thinking, com foco na resolução de problemas específicos da administração pública. Seu principal objetivo é impulsionar a transformação digital nos órgãos públicos, por meio do desenvolvimento de soluções inteligentes e adaptáveis às suas demandas. A plataforma é resultado de um termo de cooperação técnica firmado entre Tribunais e a Universidade Federal do Tocantins, unindo conhecimento acadêmico e necessidades práticas do setor público.

No âmbito desse projeto, foram desenvolvidos diversos protótipos de agentes de IA, entre os quais destacam-se: um sistema de geração automatizada de documentos de licitação e auditoria, um *chatbot* especializado na consulta a normativos internos e às normas do CNJ, além de soluções voltadas à transcrição de áudios para elaboração de atas e redução a termo. Esses protótipos demonstram o potencial da inteligência artificial como ferramenta de apoio à eficiência, à transparência e à automação de processos na esfera pública, alinhando-se às diretrizes de modernização e inovação tecnológica no setor judiciário.

4 Metodologia

Esta seção irá abordar o desenvolvimento em cada uma das técnicas envolvidas no processo de checagem de fatos.

A ideia central do framework é inspirada na checagem manual dos fatos. O método busca simular a atividade de um especialista no processo de verificação de desinformação. Inspirado nesse fluxo, o framework proposto replica essas etapas de forma automatizada, utilizando inteligência artificial para aumentar a eficiência e a escalabilidade da checagem dos fatos.

O modelo foi concebido para integrar diversas técnicas de processamento de dados, aprendizado de máquina e análise de mídia, visando identificar e classificar notícias de forma eficiente e explicável. A abordagem multidisciplinar combina extração de recursos, pré-processamento, detecção de adulteração, análise de sentimento, conversão de mídia em texto, construção de base de conhecimento, análise de similaridade e coerência, e geração de explicações.

O framework proposto é composto por quatro módulos principais, subdividido em tarefas, envolvendo modelos de IA ao longo do processo, cada qual responsável por uma parte específica do processo de checagem dos fatos. A Figura abaixo ilustra a arquitetura geral do framework, destacando os principais módulos e fluxos de dados.

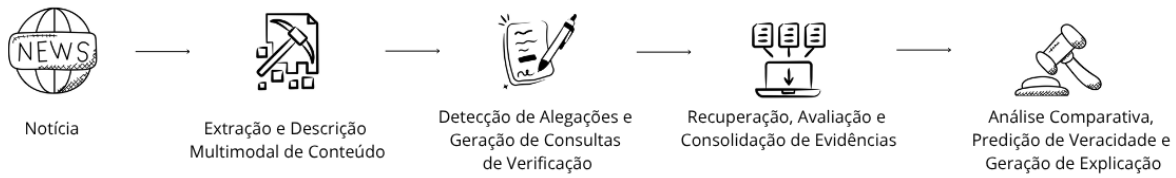

Figura 11: Arquitetura Modular do Framework

O primeiro módulo, Extração e Descrição Multimodal de Conteúdo, processa o objeto de entrada (texto, imagem, vídeo ou áudio), identificando seu formato e extraindo características relevantes. Utiliza PLN para textos, Visão Computacional para mídias visuais (incluindo detecção de manipulações) e processamento de áudio para conteúdos sonoros, gerando uma rica representação contextualizada, incluindo metadados como autoria e fonte.

O módulo de Detecção de Alegações e Geração de Consultas de Verificação emprega LLMs para identificar, a partir da descrição multimodal, as principais alegações factuais, verificáveis e relevantes. Para cada alegação qualificada, o sistema formula consultas de busca otimizadas, projetadas para facilitar a subsequente recuperação de evidências.

O terceiro módulo, Recuperação, Avaliação e Consolidação de Evidências, utiliza as consultas geradas para buscar ativamente evidências em fontes externas. As informa-

ções textuais e visuais recuperadas são avaliadas quanto à sua relevância para a alegação original, utilizando RAG multimodal para contextualizar imagens. Um ciclo de refinamento pode ser ativado se necessário, culminando na compilação de um dossiê coeso de evidências.

Finalmente, o módulo de Análise Comparativa, Predição de Veracidade e Geração de Explicação sintetiza as informações, realizando uma análise comparativa entre a alegação e as evidências. Utilizando Few-Shot Learning, o sistema classifica o conteúdo em categorias de desinformação e, crucialmente, gera uma explicação textual detalhada que justifica o veredito, tornando o processo auditável e compreensível.

4.1 Modulação

O framework é composto por quatro módulos principais sequenciais e independentes. A entrada inicial é um fato a ser checado, podendo estar num formato de texto, áudio, imagem ou vídeo; e a saída é uma classificação dentro de um grupo de classes pré-definidas, além de um texto explicativo da decisão final.

4.1.1 Extração de recursos multi-modal

O primeiro módulo é responsável por extrair informações de diversas modalidades, como texto, imagem, áudio e vídeo. A análise de múltiplos formatos permite capturar padrões complexos presentes nos objetos factuais, proporcionando uma visão mais abrangente da informação. Nesta prova de conceito, o usuário anexará o objeto factual que pretende checar.

Identificar o formato e descrever o objeto factual

No primeiro momento, o framework classificará o formato de mídia do objeto factual. O modelo aceita quatro tipos: texto, imagem, vídeo e áudio. A partir disso, cada formato segue uma rotina de tarefas diferenciada.

Nesta tarefa, o modelo irá descrever a mídia identificada. Esta contextualizaçao envolve várias percepções: pessoas envolvidas, locais, datas, cenário, eventos, e outros contextos relevantes para a checagem do fato. Esta tarefa também envolve reunir informações sobre o autor, fonte, data de publicação e dados de engajamento social, analisando o contexto em que a notícia foi compartilhada.

Para textos, a análise será realizada utilizando técnicas avançadas de PLN. Serão identificadas entidades nomeadas (Named Entity Recognition - NER) para mapear referências a pessoas, organizações e locais. Além disso, serão aplicadas análises mais profundas, incluindo a detecção de sentimentos e padrões linguísticos. A depender da fonte da notícia, serão coletadas outras informações que auxiliam na construção do contexto.

As imagens e vídeos associados às notícias serão analisados através de técnicas de Visão Computacional. Modelos multimodais generativos irão descrever em detalhes as imagens, incluindo textos aparentes, convertendo a imagem em texto, facilitando o processo posterior de detecção das alegações em imagens. Métodos de identificação de DeepFake permitirão identificar manipulações digitais e possíveis indícios de imagens forjadas ou retiradas de contexto. Serão extraídos sentimentos das imagens. Os textos extraídos serão contextualizados conforme a análise textual descrita acima.

Para conteúdos de áudio, técnicas de conversão de fala para texto serão aplicadas, permitindo a transcrição e posterior análise do conteúdo falado. Além disso, será realizada uma avaliação da tonalidade e emoção na voz, bem como a detecção de manipulações digitais. Os textos extraídos serão contextualizados conforme a análise textual descrita acima. Segue figura e prompt detalhando o primeiro módulo.

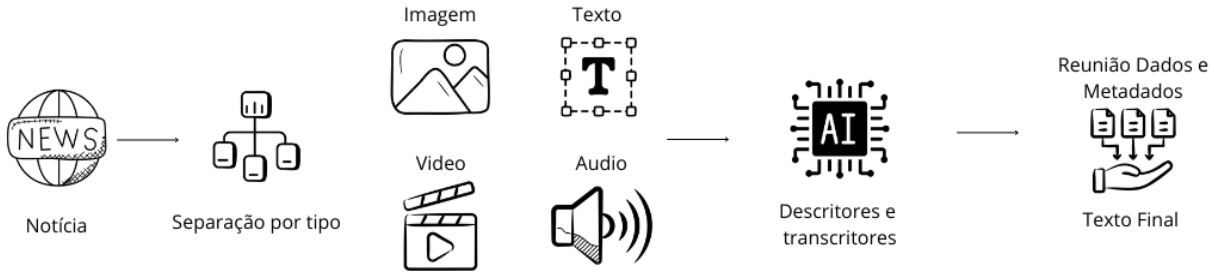

Figura 12: Módulo I: Extração de recursos multi-modal

Prompt 1: Identificação e descrição

INSTRUÇÃO: Você é um assistente de IA especializado em análise de mídia para fins de checagem de fatos. Sua tarefa é processar um "objeto factual"(que pode ser um texto, uma imagem, um vídeo, ou áudio), classificar seu formato de mídia e, em seguida, gerar uma descrição detalhada e contextualizada. O resultado final DEVE ser um objeto JSON estruturado.
ETAPAS DA TAREFA: Classificação do Formato de Mídia: Identifique se o objeto factual fornecido é predominantemente: texto, imagem, vídeo ou áudio. Esta será a base para o campo "tipo"no JSON de saída.
Descrição e Contextualização Detalhada da Mídia: Com base no tipo de mídia identificado, realize a análise apropriada e preencha o campo "descrição"no JSON. A descrição deve SEMPRE tentar incluir, quando aplicável e identificável: Pessoas envolvidas: Nomes ou descrições de indivíduos aparentes ou mencionados. Locais: Lugares geográficos ou cenários identificados. Datas: Datas ou períodos temporais relevantes mencionados ou inferidos. Cenário/Ambiente: Descrição do ambiente físico ou contextual. Eventos Principais: O que está acontecendo ou sendo discutido. Outros contextos relevantes: Qualquer informação adicional crucial para a checagem do fato (ex: objetivo da mídia, a quem se destina, etc.). Metadados (se disponíveis/inferíveis): Autor/Criador: Quem produziu o conteúdo. Fonte Original: Onde o conteúdo foi publicado ou originado. Data de Publicação/Criação: Quando o conteúdo foi tornado público ou criado. Dados de Engajamento Social (se o objeto factual for um link para uma postagem ou incluir essa informação): Menções a curtidas, compartilhamentos, comentários. Contexto do Compartilhamento (se inferível): Onde e como essa mídia foi encontrada ou compartilhada. Rotinas Específicas por Formato: Se tipo for "texto": Realize uma análise de Processamento de Linguagem Natural (PLN). Identifique Entidades Nomeadas (NER): pessoas, organizações, locais. Analise o sentimento predominante do texto. Identifique padrões linguísticos relevantes (ex: tom formal/informal, uso de jargões, linguagem persuasiva). Se a fonte da notícia for identificável e relevante, mencione informações contextuais sobre ela. Se tipo for "imagem"ou "vídeo": Utilize técnicas de Visão Computacional para descrever detalhadamente o conteúdo visual. Para imagens: Descreva objetos, pessoas, ações, cenário, cores, composição. Para vídeos: Descreva as cenas principais, transições, ações e, se houver áudio significativo, trate-o conforme a rotina de áudio. Transcreva qualquer texto visível na imagem/vídeo. Analise o sentimento visual (emoções transmitidas, atmosfera). Avalie a presença de possíveis manipulações digitais (DeepFake, edições grosseiras, sinais de que a imagem/vídeo pode estar fora de contexto). Indique se há suspeitas. O texto extraído deve ser contextualizado conforme a análise textual acima. Se tipo for "áudio": Realize a conversão de fala para texto (transcrição do conteúdo falado). Analise o conteúdo transcrito conforme a rotina de "texto"(NER, sentimento do texto, etc.). Avalie a tonalidade e emoção percebida na(s) voz(es) (ex: calma, raiva, urgência). Avalie a presença de possíveis manipulações digitais no áudio (cortes abruptos, ruídos estranhos, alterações na voz). Indique se há suspeitas.
FORMATO DE SAÍDA ESPERADO (JSON): {"tipo": "texto "imagem "video "audio", "descrição": "Descrição detalhada conforme as diretrizes acima, incluindo todos os elementos relevantes para o tipo de mídia e os pontos de contextualização."}

4.1.2 Detecção de Alegações

Para este estudo, a detecção de alegações será realizada com o uso dos mais recentes grandes modelos generativos de linguagem capazes de extrair informações precisas das alegações (Gemini 2.5 e GPT 4-5). Este módulo é composto por duas tarefas: detectar as alegações verificáveis e relevantes da mídia e geração de consultas otimizadas úteis para o processo de recuperação.

Segue abaixo figura representativa do módulo II.

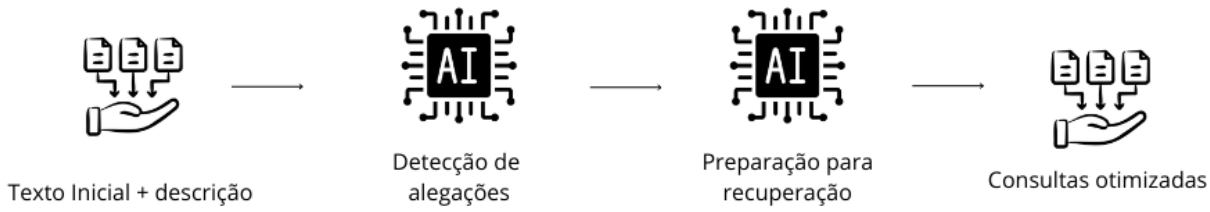

Figura 13: Módulo II: Detecção de Alegações

Prompt 2: Detecção de alegações e otimização de consulta

INSTRUÇÃO: Você é um assistente de IA especializado em análise de conteúdo para fins de checagem de fatos. Sua tarefa principal é processar um objeto JSON que descreve uma mídia. A partir da descrição contida neste JSON, você deve: Identificar sentenças ou unidades de significado que constituam alegações. Avaliar cada alegação potencial através de um processo rigoroso de três estágios: se é factual, se é verificável e se é relevante. Para cada alegação que passar com sucesso por todos os estágios de avaliação, gerar um conjunto de consultas de busca otimizadas, projetadas para auxiliar na sua verificação. O objetivo é filtrar e preparar as alegações mais importantes da mídia para a subsequente etapa de checagem de fatos. O resultado final DEVE ser um objeto JSON estruturado conforme especificado.
ETAPAS DA TAREFA: Extraia e utilize o conteúdo do campo "descrição"do JSON de entrada como o texto base para todas as análises subsequentes nesta tarefa.
Divida o texto da "descrição"em sentenças individuais ou unidades de significado coesas que possam conter alegações e processe cada sentença/unidade candidata através dos seguintes estágios sequenciais. Uma candidata só avança para o próximo estágio se for aprovada no estágio atual.
Estágio 1: Determinação de Alegação Factual Objetivo: Identificar se a sentença expressa uma afirmação sobre o mundo real que pode ser, em princípio, provada verdadeira ou falsa. Critérios de Inclusão: Afirmações que contêm fatos, eventos, estatísticas, ou declarações sobre propriedades de entidades. A presença de Entidades Nomeadas (Pessoas, Organizações, Locais, Datas, Números específicos), já potencialmente detalhadas na "descrição", é um forte indicador positivo. Critérios de Exclusão: Opiniões puras, perguntas, comandos, exclamações, expressões de gosto pessoal, declarações excessivamente vagas, triviais ou subjetivas que não podem ser objetivamente testadas.
Resultado Esperado do Estágio 1: (Classificada como "Alegação Factual"/ Classificada como "Não Alegação Factual")
Estágio 2: Avaliação de Verificabilidade (Aplicar somente se classificada como "Alegação Factual"no Estágio 1) Objetivo: Determinar se existem meios práticos e objetivos para encontrar evidências que possam confirmar ou refutar a alegação factual. Critérios de Inclusão: Alegações que podem ser checadas contra fontes confiáveis, registros públicos, dados científicos, testemunhos verificáveis, ou outras formas de evidência. Critérios de Exclusão: Alegações sobre experiências puramente pessoais e não corroboráveis, intenções não declaradas de indivíduos, previsões sobre eventos futuros altamente especulativos sem base factual presente, informações intrinsecamente privadas ou inacessíveis ao público. Resultado Esperado do Estágio 2: (Classificada como "Verificável"/ Classificada como "Não Verificável")
Estágio 3: Avaliação de Relevância (Aplicar somente se classificada como "Verificável"no Estágio 2) Objetivo: Determinar se a alegação factual e verificável possui mérito e importância suficientes para justificar um esforço de checagem de fatos. Fatores a Considerar: Interesse Público: A alegação afeta um número significativo de pessoas? Relaciona-se a tópicos de grande importância social, política, econômica, de saúde ou segurança? Potencial de Dano: A alegação, se falsa, tem potencial para causar danos, desinformar, enganar o público, ou incitar preconceito/ódio? Novidade ou Surpresa: A alegação é inesperada, contradiz o conhecimento comum, desafia narrativas estabelecidas ou alegações anteriores importantes? Influência da Fonte/Orador: A proeminência ou autoridade (real ou percebida) de quem faz a alegação (ou da fonte original da mídia) aumenta sua relevância? Viralidade/Alcance (se inferível da "descrição"): A alegação demonstra sinais de ampla disseminação ou alto engajamento que justifiquem sua verificação?
Resultado Esperado do Estágio 3: ("Relevante"ou "Não relevante").
Geração de Consultas de Busca Otimizadas para Cada Alegação Qualificada: Para CADA alegação extraída na etapa 3, formule um conjunto de 3 consultas de busca distintas e otimizadas. Objetivo das Consultas: Facilitar a localização de evidências relacionadas à alegação. Específicas e Direcionadas: Devem usar palavras-chave centrais e termos precisos extraídos diretamente da alegação. Contextualizadas: Devem incorporar, quando relevante, Entidades Nomeadas e termos temporais que são cruciais para a verificação específica daquela alegação. Variadas em Formulação: Devem explorar diferentes abordagens de busca. Faça o Uso Estratégico de Operadores de Busca.
FORMATO DE SAÍDA ESPERADO (JSON):
["alegação id": 1 (sequencial), "texto da alegação": "alegação factual, verificável e relevante", "justificativa avaliacao": "Uma breve explicação concisa", "consultas sugeridas para verificação": ["consulta otimizada 1,2,3]]

4.1.3 Recuperação de Evidências

O módulo de recuperação de evidências inicia utilizando as consultas textuais e visuais geradas anteriormente. Para as evidências textuais, essas consultas são enviadas a fer-

ramentas de busca externas, como API do DuckDuckGo, para coletar trechos de texto e links relevantes da web. Um LLM, guiado pelo prompt específico, avalia então a relevância de cada resultado textual em relação à alegação original e às perguntas de verificação, filtrando informações não pertinentes. Paralelamente, as imagens são utilizadas para buscar imagens em fontes; o LLM, então, avalia a relevância dessas imagens, considerando não apenas o conteúdo visual, mas também metadados associados como legendas e datas, aplicando um princípio similar ao RAG multimodal para contextualizar a imagem em relação à alegação. Sendo assim, o módulo é subdividido em três tarefas: busca, avaliação e refinamento.

Após a coleta e filtragem inicial de evidências textuais e visuais relevantes, o fluxo entra na fase de consolidação. O modelo de linguagem sintetiza as informações mais pertinentes analisando se as evidências coletadas convergem para uma mesma conclusão ou se apresentam informações conflitantes. O objetivo é criar um "pacote"coeso com as evidências mais fortes e diretas para subsidiar a próxima etapa de verificação da veracidade. Finalmente, caso as evidências iniciais sejam consideradas insuficientes ou de baixa qualidade, um ciclo de refinamento é ativado: o sistema pode gerar feedback para aprimorar as consultas de busca originais e reexecutar as etapas de recuperação e avaliação, buscando iterativamente melhorar a qualidade e a abrangência do conjunto de evidências coletadas.

Segue abaixo figura representativa do módulo III.

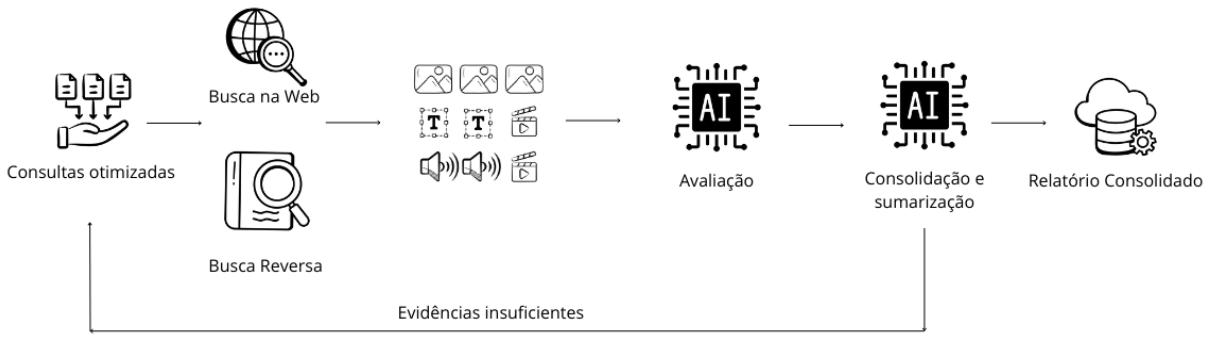

Figura 14: Módulo III: Recuperação, avaliação e refinamento

Busca em Bases Externas para geração de contexto

Esta busca consiste na execução de uma coleta de informações para a tarefa de recuperação de evidências. Utilizando as consultas textuais otimizadas e os conceitos visuais definidos anteriormente, esta tarefa interage ativamente com fontes de dados externas e publicamente acessíveis. Para a busca textual, ferramentas como a API do DuckDuckGo e outras serão empregadas para varrer a web em busca de artigos, notícias e documentos relevantes. Para a busca visual, motores de busca de imagens e APIs de modelos multimodais serão consultados usando as descrições ou palavras-chave visuais. O resultado direto desta tarefa é a compilação de uma coleção inicial e não filtrada de potenciais evidências

(snippets de texto, URLs, links de imagens, etc.), que servirá como insumo bruto para a subsequente fase de avaliação de relevância

Avaliação das Evidências

Após a coleta bruta de informações, a avaliação das evidências atua como um filtro crítico. Utilizando-se de IA, esta tarefa examina cada peça de informação recuperada (trechos de texto, imagens, metadados) e determina sua relevância direta para a alegação original e as perguntas de verificação formuladas anteriormente. O LLM classifica a relevância (ex: alta, média, baixa) com base no quão bem a evidência aborda os componentes chave da alegação, como pessoas, locais, datas e as ações ou descrições específicas. Para evidências visuais, a análise inclui a correspondência do conteúdo da imagem com a descrição na alegação e a consistência de metadados associados (legendas, datas via RAG multimodal). O resultado é um conjunto depurado de evidências consideradas pertinentes, descartando ruídos e informações tangenciais, preparando o terreno para a consolidação e análise final.

Prompt 3: Avaliação de evidências textuais

INSTRUÇÃO: Você é um assistente de IA especializado em análise de conteúdo para checagem de fatos. Sua tarefa é avaliar trechos de texto recuperados de uma busca textual, realizada com base na alegação original e em perguntas de verificação. O objetivo é determinar a relevância de cada trecho e identificar potenciais evidências diretas para confirmar ou refutar a alegação.
ENTRADA:

- Alegação Original
- Perguntas de Verificação
- Resultados da Busca Textual

ETAPAS DA TAREFA: Para cada 'Resultado da Busca Textual' fornecido na entrada, execute as seguinte atividade:
Avaliação de Relevância:

- Determine o quão diretamente relevante o trecho é para responder às 'Perguntas de Verificação' e para confirmar ou refutar a 'Alegação Original'.
- Utilize UMA das 'Categorias de Relevância' definidas abaixo.

Categorias de Relevância:

Alta Relevância: Contém informação direta sobre os elementos chave da alegação (ex: evento, local, data, pessoas envolvidas, ações descritas, consequências afirmadas) e/ou responde diretamente a uma ou mais 'Perguntas de Verificação'.

Média Relevância: Menciona alguns elementos chave da alegação ou fornece contexto útil, mas não aborda diretamente o ponto central da alegação ou não responde completamente às 'Perguntas de Verificação'. Pode ser um ponto de partida para investigações adicionais.

Baixa Relevância: O tópico é genericamente relacionado à alegação ou às perguntas, mas o trecho em si não oferece informação útil ou específica para a verificação.

Irrelevante: O conteúdo do trecho não tem relação aparente com a 'Alegação Original' ou com as 'Perguntas de Verificação'.

FORMATO DE SAÍDA ESPERADO: A saída deve ser uma lista, onde cada item corresponde a um snippet avaliado, seguindo o formato abaixo (repita para cada snippet):

```
Snippet: "[Texto do Snippet 1]"
Fonte: [Fonte/URL do Snippet 1, se houver]
Relevância: [Alta/Média/Baixa/Irrelevante]
Justificativa: [Explicação breve da relevância, conectando com a alegação/perguntas]
Evidência Direta (se houver): [Afirmação relevante do snippet OU "Nenhuma evidência direta identificada"]
```

(Repetir para todos os snippets fornecidos na entrada)

Refinamento

Esta tarefa é acionada condicionalmente, caso a consolidação indique que o conjunto de evidências coletado é insuficiente, de baixa qualidade, ou excessivamente contraditório para permitir uma verificação confiável. Com as consultas refinadas, o processo de otimização da consulta é revisto, alterando os parâmetros, com o objetivo de obter um novo conjunto de evidências mais robusto, completo e de maior qualidade para subsidiar

a verificação de fatos.

4.1.4 Predição da Veracidade e Explicação

Este módulo representa a etapa culminante do framework de checagem de fatos multimodal, sendo responsável por sintetizar as informações processadas nas fases anteriores – descrição factual, detecção de alegações e recuperação de evidências. O objetivo central é emitir um julgamento final sobre a veracidade da alegação original, classificando entre as dez possíveis classes mapeadas anteriormente. Utilizando todas as informações acumuladas, o módulo classifica o conteúdo dentro de um esquema granular pré-definido, refletindo nuances como intenção (ex: sátira, opinião), contexto ou falta de sustentação (ex: enganoso, insustentável).

Crucialmente, além da classificação, o módulo gera uma explicação detalhada que justifica o veredito, fundamentando-o nas evidências textuais e visuais coletadas. Para otimizar a precisão e o raciocínio desejado, a predição e a explicação serão guiadas por prompting Few-Shot, fornecendo ao modelo exemplos concretos de como mapear a análise das evidências às categorias de classificação e como articular a justificativa correspondente. O módulo é composto por duas tarefas: análise comparativa e síntese final e predição do veredito e explicação detalhada.

Os exemplos serão anexados de forma multi-modal no processo de requisição à LLM. Segue abaixo figura descrevendo o módulo.

Figura 15: Módulo IV: síntese final, classificação e explicação

Análise Comparativa

Esta tarefa funciona como uma análise crítica e preparatória para o julgamento final, tendo como entrada principal o relatório consolidado de evidências (textuais e visuais) e a alegação original. Seu objetivo é realizar um exame detalhado e granular, mapeando explicitamente cada peça de evidência principal às partes específicas da alegação que ela aborda. Após essa análise individualizada, a tarefa sintetiza essas descobertas em uma avaliação do "peso da evidência", descrevendo a força geral, a direção predominante (se

apoia ou contradiz), o nível de consenso ou conflito entre as evidências, e se o conjunto probatório é considerado suficiente para um veredito seguro. O resultado é um relatório estruturado que fundamenta objetivamente a decisão a ser tomada na tarefa subsequente de predição e explicação.

Prompt 4: Análise Comparativa

INSTRUÇÃO: Você é um assistente de IA especializado em análise de evidências para checagem de fatos. Sua tarefa é preparar a base para o julgamento final da veracidade de uma alegação. Você deve analisar profundamente o relatório de evidências consolidado fornecido, entender como cada peça de evidência se relaciona com a alegação original e determinar o peso geral dessas evidências.
ENTRADA:

- Conteúdos preliminares dos módulos anteriores.
- Alegação Original: [Inserir a alegação original aqui]
- Relatório Consolidado de Evidências

ETAPAS DA TAREFA: Com base na entrada fornecida:
1. Mapeamento Evidência-Alegação: Para cada 'Evidência Principal' listada:

- Identifique qual parte específica da 'Alegação Original' ela aborda (ex: a pessoa envolvida, a data, o local, a ação descrita, a consequência afirmada).
- Declare explicitamente se a evidência **Apoia Fortemente**, **Apoia Parcialmente**, **Contradiz Fortemente**, **Contradiz Parcialmente**, fornece **Contexto Neutro**, ou sugere uma **Natureza Não Factual** em relação àquela parte da alegação. Justifique brevemente sua avaliação para cada evidência.

2. Síntese do Peso da Evidência: Considerando todas as evidências principais e a análise de convergência/divergência:

- Descreva a força e a direção geral das evidências. Há um consenso claro (apoio ou contradição)? As evidências são mistas ou conflitantes? A evidência é considerada suficiente para um julgamento seguro? Existem indicações fortes sobre a natureza não factual do conteúdo?

FORMATO DE SAÍDA ESPERADO:
Alegação: "[Alegação Original]"
Mapeamento das Evidências Principais:

```
Evidência T1: "[Snippet]" (Fonte: [...])
Relação com Alegação: [Apoia/Contradiz/Contextualiza] a parte sobre [componente da alegação].
Justificativa: [...]

[...] (Para todas as evidências principais)
```

Síntese do Peso da Evidência:

```
[Descrever a força geral (forte/fraca/mista/insuficiente),
 a direção (apoio/contradição/não factual),
 e o nível de consenso/conflito entre as evidências.]
```

Síntese Final: Predição do Veredito e Geração da Explicação

Esta tarefa representa a etapa culminante da análise, onde a comparação detalhada entre a alegação original e as evidências consolidadas serve como entrada principal. O

objetivo é duplo: primeiro, classificar o conteúdo selecionando o rótulo mais apropriado entre as classes estudadas possíveis; segundo, gerar uma explicação textual abrangente que justifique essa classificação. Crucialmente, a tarefa utiliza a técnica de Few-Shot Learning, empregando os exemplos fornecidos no prompt para guiar o raciocínio do LLM. Isso assegura que a explicação final não apenas declare o veredito, mas também articule claramente como as evidências específicas recuperadas (textuais e visuais) apoiam, contradizem ou contextualizam a alegação, levando à conclusão alcançada.

Prompt 5: Classificação final e Geração de Explicação

INSTRUÇÃO: Você é um assistente de IA especializado em checagem de fatos. Sua tarefa final é, com base na análise detalhada das evidências versus a alegação (realizada na etapa anterior), atribuir um veredito de veracidade à alegação original utilizando o esquema de classificação fornecido. Além disso, você deve gerar uma explicação clara, concisa e bem fundamentada para esse veredito, utilizando o raciocínio demonstrado nos exemplos de few-shot learning.
ENTRADA:

- A alegação original.
- A síntese da análise das evidências

ETAPAS DA TAREFA:

1. **Análise da Entrada:** Revise cuidadosamente a alegação original e a síntese da análise das evidências fornecida.
2. **Seleção do Veredito:** Com base nessa análise e no "Esquema de Classificação de Veredito"abaixo, selecione UMA ÚNICA classificação que melhor descreva a natureza da alegação original.
3. **Geração da Explicação:**
    - Elabore uma explicação detalhada para o veredito escolhido.
    - Sua explicação deve justificar claramente por que o veredito selecionado é o mais apropriado.
    - Fundamente sua justificativa na análise das evidências (como elas apoiam, contradizem ou contextualizam a alegação) e na síntese do peso geral dessas evidências.
    - Siga o estilo e a profundidade de raciocínio demonstrados nos "Exemplos"fornecidos abaixo.

Esquema de Classificação de Veredito: VERDADEIRA, DESINFORMAÇÃO, PROPAGANDA, CLICKBAIT, SÁTIRA, ERRO DE EDIÇÃO, CONTEÚDO PATROCINADO, NOTÍCIAS TENDENCIOSAS (ou CONTEÚDO TENDENCIOSO), TEORIA DA CONSPIRAÇÃO, PSEUDOCIÊNCIA
Exemplos (Few-Shot Learning):
FORMATO DE SAÍDA ESPERADO:

```
Veredito Final: [Selecionar UMA classificação do Esquema]
Explicação:
[Escrever aqui a explicação detalhada, justificando o veredito com base
na análise das evidências (resultado do Prompt 9) e seguindo o padrão
dos exemplos (Few-Shot Learning). A explicação deve conectar claramente
os achados da análise de evidências com a definição da categoria de
veredito escolhida.]
```

4.2 Avaliação

Neste capítulo, detalhamos a metodologia adotada para avaliar o framework proposto. A avaliação é uma etapa crucial para validar a eficácia e a robustez, garantindo que ele seja capaz de lidar com diferentes tipos de desinformação em diversos contextos.

4.2.1 Seleção do conjunto de dados

Segundo [DCFG21], a avaliação de sistemas de detecção depende fundamentalmente da utilização de datasets rotulados, nos quais as notícias são classificadas conforme orientaçao do próprio conjunto de dados. A maioria das técnicas aborda este problema como uma classificação binária supervisionada. A seleção de um dataset adequado é crucial e deve considerar características como o domínio das notícias, o tipo de desinformação, o idioma e a plataforma de mídia. O desempenho dos sistemas é então medido através de métricas de classificação, como precisão, revocação, F1-score e acurácia, que comparam as previsões do sistema com os rótulos reais do dataset.

Os datasets para avaliação de fake news apresentam uma variedade de características, incluindo diferentes escalas de avaliação para a veracidade das notícias, sendo a escala binária (verdadeiro/falso) a mais comum. Essa predominância da classificação binária deve-se à maior precisão obtida em comparação com escalas mais complexas. A qualidade e a diversidade dos datasets utilizados impactam diretamente a confiabilidade e a generalização dos modelos de detecção. Portanto, a análise das características dos datasets é essencial para orientar pesquisadores na seleção ou criação de conjuntos de dados apropriados para uma avaliação rigorosa.

Na primeira etapa deste processo, será utilizado um conjunto de dados diversificado e representativo, composto por amostras de vários datasets, contendo notícias verdadeiras e falsas provenientes de diferentes fontes, de variados formatos de mídias, como redes sociais, sites de notícias e plataformas de fact-checking. Sendo assim, utilizamos uma abordagem estratificada em variados datasets disponíveis em seus mais distintos tipos, tamanhos, idiomas e formatos.

A amostragem estratificada será construída respeitando as características cruciais dos datasets, tais como: tipo de desinformação, incluindo categorias como artigos de notícias falsas, rumores, avaliações falsas, hoaxes, sátiras e clickbait; tamanho do dataset, considerando a vasta gama existente, desde coleções com menos de mil itens até aquelas com milhões; tipo de conteúdo da notícia, abrangendo datasets que contêm apenas texto, texto e imagens, ou texto, imagens e vídeos; e idiomas predominantes, priorizando a inclusão de datasets monolíngues em inglês, bem como aqueles em outros idiomas como espanhol, chinês e datasets multilingues, de forma a contemplar a diversidade linguística presente; dentre outras categorias. Esta abordagem permitirá uma análise abrangente das diferentes facetas dos datasets de detecção de notícias falsas.

4.2.2 Pré-processamento dos dados

Os dados serão pré-processados para garantir que estejam no formato adequado para a análise. Isso inclui a tokenização de textos, a normalização de imagens e vídeos, e a extração de metadados relevantes. Além disso, serão aplicadas técnicas de limpeza de dados, como a remoção de ruídos e a correção de inconsistências.

4.2.3 Execução da avaliação

A execução será conduzida por meio da avaliação das métricas de desempenho, por meio das quais será analisada a performance do classificador em relação aos valores etiquetados nos datasets.

Métricas de desempenho

A avaliação de modelos de classificação envolve a utilização de métricas derivadas da matriz de confusão, que categoriza as previsões do modelo em verdadeiros positivos (VP), falsos positivos (FP), verdadeiros negativos (VN) e falsos negativos (FN). A escolha das métricas mais adequadas depende do contexto do modelo, da tarefa específica, do custo associado a diferentes tipos de erros e do equilíbrio do conjunto de dados. [RPPD23]

1. Acurácia (Accuracy) A acurácia é uma métrica que mede a proporção de classificações corretas, tanto positivas quanto negativas, em relação ao total de previsões. Matematicamente, a precisão é definida como:

$$\text{Acurácia} = \frac{VP}{VP + FP}$$

No contexto de detecção de fake news, a acurácia representa a fração de notícias que foram corretamente classificadas como falsas ou verdadeiras. Um modelo ideal, que não comete erros, teria uma acurácia de 1,0 (ou 100%). Como a acurácia leva em consideração todos os quatro resultados da matriz de confusão, ela pode ser uma medida geral da qualidade do modelo, especialmente em conjuntos de dados equilibrados, onde as classes estão igualmente representadas. Por essa razão, a acurácia é frequentemente utilizada como métrica padrão para avaliar modelos genéricos.

No entanto, em cenários onde o conjunto de dados é desequilibrado ou quando um tipo de erro (falsos positivos ou falsos negativos) é mais crítico que o outro, a acurácia pode ser enganosa. Por exemplo, em um conjunto de dados altamente desequilibrado, onde notícias falsas representam apenas 10% dos exemplos, um modelo que sempre prediz "verdadeira"teria uma acurácia de 90%, mesmo sendo ineficaz.

2. Recall (Taxa de Verdadeiro Positivo) O recall, também conhecido como taxa de verdadeiro positivo (TPR), mede a proporção de exemplos positivos que foram corretamente identificados pelo modelo. Matematicamente, o recall é definido como:

$$\text{Recall} = \frac{VP}{VP + FN}$$

No exemplo de detecção de fake news, o recall indica a fração de notícias falsas que foram corretamente detectadas. Um modelo perfeito teria um recall de 1,0, ou seja, identificaria 100% das notícias falsas. O recall é particularmente útil em situações onde a detecção de falsos positivos é crucial, como na moderação de conteúdo em redes sociais.

Em conjuntos de dados desequilibrados, onde o número de notícias falsas é muito baixo, o recall pode perder sua utilidade como métrica, pois mesmo um pequeno número de falsos negativos pode impactar significativamente seu valor.

3. Taxa de Falso Positivo (FPR) A taxa de falso positivo (FPR) mede a proporção de exemplos negativos que foram incorretamente classificados como positivos. Matematicamente, a FPR é definida como:

$$\text{FPR} = \frac{FP}{FP + VN}$$

No contexto de detecção de fake news, a FPR representa a fração de notícias verdadeiras que foram erroneamente classificadas como falsas. Um modelo ideal teria uma FPR de 0,0, indicando que nenhuma notícia verdadeira foi marcada incorretamente como falsa. Em conjuntos de dados desequilibrados, onde o número de notícias verdadeiras é muito alto, a FPR pode não ser uma métrica significativa.

4. Precisão (precision)

A precisão mede a proporção de classificações positivas feitas pelo modelo que são realmente positivas. Matematicamente, a precisão é definida como:

$$\text{Precisão} = \frac{VP}{VP + FP}$$

No exemplo de detecção de fake news, a precisão indica a fração de notícias classificadas como falsas que realmente eram falsas. Um modelo perfeito teria uma precisão de 1,0, ou seja, não cometeria falsos positivos. A precisão é particularmente útil em cenários onde falsos positivos são custosos, como em verificadores de fatos utilizados por agências de notícias.

Em conjuntos de dados desequilibrados, onde o número de notícias falsas é muito baixo, a precisão pode não ser uma métrica confiável, pois mesmo um pequeno número de falsos positivos pode reduzir significativamente seu valor.

5. F1-Score

O F1-score é a média harmônica entre precisão e recall, oferecendo um equilíbrio entre essas duas métricas. Matematicamente, é definido como:

$$\text{F1-Score} = 2 \times \frac{\text{Precisão} \times \text{Recall}}{\text{Precisão} + \text{Recall}}$$

O F1-score é particularmente útil quando há um desequilíbrio entre as classes e nem a precisão nem o recall sozinhos são suficientes para avaliar corretamente o modelo. Em detecção de fake news, um alto F1-score indica que o modelo consegue identificar notícias falsas com um bom equilíbrio entre evitar falsos positivos e falsos negativos.

6. Curva ROC e AUC

A curva ROC é um gráfico que mostra a relação entre a taxa de verdadeiros positivos (VP) e a taxa de falsos positivos (FP) em vários limiares de decisão do modelo.

Diferente da acurácia, a curva ROC e o AUC não são afetadas por desequilíbrio de classes. Isso é muito útil em contextos como fake news, onde talvez haja muito mais notícias verdadeiras do que falsas (ou vice-versa).

4.2.4 Resultados Esperados

A seguir, descrevemos os principais resultados esperados em termos de desempenho, interpretabilidade e aplicabilidade:

- Desempenho do Modelo: A combinação de análise multimodal (texto, imagens e vídeos) deve permitir uma detecção robusta de fake news, mesmo em cenários complexos e dinâmicos.
- Interpretabilidade das Decisões: Um dos diferenciais do framework é a capacidade de fornecer justificativas interpretáveis para as decisões tomadas pelo modelo.
- Integração com Fontes de Conhecimento Externas: A utilização de técnicas de RAG para consultar fontes confiáveis, como enciclopédias digitais, deve aumentar a precisão do framework na verificação de alegações factuais.

4.2.5 Custos Estimados

Ao final do processo de avaliação, os custos envolvidos por cada operação de checagem.

5 Referências

[AFP25] AFP. Manuel du fact-checking à l'afp, 2025. Accessed: 2025-03-22.

[AG17] Hunt Allcott and Matthew Gentzkow. Social media and fake news in the 2016 election. *Journal of Economic Perspectives*, 31(2):211–236, May 2017.

[AG21] Wazib Ansar and Saptarsi Goswami. Combating the menace: A survey on characterization and detection of fake news from a data science perspective. *International Journal of Information Management Data Insights*, 1(2):100052, 2021.

[ALL23] Jawaher Alghamdi, Suhuai Luo, and Yuqing Lin. A comprehensive survey on machine learning approaches for fake news detection. *Multimedia Tools and Applications*, 83(17):51009–51067, November 9 2023.

[Bar17] Bruce R. Bartlett. *The Truth Matters: A Citizen's Guide to Separating Facts from Lies and Stopping Fake News in Its Tracks.* Ten Speed Press, California, 2017.

[Bir19] Jen Birks. *Fact-Checking Journalism and Political Argumentation.* Palgrave Macmillan, Cham, Switzerland, 2019.

[BM21] Dylan De Beer and Machdel Matthee. Approaches to identify fake news: A systematic literature review. In Tatiana Antipova, editor, *Integrated Science in Digital Age 2020*, volume 136, pages 13–22. Springer International Publishing, 2021.

[Bor23] Brooke Borel. *The Chicago Guide to Fact-Checking.* University of Chicago Press, Chicago and London, second edition, 2023.

[BRD20] Costin Busioc, Stefan Ruseti, and Mihai Dascalu. A literature review of nlp approaches to fake news detection and their applicability to romanian-language news analysis. *Transilvania*, pages 65–71, October 1 2020.

[Bun84] Mario Bunge. What is pseudoscience? *The Skeptical Inquirer*, 9(1):36–46, 1984.

[CGMS23] Tanmoy Chakraborty, Valerio La Gatta, Vincenzo Moscato, and Giancarlo Sperlì. Information retrieval algorithms and neural ranking models to detect previously fact-checked information. *Neurocomputing*, 557:126680, 2023.

[Che25a] Africa Check. How we fact-check, 2025. Accessed: 2025-03-22.

[Che25b] First Check. Methodology, 2025. Accessed: 2025-03-22.

[Che25c] Greece Fact Check. , 2025. Accessed: 2025-03-22.

[Che25d] Chequeado. Método, 2025. Accessed: 2025-03-22.

[Com25] Projeto Comprova. Metodologia, financiamento e correção de erros, 2025. Accessed: 2025-03-22.

[DCFG21] Arianna D'Ulizia, Maria Chiara Caschera, Fernando Ferri, and Patrizia Grifoni. Fake news detection: A survey of evaluation datasets. *PeerJ Computer Science*, 7:e518, June 2021.

[dDPA25] dpa Deutsche Presse-Agentur. Faktencheck: Unsere redaktion überprüft behauptungen, 2025. Accessed: 2025-03-22.

[dF16] Mural da Flor. Uma notícia em dois jornais, 2016. Acesso em: 13 mar. 2025.

[dFN25] Cazadores de Fake News. Metodología, 2025. Accessed: 2025-03-22.

[EAV20] EAVI - European Association for Viewers Interests. Beyond fake news: 10 types of misleading info, 2020.

[Ell97] Charles John Ellicott. *Ellicott's Commentary for English Readers*. Cassell and Company, London, 1897. Acessado em 31 mar. 2025.

[Fac25a] Facta. Come lavoriamo, 2025. Accessed: 2025-03-22.

[Fac25b] Factcheck.ge. , 2025. Accessed: 2025-03-22.

[Fat25] Aos Fatos. Política editorial, 2025. Accessed: 2025-03-22.

[GDJ+22] Zixian Guo, Bowen Dong, Zhilong Ji, Jinfeng Bai, Yiwen Guo, and Wangmeng Zuo. Texts as images in prompt tuning for multi-label image recognition. *arXiv*, 2022.

[Gel18] Axel Gelfert. Fake news: A definition. *Informal Logic*, 38(1):84–117, March 15 2018.

[GPA20] Sheila Freitas Gomes, Juliana Coelho Braga De Oliveira Penna, and Agnaldo Arroio. Fake news científicas: Percepção, persuasão e letramento. *Ciência & Educação (Bauru)*, 26:e20018, 2020.

[HA21] Sakshini Hangloo and Bhavna Arora. Fake news detection tools and methods – a review. 2021.

[hib25] hibrid.info. Metodologjia, 2025. Accessed: 2025-03-22.

[Inf25] InfoVeritas. Metodología, 2025. Accessed: 2025-03-22.

[Kal18] Bente Kalsnes. Fake news. In *Oxford Research Encyclopedia of Communication*. Oxford University Press, 2018.

[KCM+24] M. Abdul Khaliq, P. Chang, M. Ma, B. Pflugfelder, and F. Miletić. Ragar, your falsehood radar: Rag-augmented reasoning for political fact-checking using multimodal large language models. *arXiv*, July 11 2024.

[KPBZ21] Lev Konstantinovskiy, Oliver Price, Mevan Babakar, and Arkaitz Zubiaga. Toward automated factchecking: Developing an annotation schema and benchmark for consistent automated claim detection. *Digital Threats: Research and Practice*, 2(2):1–16, June 30 2021.

[KT20] Neema Kotonya and Francesca Toni. Explainable automated fact-checking: A survey. *arXiv*, 2020.

[LaG18] Jennifer LaGarde. *Fact Vs. Fiction: Teaching Critical Thinking Skills in the Age of Fake News*. International Society for Technology in Education, La Vergne, 2018.

[LBB+18] David M. J. Lazer, Matthew A. Baum, Yochai Benkler, Adam J. Berinsky, Kelly M. Greenhill, Filippo Menczer, Miriam J. Metzger, Gordon Pennycook, David Rothschild, Michael Schudson, Steven A. Sloman, Cass R. Sunstein, Emily A. Thorson, Duncan J. Watts, and Jonathan L. Zittrain. The science of fake news. *Science*, 359(6380):1094–1096, March 2018.

[Lor97] Alfred L. Lorenz. Review of richard alan nelson, a chronology and glossary of propaganda in the united states. *American Journalism*, 14(2):241–243, 1997.

[MAMP22] Nicholas Micallef, Vivienne Armacost, Nasir Memon, and Sameer Patil. True or false: Studying the work practices of professional fact-checkers. *Proc. ACM Hum.-Comput. Interact.*, 6(CSCW1), April 2022.

[McB20] Justin P. McBrayer. *Beyond Fake News: Finding the Truth in a World of Misinformation*. Routledge, New York, London, 2020.

[MFE+19] Federico Monti, Fabrizio Frasca, Davide Eynard, Damon Mannion, and Michael M. Bronstein. Fake news detection on social media using geometric deep learning. *arXiv*, 2019.

[Mon25] Monash University Library. Citing and referencing, 2025. Acessado em 22 de abril de 2025.

[NKV21] Jamal Abdul Nasir, Osama Subhani Khan, and Iraklis Varlamis. Fake news detection: A hybrid cnn-rnn based deep learning approach. *International Journal of Information Management Data Insights*, 1(1):100007, 2021.

[PGH+23] Baolin Peng, Michel Galley, Pengcheng He, Hao Cheng, Yujia Xie, Yu Hu, Qiuyuan Huang, and et al. Check your facts and try again: Improving large language models with external knowledge and automated feedback. *arXiv*, March 8 2023.

[PM18] Julie Posetti and Alice Matthews. A short guide to history of fake news and disinformation, 2018. A Learning Module for Journalists and Journalism Educators.

[PZ24] Rrubaa Panchendrarajan and Arkaitz Zubiaga. Claim detection for automated fact-checking: A survey on monolingual, multilingual and cross-lingual research. *Natural Language Processing Journal*, 7:100066, 2024.

[PZ25] Rrubaa Panchendrarajan and Arkaitz Zubiaga. Entity-aware cross-lingual claim detection for automated fact-checking. *arXiv*, 2025.

[Reu25] Reuters. About reuters fact check, 2025. Accessed: 2025-03-22.

[RG19] Raquel Recuero and Anatoliy Gruzd. Cascatas de fake news políticas: Um estudo de caso no twitter. *Galáxia (São Paulo)*, (41):31–47, 2019.

[RPPD23] Shaina Raza, Drai Paulen-Patterson, and Chen Ding. Fake news detection: Comparative evaluation of bert-like models and large language models with generative ai-annotated data. 2023. *Preprint - July 3, 2024* [Fake News Detection$_{I}t'sAllintheData!.pdf$].

[SBAB22] Isabel Segura-Bedmar and Santiago Alonso-Bartolome. Multimodal fake news detection. *Information*, 13(6):284, June 2022.

[SSC+19] Shivangi Singhal, Rajiv Ratn Shah, Tanmoy Chakraborty, Ponnurangam Kumaraguru, and Shin'ichi Satoh. Spotfake: A multi-modal framework for fake news detection. In *2019 IEEE Fifth International Conference on Multimedia Big Data (BigMM)*, pages 39–47. IEEE, 2019.

[SSW+17] Kai Shu, Amy Sliva, Suhang Wang, Jiliang Tang, and Huan Liu. Fake news detection on social media: A data mining perspective. *ACM SIGKDD Explorations Newsletter*, 19(1):22–36, 2017.

[Vla25] Factcheck Vlaanderen. Onze werkwijze, 2025. Accessed: 2025-03-22.

[VRA18] Soroush Vosoughi, Deb Roy, and Sinan Aral. The spread of true and false news online. *Science*, 359(6380):1146–1151, March 9 2018.

[Wan17] William Yang Wang. "liar, liar pants on fire": A new benchmark dataset for fake news detection. In Regina Barzilay and Min-Yen Kan, editors, *Proceedings of the 55th Annual Meeting of the Association for Computational Linguistics (Volume 2: Short Papers)*, pages 422–426, Vancouver, Canada, July 2017. Association for Computational Linguistics.

[WD17] Claire Wardle and Hossein Derakhshan. *Information disorder: Toward an interdisciplinary framework for research and policymaking*, volume 27. Council of Europe Strasbourg, 2017.

[YSS+23] Barry Menglong Yao, Aditya Shah, Lichao Sun, Jin-Hee Cho, and Lifu Huang. End-to-end multimodal fact-checking and explanation generation: A challenging dataset and models. In *Proceedings of the 46th International ACM SIGIR Conference on Research and Development in Information Retrieval*, pages 2733–2743. ACM, 2023.

[ZAZ21] Xia Zeng, Amani S. Abumansour, and Arkaitz Zubiaga. Automated fact-checking: A survey. *Language and Linguistics Compass*, 15(10):e12438, 2021.

[ZZ21] Xinyi Zhou and Reza Zafarani. A survey of fake news: Fundamental theories, detection methods, and opportunities. *ACM Computing Surveys*, 53(5):1–40, September 2021.