Detector de texto sintético para português brasileiro usando arquitetura Transformers

Synthetic text detector for Brazilian Portuguese using Transformers architecture

Resumo: A crescente disponibilidade de dados gerados por inteligências artificiais (IA) trouxe benefícios e potenciais riscos. A disponibilidade destes modelos baseados em português brasileiro (PT-BR) é estritamente reduzida. Este estudo apresenta um novo classificador com o objetivo de detectar a origem da geração do texto: sinético (TS) vs humano (TH). A arquitetura utilizada foi a biblioteca transformers, através do aprendizado por transferência. A matéria-prima do modelo, com o objetivo de treinar, testar e avaliar, é um conjunto de dados misto de textos em PT-BR. Em sua construção, foram compilados dezenas de textos humanos de variadas fontes, e posteriormente, a partir destes, foram gerados correspondentes, se utilizando de vários modelos de IA generativa. Foram treinados e avaliados dois modelos de base pré-treinados da plataforma huggingface: FacebookAI/xlm-roberta-base e neuralmind/bert-base-portuguese-cased. Os resultados revelam uma precisão de aproximadamente 100% em ambos os modelos. O melhor modelo ajustado é estudante do xml-RoBERTa-base. A contribuição está em um *dataset* misto em português brasileiro aberto e um modelo de detecção estudante RoBERTa ajustado para o português brasileiro.

Palavras Chaves: detector de IA; transformers; RoBERTa; Português brasileiro.

Abstract: The increasing availability of data generated by artificial intelligence (AI) has brought benefits and potential risks. The availability of these Brazilian Portuguese (PT-BR) based models is strictly limited. This study presents a new classifier with the aim of detecting the origin of text generation: synetic (TS) vs human (TH). The architecture used was the transformers library, through transfer learning. The raw material of the model, for the purpose of training, testing and evaluating, is a mixed *dataset* of PT-BR texts. In its construction, dozens of human texts were compiled from various sources, and subsequently, from these, correspondents were generated, using various generative AI models. Two pre-trained base models from the huggingface platform were trained and evaluated: FacebookAI/xlm-roberta-base and neuralmind/bert-base-portuguese-cased. The results reveal an accuracy of 100% for both models. The best fitted model is xml-RoBERTa-base student. The contribution is in a mixed *dataset* in open Brazilian Portuguese and a RoBERTa student detection model adjusted for Brazilian Portuguese.

Keywords: AI detector; transformers; RoBERTa; Brazilian Portuguese.

Detector de texto sintético para português brasileiro usando arquitetura Transformers

1. INTRODUÇÃO

Os grandes modelos de linguagem (LLMs) atuais de última geração possuem uma capacidade excepcional em diversas tarefas com precisão de estado-da-arte. No que diz respeito à geração de textos, os LLMs se destacam pela fluência, gramaticalidade, coerência e conhecimento do mundo real. (Ganesh Jawahar, 2020)

A revolução na área de processamento de linguagem natural (PLN) sob a égide da arquitetura codificador-decodificador alavancado pela biblioteca Transformers possibilitou o desenvolvimento de modelos de IA sob baixo custo, rápidos e baixa impressão de carbono. (Jain, 2022)

Com um sistema inovador de processamento de textos, o codificador é responsável em processar a entrada e transformá-la em uma representação interna. Já o decodificador recebe a informação e a transforma objetivando a geração de uma saída. Aliado ao mecanismo de atenção que suporta a criação de pesos a cada token de entrada, os modelos possuem um balanceamento adequado de longa memória. Isso permitiu a criação de uma vasta gama de modelos pré-treinados disponíveis para uso da comunidade, os quais são adaptados para uma tarefa específica, através do processo de ajuste fino.

Por outro lado, existem riscos associados à essa explosão de modelos disponíveis. Eventos associados como robôs agindo como humanos na web, plágio, criação de notícias falsas, ou outros problemas éticos e sociais estão envolvidos com essa problemática. Por isso, surge a necessidade de detectores capazes de diferenciar textos exclusivamente humanos de textos sintéticos.

A disponibilidade de conjuntos de dados e modelos disponíveis em PT-BR ainda é muito limitada. Com uma simples busca no repositório *huggingface.co*, vemos que 0,3% dos modelos e dados disponíveis se aplicam ao Português.

O português brasileiro possui expressões idiomáticas, gírias, detalhes linguísticos e gramática única os quais diferem de outras línguas e variações portuguesas. Desenvolver estudos com foco em PT-BR permite que o detector identifique padrões e perturbações específicas para a língua.

Para suprir essa deficiência, desenvolvemos um conjunto de dados que fosse exclusivamente em PT-BR, e ainda pudesse generalizar os vários estilos e formas que textos dessa linguagem podem assumir. Em seguida, criamos dados sintéticos de variados LLMs com relação aos textos humanos, através de engenharia de *prompt*. Portanto, foi feita uma minuciosa busca em dados de acesso aberto a fim de reunir os diferentes estilos, formatos e formas que a variação brasileira da língua portuguesa, abrangendo textos formais, coloquiais, poemas e outros.

O objetivo principal do trabalho se refere a desenvolver um detector de textos gerados por LLMs, de forma geral. Para alcançar este objetivo, o método aplicado neste artigo é o ajuste fino de um conjunto de dados em modelos pré-treinados.

Por isso, se fez necessário a criação de um conjunto de dados em PT-BR que pudesse ser o suporte do treinamento. Sendo assim, o objetivo secundário do artigo é desenvolver um *dataset* específico para esta tarefa.

A nossa contribuição para este artigo se resume:

- desenvolvimento de um conjunto de dados aberto variado de textos humanos em PT-BR e textos sintéticos de diversos LLMs com objetivo de treinamento do detector;
- desenvolvimento de um classificador em PT-BR usando a arquitetura Transformers.

2. TRABALHOS RELACIONADOS

Ao longo da leitura dos trabalhos relacionados, notamos que a área está atravessando uma fase de competição incessante, onde os avanços nas técnicas de detecção são confrontados por contramedidas de ataques para iludir e contornar as defesas.

Nesta revisão de literatura (Ganesh Jawahar, 2020), os autores introduziram o tema abordando questões éticas e sociais, salientando aspectos positivos e negativos das LLMs. Posteriormente, o autor enfatiza que a arquitetura estado-de-arte dos LLMs é o Transformer. Em seguida, classificou os detectores segundo seus métodos. Por fim, ressaltou que o modelo RoBERTa se destacou no problema de detecção de texto sintético.

- Detectores treinados desde o início: frequência de palavras e detecção de configuração de máquina;
- classificadores zero-shot;
- detectores ajustados fino;
- colaboração máquina-humano.

Acerca da revisão de literatura (Valiaiev, 2024), o autor destacou a revolução ocorrida na área de PNL devido ao poder computacional e aos grandes conjuntos de dados, enfatizando os potenciais problemas criados pelo mau uso dos LLMs. Nesse mesmo estudo, o autor destaca a utilidade da arquitetura Transformers em lidar com dependências de longo prazo no texto. O autor citou inúmeras técnicas de aprendizado de máquina para a tarefa de detecção de dados sintéticos: ajuste fino BERT, *bag-of-words*, probabilidade total e baseado na classificação de histograma de verossimilhança. O autor traçou uma linha temporal sobre a evolução das pesquisas e tendências:

- Antes de 2019: Introdução da arquitetura transformers e desenvolvimento do BERT e GPT;
- 2020: início da detecção automática de texto sintético; primeiros reflexos dos LLMs na sociedade; estudo de textos discriminatórios.
- 2021: aprimoramento dos métodos de detecção, limitações e soluções de vieses.

Em seu estudo (Mitchell, 2023), o autor apresenta o DetectGPT, uma abordagem estatística pra detecção de textos gerados por LLMs. Ele observou que a curvatura da função de log-probabilidade tende a ser significativamente mais negativa que textos

humanos. Outra contribuição do trabalho diz respeito às variações de máquinas detectoras: detecção de textos parafraseados; impacto de estratégias alternativas na detecção como temperatura, "*top_k*"; e por fim, a problemática da detecção quando o modelo é desconhecido (*black-box*).

Neste recente trabalho (Ruixiang Tang, 2024), o autor agrupou os métodos de detecção de textos gerados por LLMs em:

- *white-box* – acesso prévio aos modelos generativos. Por exemplo, detecção baseada em marcas d'água.
- *black-box* – sem acesso aos modelos. Por exemplo, verificação de fatos, padrões linguísticos e desigualdades estatísticas.

Em seu estudo (Weber-Wulff, 2023), o autor testou 12 ferramentas disponíveis publicamente e dois sistemas comerciais. Nos resultados, identificaram viés em classificar os textos como escritos por humanos, ao invés de ser sintético. Enfatizaram que as técnicas de ofuscação pioraram significativamente o desempenho das ferramentas.

Este artigo apresenta o sistema "Real or Fake Text" (Dugan, 2020), um aplicativo que coleta simultaneamente anotações de qualidade de texto gerado por máquina, permitindo que o público avalie e melhore sua habilidade na detecção de texto sintético.

Este importante trabalho (Chakraborty, 2023), baseado na teoria da informação, abordam práticas necessárias para a tarefa de detecção de textos sintéticos, tendo em vista que os LLMs estão mais parecidos com textos humanos. Os autores se aprofundam em diversos métodos de detecção: Abordagens tradicionais: envolvimento de métodos estatísticos de detecção de outliers como métricas de entropia, perplexidade e frequência de n-gramas; detectores baseados em classificador; outros baseados no *watermark*; por fim, resultados impossibilitados: os autores evidenciaram as vulnerabilidades das metodologias usando ataques *vanilla*, ataques com uso de paráfrases e de falsificação.

Os autores concluíram que técnicas de parafraseamento reduzem o desempenho da detecção, porém ainda é possível alcançar uma detecção razoável.

Neste trabalho (Trung T. Nguyen, 2023), os autores desenvolveram um método para detectar textos sintéticos focados na criação de um conjunto de dados baseado no Wikipedia e em notícias das eleições 2024.

Neste artigo (Sebastian Gehrmann, 2019), foi apresentada uma ferramenta para apoiar humanos na detecção de textos sintéticos aplicando um conjunto de métodos estatísticos e de forma visual. O sistema facilita a interpretação humana na tarefa de classificação da fonte dos textos.

Neste curioso trabalho (Liu, 2024), o autor utiliza o método de classificação zero-shot do ChatGPT para detectar textos gerados por IA. Os resultados sugerem que o detector possui desempenho assimétrico, uma vez que tem um bom desempenho em identificar textos humanos, porém se esforça em identificar texto gerado por IA.

A plataforma Kaggle (Kaggle, 2024) realizou uma competição em 2024 com o objetivo de detectar texto gerado por IA. Este desafio produziu inúmeros materiais úteis para a construção de um detector preciso e generalista.

Entre as sete publicações vencedoras na tabela de classificação privada, temos a prevalência da arquitetura transformers e o ajuste fino como destaque na maioria dos melhores resultados. Segue as técnicas dos vencedores:

1º Lugar: Pseudo-Rótulos com Múltiplos Modelos

2º Lugar: Geração de Dados + Ensemble de Modelos

3º Lugar: Uso de Filtros de Probabilidade com Modelos Pré-Selecionados

4º Lugar: Abordagem de Armas Combinadas

5º Lugar: Fine-tuning com 1.7 Milhões de Exemplos + Adaptação de Domínio

6º Lugar: SVM de Uma Classe com Features Sintéticos Baseados em Entropia

7º Lugar: Geração de Dados com Modelos Não-Instruídos

3. METODOLOGIA

Nossa abordagem foi baseada no paradigma de aprendizado por transferência, onde o modelo final é adaptado a partir de um modelo pré-treinado para desempenhar uma tarefa específica, no caso, a detecção de textos sintéticos, de saída binária (0 para humano ou 1 para sintético).

Para avaliar o desempenho do modelo, utilizamos métricas de qualidade das previsões (precisão, *recall* e F1-score), matriz de confusão, a Curva de Característica Operacional do Receptor (ROC) e a Área sob a curva (AUC) como métricas principais.

Conforme o autor (Mariano, 2021), as principais métricas para avaliação de modelos de classificação são a acurácia, sensibilidade (recall), especificidade, precisão e F-score.

Para o nosso estudo, segue como é construída a matriz de confusão:

Tabela I – Matriz de confusão padrão.

Matriz de confusão		Classe Predita	
		IA	Humano
Classe Original	IA	VP	FN
	Humano	FP	VN

Legenda:

VP – verdadeiro positivo. O texto é de IA e o modelo classificou IA.

FP – falso positivo. O texto é de humanos e o modelo classificou IA.

FN – falso negativo. O texto é de IA e o modelo classificou de humanos.

VN – verdadeiro negativo. O texto é de humanos e o modelo classificou de humanos.

A acurácia avalia simplesmente o percentual de acertos.

$$acurácia = \frac{VP + VN}{VP + FN + VN + FP}$$

A sensibilidade ou recall avalia a capacidade do método detectar resultados positivos, para nosso caso, detectar textos sintéticos.

$$sensibilidade = \frac{VP}{VP + FN}$$

Por outro lado, a especificidade avalia a capacidade de detectar resultados negativos, neste trabalho, detectar textos humanos.

$$especificidade = \frac{VN}{VN + FP}$$

A precisão avalia a quantidade de verdadeiros positivos sobre todas as classificações positivas. Para nosso caso, a precisão avalia a certeza em detectar positivos, ou seja, a certeza de detectar textos de IA.

$$precisão = \frac{VP}{VP + FP}$$

O F-score é uma média harmônica entre a precisão e a sensibilidade.

$$F1 = 2 * \frac{precisão * sensibilidade}{precisão + sensibilidade}$$

A Curva ROC é uma representação gráfica da taxa de verdadeiros positivos (TVP) em função da taxa de falsos positivos (TFP) para diferentes limiares de classificação. A curva ROC resultante do nosso modelo foi gerada com base nos valores preditivos do modelo e nos rótulos verdadeiros dos dados.

A métrica AUC quantifica a área sob a curva ROC, oferecendo uma medida agregada de desempenho do modelo. Um valor de AUC próximo de 1.0 indica que o modelo tem um desempenho excelente na distinção entre as classes positiva e negativa.

4. DESENVOLVIMENTO DO CONJUNTO DE DADOS

Nesta seção, vamos fornecer os detalhes do *modus operandi* para a produção do conjunto de dados - Database e do classificador binário para textos sintéticos - Ajuste fino do FacebookAI/xlm-roberta-base. O nome Database foi escolhido em referência à comida brasileira, conhecida por sua mistura de ingredientes. Em relação ao modelo Ajuste fino do FacebookAI/xlm-roberta-base, o nome foi escolhido devido à habilidade do animal se adaptar ao ambiente, buscando distinguir o contexto à sua volta.

Para a construção de um *dataset* misto capaz de generalizar uma ampla variedade de textos em PT-BR, selecionamos textos, de variadas fontes de dados, em diversos estilos de escritas de humanos, e uma ampla gama de conteúdo. A seguir o fluxo de criação do *dataset* conforme pode ser observado na Figura I.

Figura I – Fluxo de criação do Database.

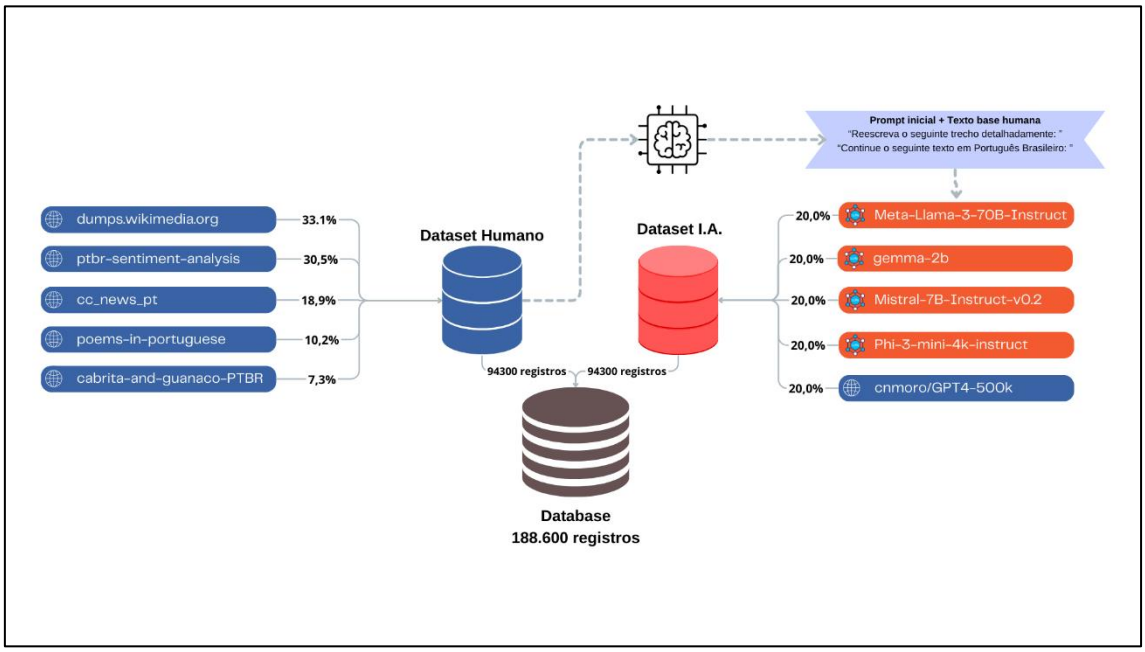

4.1 *dataset* de textos humanos

Antes de detalhar o processo de criação, é importante observar que não foram selecionados os textos em PT-BR traduzidos ao longo de sua criação, uma vez que a maioria dos tradutores utilizam IA em sua geração. Portanto, devem ser textos escritos originalmente na linguagem de estudo.

Primeiramente, incluímos um conjunto de dados com textos mais informais e variados, disponibilizado pelo Kaggle e originalmente utilizado para análise de sentimento (Kaggle, Brazilian Portuguese Sentiment Analysis Datasets, 2021). Nele foram retirados comentários e opiniões de variadas fontes.

Em busca de um conjunto de dados mais variado e completo, optamos por utilizar um total de 28.788 linhas (30,5%), incluindo apenas os valores acima de 512 caracteres, de maneira a selecionar apenas frases completas, que em sua maioria foram comentários e sugestões bem estruturadas dos mais diversos usuários e plataformas.

Ainda pelo Kaggle, foi adicionado a nossa base, parte do *dataset* de poemas de autores brasileiros (Kaggle, Poems in Portuguese, 2020), com o objetivo de obtermos textos menos informais, mas com uma boa diversidade de estilos de escrita. Esse conjunto de dados por sua vez foi retirado do website https://www.escritas.org/pt/poemas, e optamos por selecionar um total de 9.641 linhas (10,2%) apenas os poemas com mais de 400 caracteres, na intenção de evitar poemas curtos e garantir textos mais contínuos.

Outra parte do *dataset* foi obtida a partir de *dumps* da Wikipédia (wikipedia, s.d.). Para garantir a boa qualidade dos dados, foram excluídas as marcações html e outros ruídos, utilizando assim um total de 31.251 linhas (33,1%), sendo nossa maior fonte de dados, principalmente por estar com as regras normativas da língua portuguesa bem ajustadas.

Adicionalmente, buscamos no repositório *huggingface.co* um conjunto de notícias (Face, 2024) que engloba uma variedade de notícias e reportagens de muitos portais brasileiros. O motivo da inclusão é devido aos diversos estilos de manifestação de conteúdos ao redor do Brasil, obtendo 17.774 de linhas (18,8%).

Por fim, agregamos um *dataset* focado em *prompts* humanos e respostas geradas por IA (Face, Hugging Face, 2024). Nele, buscamos extrair apenas as instruções humanas, no propósito de capturar uma possível conversa em português. Sendo assim, nossa menor fonte, totalizando 6.845 linhas (7,3%).

4.2 *dataset* de textos sintéticos

Com o objetivo de balancear a parte humana do Database, e ainda, buscando diversificar o conjunto sintético e manter relação com os textos humanos em questões de assuntos, tipo e formas textuais, optamos por gerar textos a partir de diferentes LLMs, provendo como entrada (prompt) parte do texto humano. Segue os modelos utilizados:

- meta-llama/Meta-Llama-3-70B-Instruct
- mistralai/Mistral-7B-Instruct-v0.2
- google/gemma-2b
- microsoft/Phi-3-mini-4k-instruct

A primeira etapa no processo de engenharia de *prompt* foi definir a sua estrutura inicial para orientar a IA. A criação que gerasse respostas consistentes e dentro do esperado apresentou dificuldades iniciais, sendo o maior deles a tendência do modelo a produzir textos fora da língua esperada.

Para construir a parte sintética, adotamos uma abordagem iterativa, onde fizemos a utilização de *prompts* iniciais fixos, seguidos por partes aleatórias de trecho de nossa base humana já existente. Os mesmos foram testados em pequena escala, e com base nos resultados, refinamos a linguagem, e guiamos o modelo para o uso do português. O uso de "*prompts* de exemplo" foi uma estratégia crucial para ajustar o comportamento dos modelos. Os melhores que se destacaram para a geração foram “Reescreva o seguinte trecho detalhadamente:” e “Continue o seguinte texto em Português Brasileiro:” ambos seguidos por textos de nossa base humana.

Como resultado, os modelos Meta-Llama-3-70B-Instruct e Phi-3-mini-4k-instruct se comportaram melhor com o início do *prompt* sendo “Reescreva o seguinte trecho detalhadamente: ”, enquanto os modelos Mistral-7B-Instruct-v0.2 e gemma-2b se deram melhor com a outra instrução, focada em continuação e especificidade em português

brasileiro. Todos os modelos foram igualmente balanceados, cada um representando individualmente 20% do *dataset* (15.000 linhas).

O gráfico I apresenta a diversidade dos dados agregados, destacando a variedade de fontes e formatos incluídos.

Gráfico I – Representação gráfica do conjunto de dados Database.

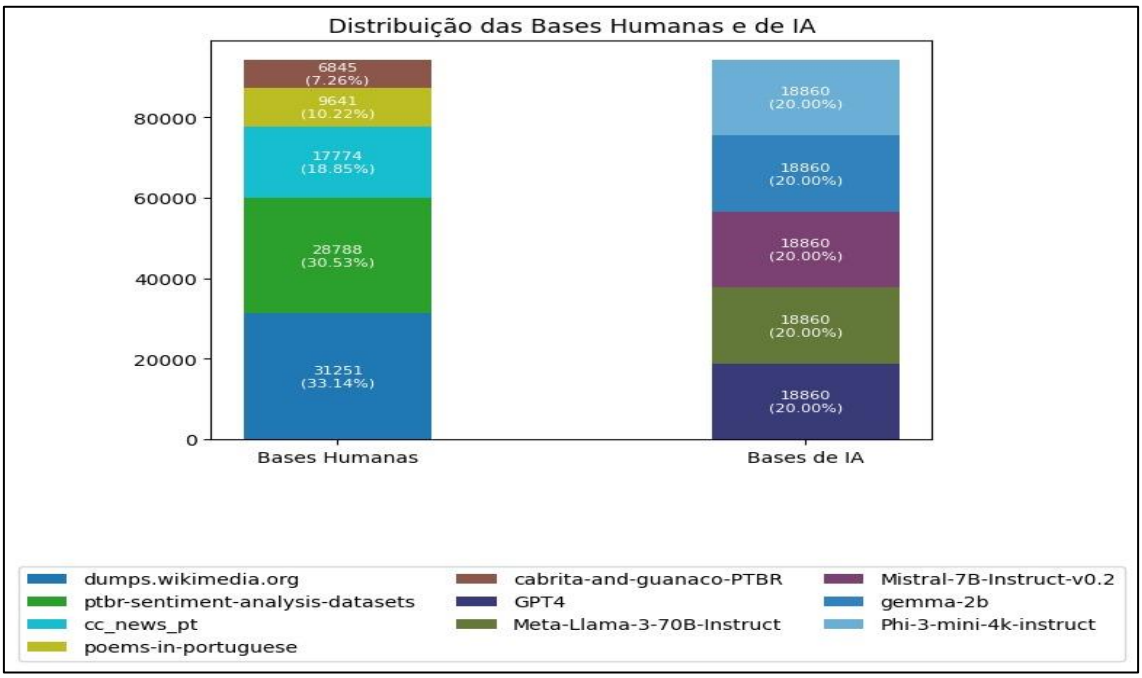

Com o propósito de descrever melhor as palavras mais frequentes dos conjuntos de dados, resumimos os dados em duas palavras de nuvens de cada um dos *datasets*, respectivamente figura II (textos humanos) e figura III (textos sintéticos):

Figura II – Nuvem de palavras dataset humano

Figura III – Nuvem de palavras dataset sintético

Finalizado o conjunto de dados, foi subdividido em treino (~75 mil linhas – 80%), validação (9750 linhas – 10%) e teste (9750 linhas – 10%).

5. DESENVOLVIMENTO DO DETECTOR DE TEXTO SINTÉTICO

O modelo pré-treinado escolhido para ajuste fino foram os FacebookAI/xlm-roberta-base, um modelo com 279M de parâmetros e treinado em mais de 100 idiomas, corroborado pelo autor por excepcionais capacidades multilíngues; e o modelo neuralmind/bert-large-portuguese-cased, conhecido por BERTimbau, de 24 camadas e 335M de parâmetros.

5.1 Pré-processamento

A limpeza dos dados foi o primeiro passo antes de iniciar o treinamento do Modelo. Nessa fase, foram identificados e removidos “paragrafação” e valores atípicos que poderiam distorcer os resultados. Além disso, inconsistências e erros nos dados, como partes de texto em língua diferente também são identificados e corrigidos por meio de remoção para garantir a integridade do conjunto de dados em português.

Após a limpeza, os dados passaram por um processo de normalização, que ajusta os dados a uma escala comum, para diminuir a complexidade de tokenização (codificação) e processamento. A base de dados de teste não sofreu o pré-processamento completo com o objetivo de testar generalizações.

5.2 Ajuste fino

Ao longo do processo de ajuste fino, consideramos inúmeros cenários a fim de evitar o sobreajuste dos dados, mantendo uma alta precisão dos dados. Apesar da otimização bayesiana apontar alguns caminhos, foi utilizado um treinamento com taxa de aprendizado variável, iniciando com uma taxa de aprendizado baixa no valor de 5e-07.

Foi utilizada a técnica de aumento da taxa de aprendizado ao longo das épocas. E ainda foi utilizada a técnica de "*early stopping*", ao longo das épocas, o valor da perda começasse a se estabilizar. O decaimento de peso foi no valor de 0.07. E ainda, utilizou-se uma técnica de carregamento de melhor modelo ao final na melhor época.

Após os ensaios, ficou evidente que o uso de 4 épocas foi suficiente para o modelo se estabilizar. A métrica utilizada foi a perda na avaliação. Segue abaixo, apresentado na figura IV, o processo de ajuste fino dividido em treinamento, validação e teste.

Figura IV – Fluxo de criação do Ajuste fino do FacebookAI/xlm-roberta-base.

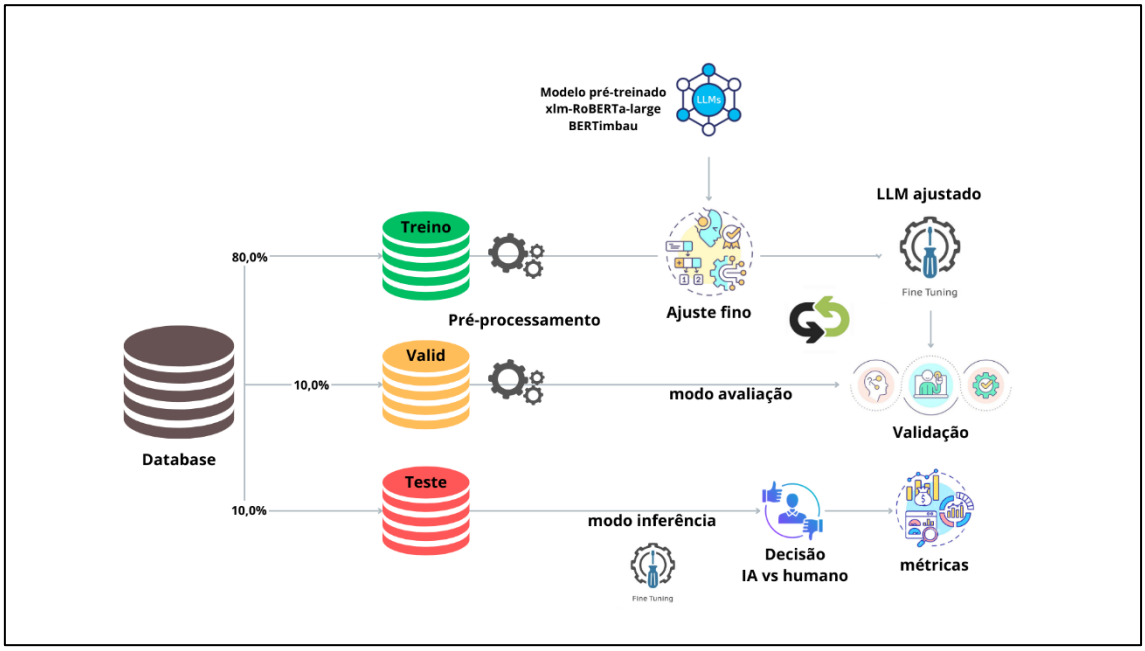

Para a calibração dos hiperparâmetros iniciais, o modelo professor recebeu um pré-treinamento em uma amostra aleatória de 20% da base buscando os melhores parâmetros.

Ao final do ajuste dos hiperparâmetros, os argumentos de treinamento estão detalhados na Tabela II:

Tabela II – Argumentos do treinamento.

Argumento	Valor	Descrição
evaluation_strategy	epoch	Avaliação por época
learning_rate	5e-07	Taxa de aprendizado no início
weight_decay	0.07	Decaimento de peso na regularização
lr_scheduler_type	linear	Agendador da taxa de aprendizado
warmup_steps	500	Passos de aquecimento antes de iniciar o agendador
load_best_model_at_end	True	Carregamento do melhor modelo no final do treinamento
metric_for_best_model	eval_loss	Métrica para determinar o melhor modelo
greater_is_better	False	Polaridade da métrica

6. RESULTADOS E DISCUSSÃO

O grande desafio para o treinamento do modelo é evitar o sobreajuste dos dados. Após inúmeros cenários de treinamento, o modelo final que obteve um teste robusto e não teve sinais de sobreajuste obteve as seguintes métricas, conforme a Tabela III a seguir:

Tabela III – Perdas ao longo do treinamento do ajuste fino do FacebookAI/xlm-roberta-base.

Época	**Perda de treinamento**	**Perda de validação**
1	0.002800	0.001495
2	0.002200	0.000922
3	0.000800	0.000633
4	0.000800	0.000531

É interessante observar que, ao longo das épocas, houve um decréscimo na perda de treinamento, confirmando a hipótese de que o modelo está efetivamente aprendendo a tarefa. A redução na perda de validação confirma este aprendizado, indicando que o ajuste fino não se limita à base de treinamento.

E por outro lado, observamos que a perda na base de validação esteve menor que na perda de treinamento ao longo das épocas, refutando a hipótese de sobreajuste dos dados na base de treinamento.

Para esse ajuste fino, as métricas avaliadas foram:

- Acurácia: 0.9998
- Precisão: 0.9997
- *Recall*: 0.9999
- *F1*-score: 0.9998

Para a fase de testes, segue a análise dos resultados alcançados a partir da inferência dos modelos na base de teste do Database.

Nesta etapa, submetemos três modelos para testes:

- Ajuste fino do FacebookAI/xlm-roberta-base
- Ajuste fino do Bertimbau - neuralmind/bert-large-portuguese-cased
- openai-community/roberta-base-openai-detector: detector disponível na plataforma *huggingface.co*

A seguir, apresentamos na Tabela IV o resumo de métricas avaliadas.

Tabela IV – Modelos e métricas na fase de testes.

Modelo	Acurácia	Precisão	Recall	F1-score	AUC-ROC
Ajuste fino do FacebookAI/xlm-roberta-base	1.00	1.00	1.00	1.00	1.00
Ajuste fino do neuralmind/bert-large-portuguese-cased	1.00	1.00	1.00	1.00	1.00
openai-community/roberta-base-openai-detector (Solaiman, 2019)	0.50	0.52	0.03	0.06	0.45

O modelo da openai-community/roberta-base-openai-detector se comportou como um classificador aleatório para esta base de avaliação. O detector não é relevante para textos em PT-BR.

O ajuste fino do FacebookAI/xlm-roberta-base atingiu valores consistentes e robustos para esta tarefa de detecção de textos sintéticos. A performance sugere que é altamente adequado e recomendável para esta tarefa treinado neste banco de dados.

O ajuste fino do BERTimbau obteve resultados notáveis sendo competitivo para esta tarefa. Apresentamos as matrizes de confusão de ambos os modelos e as curvas ROC.

Figura V – Matriz de confusão na fase de testes do ajuste fino FacebookAI/xlm-roberta-base.

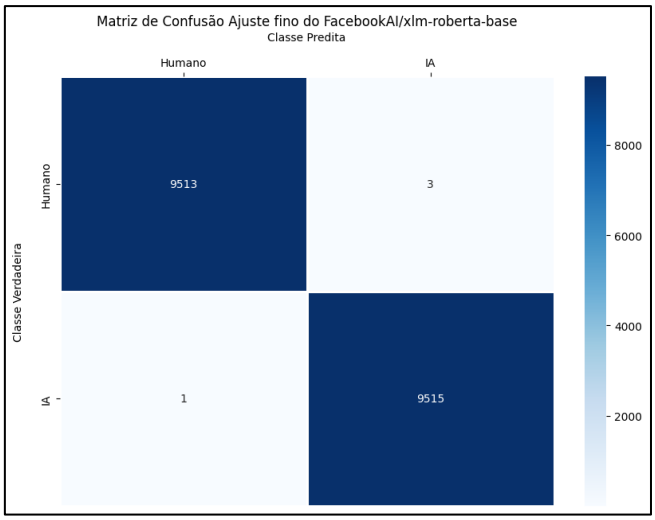

Figura VI – Matriz de confusão na fase de testes do ajuste fino neuralmind/bert-large-portuguese-cased

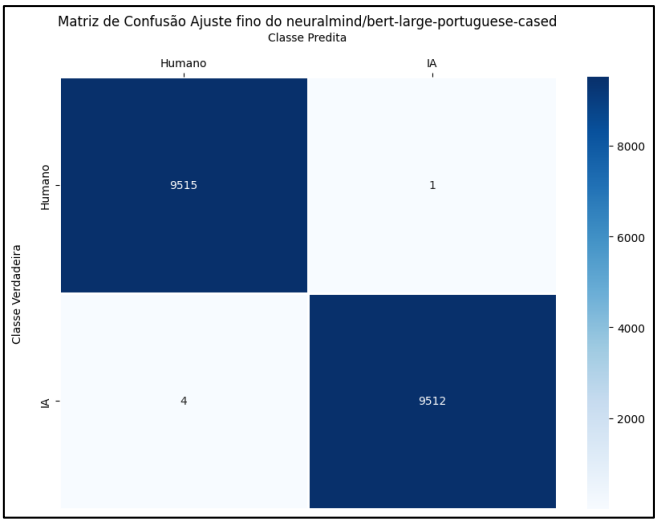

Figura VII – Matriz de confusão openai-community/roberta-base-openai-detector

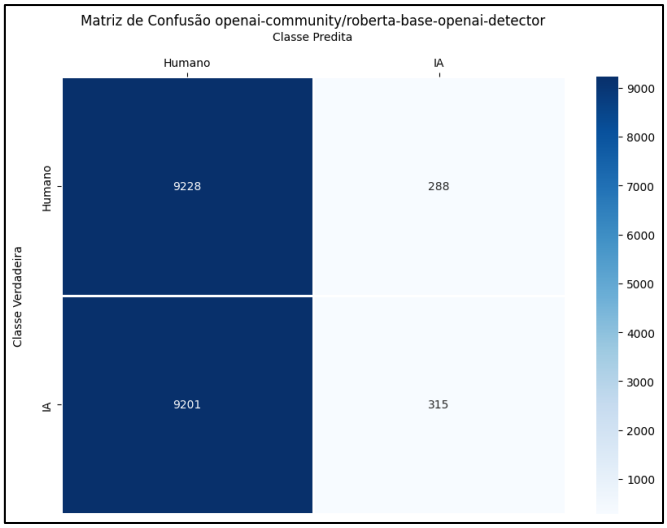

A matriz de confusão da figura V – ajuste fino do modelo FacebookAI/xlm-roberta-base descreve os acertos e erros das classificações. Temos que, dos 9516 textos de I.A., o modelo errou apenas uma vez (falso positivo). E dos textos humanos, o modelo classificou apenas 3 textos errados (falso negativo). O modelo alcançou F1-score de valor aprimado 1.0 o que sugere um classificador excepcional.

A matriz da figura VI revela uma precisão semelhante ao anterior. Isso indica que o modelo se ajustou bem ao conjunto de dados. Essa precisão se assemelha aos classificadores no estado-da-arte (SOTA).

Em contrapartida, na figura VII, ao testar o modelo "openai-community/roberta-base-openai-detector", é possível notar uma tendência no modelo em prever texto como sendo de humano, independente da classe verdadeira. Logo, os falsos negativos (previsão de texto humano sendo sintético) foram muito frequentes, prejudicando a avaliação do modelo, sendo reprovado na tarefa de detectar textos em PT-BR.

Figura VIII – Curva ROC do ajuste fino FacebookAI/xlm-roberta-base.

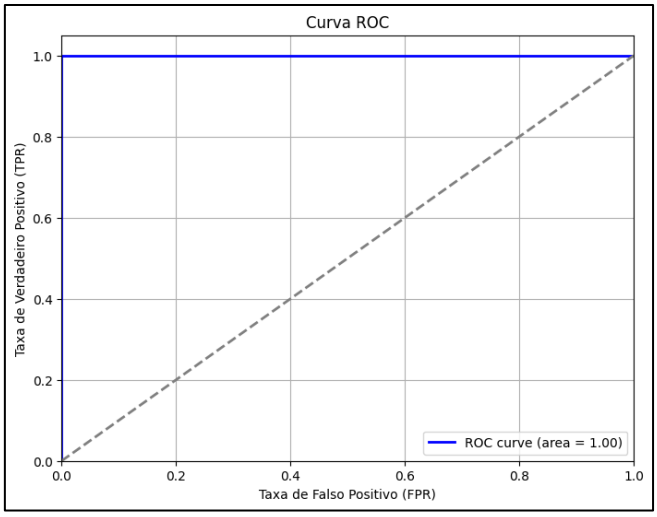

Figura IX – Curva ROC do ajuste fino do neuralmind/bert-large-portuguese-cased

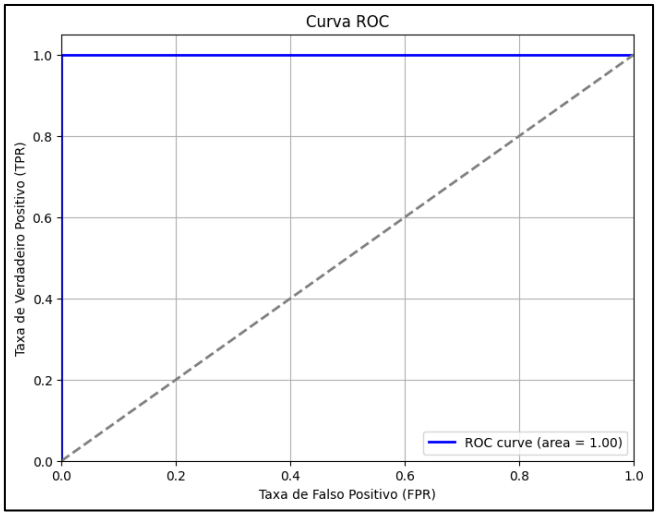

Figura X – Curva ROC openai-community/roberta-base-openai-detector

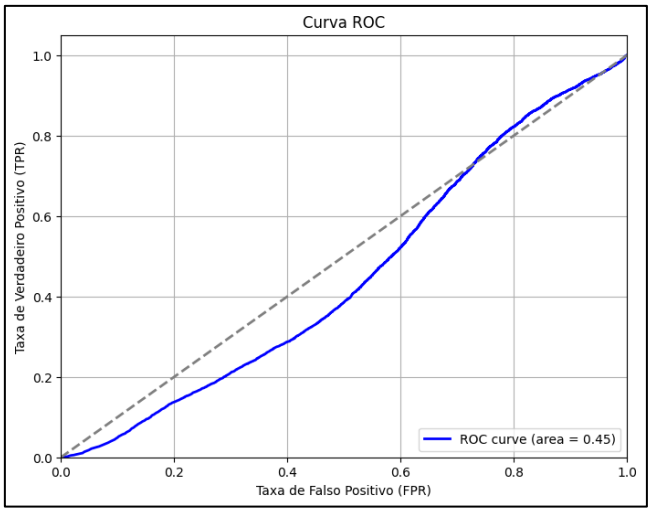

Por fim, os gráficos ROC das figuras VIII, IX e X retificam a percepção da matriz de confusão elevando tais modelos à estado-da-arte para este conjunto de dados, em contrapartida do modelo da "openai-community/roberta-base-openai-detector" o qual se comporta próximo ao tracejado, isto é, um classificador aleatório.

7. CONCLUSÃO E TRABALHOS FUTUROS

Neste trabalho, desenvolvemos um variado conjunto de dados integralmente em PT-BR. Ele foi pensado para ser o mais diversificado possível, contendo diferentes fontes, tipos textuais, autores e outras características. A partir dos textos humanos, foram geradas sentenças de LLMs com o objetivo de criar pares de textos de mesmo assunto e tipos textuais. Para o futuro, pensamos em ampliar o corpus no quantitativo de textos humanos, e criar variações de parâmetros para a criação dos textos sintéticos, como temperatura e "*top_k*", e manter sempre aberto para a comunidade.

Em um ambiente de explosiva criação de conteúdo sintético e sua rápida propagação, este trabalho busca ser uma ferramenta útil em diversas áreas, tais como combate à desinformação.

É fundamental o desenvolvimento de LLMs exclusivos na variação brasileira da língua portuguesa pois os capacitam a identificar nuances linguísticas, expressões idiomáticas, textos poéticos, gírias, e outras estruturas do PT-BR. Portanto, o estudo se reveste de tal relevância para a comunidade brasileira.

Por fim, construímos um classificador binário específico para PT-BR. Ele foi projetado para distinguir textos sintéticos gerados por LLMs em contraste de textos humanos. Para o futuro, pretendemos nos aprofundar nesse domínio, principalmente na área de testagem e avaliação, usando os modelos desenvolvidos em bases externas e ainda textos inéditos que não estão disponíveis na web, e por fim, avaliar como os modelos se comportam com ataques de paráfrases e ofuscação de textos.

8. REFERÊNCIAS

Brandão, S. R. (2024). AI Tools vs AI Text: Detecting AI-Generated Writing in Foot and Ankle Surgery. *Foot & Ankle Surgery: Techniques, Reports & Cases*. doi:https://doi.org/10.1016/j.fastrc.2024.100367

Chakraborty, S. A. (2023). On the Possibilities of AI-Generated Text Detection. *arXiv*. doi:https://doi.org/10.48550/ARXIV.2304.04736

Desaire, H. A. (2023). Distinguishing Academic Science Writing from Humans or ChatGPT with over 99% Accuracy Using Off-the-Shelf Machine Learning Tools. *Cell Reports Physical Science 4*. doi:https://doi.org/10.1016/j.xcrp.2023.101426

Desaire, H. A.-G. (2023). Accurately Detecting AI Text When ChatGPT Is Told to Write like a Chemist. *Cell Reports Physical Science 4*. doi:https://doi.org/10.1016/j.xcrp.2023.101672

Dugan, L. D.-B. (2020). RoFT: A Tool for Evaluating Human Detection of Machine-Generated Text. *Proceedings of the 2020 Conference on Empirical Methods in Natural Language Processing: System Demonstrations (Proceedings of the 2020 Conference on Empirical Methods in Natural Language Processing: System Demonstrations, Online: Association for Computati*, (pp. 189-96).

Face, H. (2024). *Hugging Face*. Fonte: eduagarcia/cc_news_pt: https://huggingface.co/datasets/eduagarcia/cc_news_pt

Face, H. (2024). *Hugging Face*. Fonte: vlofgren/cabrita-and-guanaco-PTBR: https://huggingface.co/datasets/vlofgren/cabrita-and-guanaco-PTBR

Ganesh Jawahar, M. A.-M. (2020). Automatic Detection of Machine Generated Text: A Critical Survey. *arXiv*. doi:https://doi.org/10.3390/bdcc8030032

Guo, B. X. (2023). How Close Is ChatGPT to Human Experts? Comparison Corpus, Evaluation, and Detection. *arXiv*. doi:https://doi.org/10.48550/ARXIV.2301.07597

Hamed Alshammari, A. E.-S. (2024). AI-Generated Text Detector for Arabic Language Using Encoder-Based Transformer Architecture. *Big Data and Cognitive Computing*. doi:https://doi.org/10.48550/ARXIV.2011.01314

Jain, S. M. (2022). Hugging Face." In Introduction to Transformers for NLP. *CA: Apress*. doi:https://doi.org/10.1007/978-1-4842-8844-3_4

Kaggle. (2020). *Poems in Portuguese*. Fonte: Kaggle: https://www.kaggle.com/datasets/oliveirasp6/poems-in-portuguese

Kaggle. (2021). *Brazilian Portuguese Sentiment Analysis Datasets*. Fonte: Kaggle: https://www.kaggle.com/datasets/fredericods/ptbr-sentiment-analysis-datasets

Kaggle. (2024). *LLM - Detect AI Generated Text*. Fonte: Kaggle: https://www.kaggle.com/competitions/llm-detect-ai-generated-text/leaderboard

Liu, A. B. (2024). Fighting Fire with Fire: Can ChatGPT Detect AI-Generated Text? *ACM SIGKDD Explorations Newsletter 25*. doi:https://doi.org/10.1145/3655103.3655106

Mitchell, E. Y. (2023). DetectGPT: Zero-Shot Machine-Generated Text Detection Using Probability Curvature. *arXiv*. doi:https://doi.org/10.48550/ARXIV.2301.11305

Ruixiang Tang, Y.-N. C. (2024). The Science of Detecting LLM-Generated Text. *Communications of the ACM 67*. doi:https://doi.org/10.1145/3624725

Sadasivan, V. S. (2023). Can AI-Generated Text Be Reliably Detected? *arXiv*. doi:https://doi.org/10.48550/ARXIV.2303.11156

Sebastian Gehrmann, H. S. (2019). GLTR: Statistical Detection and Visualization of Generated Text. *arXiv*. doi:https://doi.org/10.48550/ARXIV.1906.04043

Trung T. Nguyen, A. H. (2023). How to Detect AI-Generated Texts? *IEEE 14th Annual Ubiquitous Computing, Electronics & Mobile Communication Conference (UEMCON)*, (pp. 0464–71). doi:https://doi.org/10.1109/UEMCON59035.2023.10316132

Valiaiev, D. (2024). Detection of Machine-Generated Text: Literature Survey. *arXiv*. doi:https://doi.org/10.48550/ARXIV.2402.01642

Weber-Wulff, D. A.-N.-D. (2023). Testing of Detection Tools for AI-Generated Text. *International Journal for Educational Integrity 19*. doi:https://doi.org/10.1007/s40979-023-00146-z

wikipedia. (s.d.). *Wikimedia*. Fonte: https://dumps.wikimedia.org