Uma abordagem de colaboração interinstitucional para treinamento de modelos de inteligência artificial no Poder Judiciário Brasileiro

Resumo. *O uso de inteligência artificial (IA) no sistema judiciário tem promovido avanços significativos. Contudo, o desenvolvimento desses sistemas ocorre, em grande parte, de forma isolada pelos diferentes tribunais, o que gera altos custos, limitações de interoperabilidade e modelos com vieses regionais. Além disso, o tratamento de dados sensíveis impõe desafios éticos e legais relacionados à privacidade e à confidencialidade. Diante desse cenário, este trabalho propõe uma abordagem alternativa baseada em aprendizado federado, visando um modelo distribuído de treinamento de IA. A metodologia apresentada examina a viabilidade técnica do aprendizado federado em comparação com abordagens centralizadas. Os resultados demonstram que o aprendizado federado possibilita equilibrar inovação tecnológica e conformidade legal, abrindo perspectivas para soluções colaborativas e sustentáveis no âmbito do sistema judiciário.*

Palavras-chave: *Aprendizado Federado, inteligência artificial, justiça*

1. INTRODUÇÃO

A inteligência artificial (IA) tem se consolidado como uma ferramenta estratégica para a modernização do Poder Judiciário, com potencial para transformar significativamente a administração e a experiência de acesso à justiça. As aplicações da IA no campo jurídico são amplas, abrangendo desde a automatização de tarefas rotineiras, como a identificação de peças processuais e a classificação de casos por matéria, até a análise preditiva de decisões judiciais e a geração automática de textos e sentenças. No Brasil, o Conselho Nacional de Justiça (CNJ) identificou 140 projetos relacionados à aplicação de IA desenvolvidos por 62 tribunais brasileiros, englobando diversas áreas, soluções e objetivos. (Conselho Nacional de Justiça (CNJ), 2023).

Entre as atividades mais recorrentes nesses projetos, destacam-se a ”busca por dados similares” (69 projetos), seguida pela ”classificação de documentos” (66 projetos) e pela ”automação de documentos processuais” (39 projetos). A principal motivação para o desenvolvimento dessas iniciativas reside na busca por maior eficiência e celeridade nos processos judiciais, além de proporcionar maior precisão e consistência na execução de tarefas repetitivas.

No que concerne às equipes especializadas para o desenvolvimento de IA, constatou-se que 69,3% dos tribunais dispõem de equipes dedicadas, enquanto 30,7% necessitam alocar recursos humanos de outras áreas para atender às demandas. Em relação à infraestrutura computacional,

observa-se que a maioria dos projetos utiliza exclusivamente parques computacionais baseados em CPUs (76 projetos). Dentre as ferramentas empregadas, destacam-se o uso das bibliotecas *TensorFlow* e *Keras*, enquanto os modelos de linguagem mais aplicados foram o BERT e o GPT-4. Adicionalmente, a biblioteca *Scikit-learn* figura como uma das mais utilizadas para o desenvolvimento dessas soluções.

Apesar dos avanços observados, o panorama atual do desenvolvimento de projetos de IA no Poder Judiciário brasileiro reflete uma descentralização significativa entre os tribunais, com limitada colaboração interinstitucional. Esse contexto aponta para a necessidade de maior integração e compartilhamento de conhecimentos e recursos, a fim de maximizar o impacto das soluções tecnológicas implementadas.

1.1 Trabalhos Relacionados

A técnica de aprendizado federado foi proposta pelo Google em 2016 (McMahan et al., 2023), propondo uma abordagem inovadora do treinamento de redes neurais profundas onde os dados estão distribuídos em várias fontes distintas. A principal motivação para o desenvolvimento do Aprendizado Federado é a crescente disponibilidade de dados em dispositivos móveis e a necessidade de proteger a privacidade dos usuários.

Os autores introduziram o **FedAvg**, algoritmo central para o aprendizado federado. Ele se baseia na ideia de combinar a descida de gradiente estocástica realizada localmente em cada cliente com a média dos modelos no servidor central. O autor identifica três vantagens no uso da técnica: possibilitar o treinamento sem ter acesso aos dados brutos, robustez em dados desbalanceados e efeitos positivos na regularização, contribuindo para a generalização do modelo.

Diversos estudos têm investigado o uso do aprendizado federado como alternativa para treinamento de modelos em que os dados estão protegidos por alguma razão específica. Em uma revisão (Li et al., 2020), os autores identificaram o aprendizado federado como solução para os problemas de silo e sensibilidade de dados.

As principais características e vantagens identificadas são:

- Preservação da privacidade: Permite que múltiplos clientes (dispositivos, instituições, etc.) treinem um modelo de aprendizado de máquina colaborativo sem compartilhar dados brutos, garantindo a privacidade dos dados;

- Adequado para cenários de dados distribuídos: Ideal para situações onde os dados estão dispersos em vários dispositivos ou instituições, permitindo a construção de modelos mais robustos e generalizáveis;

- Superação de silos de dados: Permite a colaboração entre entidades que, de outra forma, não poderiam compartilhar dados devido a restrições legais ou de privacidade;

- Diversidade de aplicações: Pode ser aplicado em diversas áreas, incluindo dispositivos móveis, engenharia industrial e saúde.

Apesar dessas oportunidades promissoras, o aprendizado federado também enfrenta vários desafios. Essas dificuldades podem ser categorizadas em desafios relacionados ao treinamento e de segurança e privacidade. Em seu trabalho, (Mammen, 2021), o autor expõe alguns obstáculos a serem considerados, tais como: sobrecarga de comunicação, heterogeneidade de sistemas e dados, ataques de inferência de associação, ataques de envenenamento de dados, ataques de envenenamento de modelo e ataques de backdoor.

1.2 Delimitação do Problema

A promessa de um Judiciário mais eficiente, célere e acessível, impulsionada pela IA, contrapõe-se, no entanto, a desafios complexos, em especial no que tange à questão dos altos custos operacionais devido à necessidade de infraestrutura robusta para processar e treinar as aplicações inteligentes. Além de um parque computacional moderno, no âmbito humano, são necessárias equipes especializadas em ciência de dados e segurança, cujo treinamento e retenção geram despesas significativas. (Conselho Nacional de Justiça (CNJ), 2023)

Outro desafio diz respeito ao viés de regionalização. Modelos de inteligência artificial treinados em unidades da federação diferentes podem apresentar desvios regionais devido à heterogeneidade dos dados disponíveis em cada jurisdição. Cada tribunal possui particularidades nos tipos de casos processados, na linguagem utilizada nos documentos judiciais e nas práticas locais de aplicação da lei.

Outro ponto crucial é a questão do sigilo e segredo de justiça. A distribuição de dados sigilosos, inerentes à atividade judicial, para o treinamento de modelos de IA, suscita inevitáveis preocupações sobre a proteção da privacidade e a confidencialidade das informações, sob a ótica da LGPD (da República, 2018). Garantir a segurança e a integridade dos dados, sem comprometer a efetividade das ferramentas de IA, configura-se como um desafio central para a implementação responsável dessa tecnologia no Judiciário.

Além disso, um dos desafios encontrados no desenvolvimento de IA no âmbito do Poder Judiciário envolve preocupações éticas e de transparência. Discriminação e viés nos resultados obtidos pelos modelos, falta de transparência e auditabilidade no processo de treinamento, estabelecimento de políticas claras, além da violação da privacidade das partes envolvidas são questões em debate atualmente, conforme o estudo publicado pelo CNJ. (Conselho Nacional de Justiça (CNJ), 2023)

1.3 Solução Proposta e objetivos

É nesse contexto que o sistema distribuído de aprendizado federado horizontal emerge como uma alternativa promissora para o desenvolvimento de modelos de IA no âmbito judicial. Essa técnica permite o treinamento de modelos de forma colaborativa entre os tribunais, preservando a confidencialidade e a segurança das informações, e possibilita o treinamento de modelos mais representativos.

Este artigo propõe, portanto, explorar o potencial do aprendizado federado como solução para o treinamento de modelos de IA no Poder Judiciário. Partindo da análise das oportunidades, dos benefícios e dos desafios da IA no contexto jurídico brasileiro, o artigo apresenta uma abordagem federada como uma alternativa viável para impulsionar a modernização do Judiciário.

Assim, o modelo federado proposto como alternativa ao paradigma atual apresenta-se como uma estratégia promissora ao abordar os seguintes aspectos:

- Precisão e acurácia dos modelos: O acesso colaborativo a dados distribuídos permite o treinamento de modelos com maior diversidade e abrangência, resultando em ganhos significativos no desempenho e na confiabilidade das previsões realizadas, eliminando o vies regionalizado entre os modelos individualizados.

- Economia de recursos: A colaboração entre instituições possibilita o redimensionamento das equipes envolvidas e promove uma economia computacional, ao permitir que recursos

sejam compartilhados de maneira eficiente e sinérgica.

- Proteção de dados: No aprendizado federado, apenas os parâmetros do modelo (pesos e gradientes) são transferidos entre as instituições, enquanto os dados de treinamento permanecem localmente armazenados. Essa abordagem reduz significativamente os riscos associados à proteção e segurança das informações, promovendo maior privacidade dos dados.

A seguir, apresentamos uma ilustração que detalha a proposta de modelo para o treinamento de IAs no âmbito do Poder Judiciário. Conforme mostra a figura abaixo, no modelo atual, os tribunais desenvolvem seus modelos de forma independente e individualizada, consumindo seus próprios dados e recursos para isso, ao passo que, no modelo federado e distribuído, uma entidade servidor desenvolve um modelo a partir do treinamento dos dados de seus clientes (tribunais) de forma colaborativa, dinâmica e sinérgica.

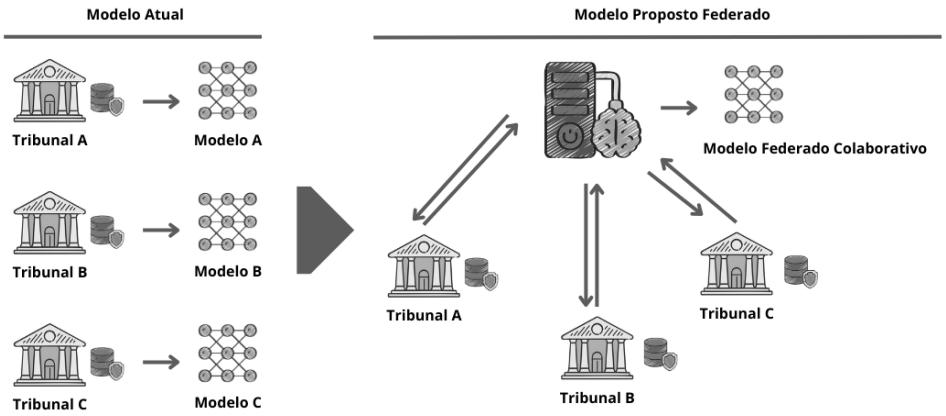

Figure 1: Proposta de Modelo Distribuído Federado

Sendo assim, o objetivo principal deste estudo é apresentar uma nova abordagem em relação ao treinamento de modelos de IA no Poder Judiciário brasileiro, mais especificamente, analisar um estudo de caso para corroborar esse entendimento.

2. Metodologia

A metodologia proposta visando a validação da hipótese suscitada é uma pesquisa experimental, buscando comparar os resultados do processo de avaliação em cada um dos métodos aplicados no treinamento dos modelos de IA: treinamento centralizado versus aprendizado federado.

O modelo utilizado para treinamento e teste da hipótese é um classificador de documentos judiciais. Uma aplicação comum de uso de IA no Judiciário é a classificação de classes e assuntos processuais a partir das petições iniciais nos processos judiciais.

A pesquisa é constituída em três etapas, conforme figura e detalhamento a seguir.

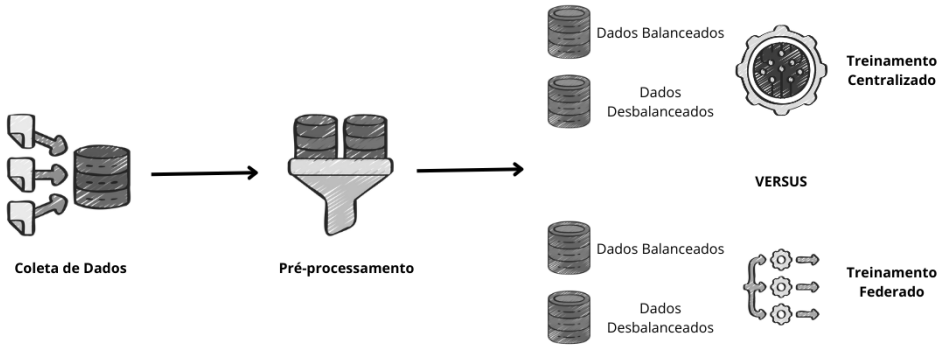

Figure 2: Experimento em 3 etapas

A primeira etapa consiste na coleta de dados. A extração se deu através de uma busca na base pública processual do Processo Judicial Eletrônico (PJe) (Eleitoral, 2025). A segunda etapa envolve o tratamento destes dados, com o objetivo de preparar a entrada de informações no ambiente de treinamento de inteligência artificial. E por fim, a última etapa se resume ao treinamento e avaliação da performance do classificador. O propósito principal deste estudo é avaliar a qualidade de um treinamento federado em comparação ao treinamento centralizado. Para isso, a proposta consiste em realizar dois treinamentos utilizando o mesmo conjunto de dados e parâmetros semelhantes, a fim de avaliar o desempenho de cada abordagem.

2.1 Coleta de Dados

Na etapa de coleta de dados, foram extraídos dois conjuntos de documentos processuais, especificamente do tipo ”Petição Inicial”, oriundos de processos judiciais selecionados de forma aleatória. A fonte dos dados consistiu no Processo Judicial Eletrônico (PJe), abrangendo o âmbito de primeiro grau da Justiça Eleitoral. (Eleitoral, 2025). O universo dos processos judiciais foi extraído da API pública do CNJ - Datajud. (Conselho Nacional de Justiça (Brasil), 2025)

O cálculo do tamanho amostral indica que a amostra analisada apresenta uma margem de erro de ±2,83% para um nível de confiança de 95%, considerando um universo aproximado de 5 milhões de processos da Justiça Eleitoral. (Cochran, 1977)

Para o primeiro experimento, adotou-se o método de **amostragem aleatória simples sem reposição**. Nesse procedimento, cada processo teve probabilidade uniforme de inclusão na amostra, assegurando a independência da seleção. Foram utilizados geradores pseudoaleatórios da biblioteca random do Python, com semente controlada (random.seed) para garantir a reprodutibilidade dos resultados. Esse processo resultou em 1200 processos judiciais, com distribuição natural das classes judiciais, caracterizando um cenário desbalanceado.

No segundo experimento, utilizou-se o critério de **amostragem estratificada sistemática**. Inicialmente, os processos foram agrupados por classe judicial e, em seguida, aplicou-se a seleção proporcional, de modo a assegurar a representatividade de cada estrato. A partir de cada classe, foram extraídos 485 processos, totalizando 4850 amostras, o que garantiu um conjunto balanceado entre as 10 principais classes em termos quantitativos. Esse critério foi definido para possibilitar a comparação entre os cenários de dados desbalanceados (primeiro experimento) e balanceados (segundo experimento).

Para fins de extração de dados, foi utilizada uma chamada ao banco de dados desenvolvida em Python, biblioteca *requests* (Reitz, 2020). E o armazenamento das informações se deu em

um banco de dados sqlite3. (Hipp, 2020)

2.2 Pré-processamento

A etapa de pré-processamento dos dados diz respeito ao tratamento dos textos com o objetivo de serem preparados para a etapa de aprendizado, uma vez que os algoritmos de treinamento requerem um formato adequado em sua entrada de informações. Esta etapa, por sua vez, está separada em 2 fases:

- Reconhecimento Ótico de caracteres (OCR): Alguns documentos extraídos possuíam imagens em sua composição, muitos deles resultado do processo de digitalização. A aplicação deste técnica permitiu a conversão das imagens em texto editável, viabilizando a extração precisa e eficiente dos dados. Para o reconhecimento foi utilizada a biblioteca *pytesseract* (Patil, 2020).

- Limpeza dos textos: Inicialmente, foram removidos caracteres não alfanuméricos indesejados, mantendo apenas pontuações básicas como vírgulas, pontos, interrogações e exclamações, o que contribuiu para a eliminação de ruídos no texto. Em seguida, espaços extras foram removidos e ajustados, incluindo a correção de espaços desnecessários antes da pontuação, além de outras técnicas posteriores.

2.3 Treinamento

O objetivo secundário deste experimento é comparar a performance de modelos de aprendizado centralizado e federado na tarefa de classificação de textos jurídicos, a fim de dar suporte ao modelo federado horizontal proposto.

Para isso, foi utilizado o modelo *Longformer* (Beltagy et al., 2020) para processamento de sequências longas. Este modelo foi escolhido por sua capacidade de processar sequências longas de até 4096 tokens utilizando o mecanismo de atenção esparsa. Esse recurso o torna particularmente adequado para textos jurídicos, que frequentemente ultrapassam os limites de modelos tradicionais como BERT (512 tokens). Além disso, o modelo conta com eficiência computacional maior frente a outras alternativas e possui disponibilidade no ecossistema Huggingface.

A metodologia de treinamento foi dividida em duas abordagens: centralizada e federada.

Aprendizado Centralizado No aprendizado centralizado, todo o conjunto de dados é reunido em um único ponto (um servidor central) e utilizado para treinar um modelo global. O processo é detalhado abaixo, e as etapas envolvem:

1. Carregamento e Processamento de Dados: Os dados utilizados para treinamento e validação foram extraídos e o texto de documentos foi emparelhado com suas respectivas classes. O processo de pré-processamento envolveu a codificação das classes (utilizando *LabelEncoder*) e a divisão dos dados em conjuntos de treinamento e validação, em uma proporção de 75% para treinamento e 25% para validação, utilizando a função *train test split* da biblioteca scikit-learn.

2. *Tokenização*: Foi utilizado o *tokenizer* específico da biblioteca *Hugging Face Transformers*, o qual converte os textos em uma sequência de *tokens* numérica compatível com o modelo. O *tokenizer* foi configurado para lidar com textos de até 4096 tokens, pois

o *Longformer* é um modelo especializado no processamento de sequências longas de texto.

3. Configuração do Modelo: O modelo utilizado foi o *LongformerForSequenceClassification* pré-treinado, carregado a partir do repositório *Hugging Face*. O modelo foi ajustado para realizar a tarefa de classificação de textos, considerando o número de classes presente no conjunto de dados. Após o carregamento do modelo, ele foi transferido para a GPU a fim de acelerar o processo de treinamento.

4. Parâmetros de treinamento:

Table 1: Parâmetros de Treinamento

Parâmetro	**Valor**
Número de épocas	3
Tamanho do batch	2 por dispositivo
Taxa de aprendizado	5e-5
Estratégia de agendamento	Agendador linear
Aquecimento	500 passos

5. Treinamento e Avaliação: O treinamento foi realizado utilizando a classe *Trainer* da Hugging Face, que facilita a execução do treinamento e da avaliação. Durante o treinamento, o modelo foi avaliado após cada época utilizando a métrica de *loss* (perda), e o modelo com melhor desempenho foi salvo ao final de cada época. Além disso, métricas como precisão, *recall*, e *f1-score* foram extraídas a partir da matriz de confusão gerada no final do treinamento, utilizando a biblioteca scikit-learn.

6. Resultados: Após o treinamento, o modelo foi testado utilizando o conjunto de validação, e as previsões foram comparadas com os rótulos reais através da matriz de confusão, relatório de classificação e cálculo da acurácia. O modelo treinado foi então salvo e compactado para análise posterior.

Aprendizado Federado O aprendizado federado, por sua vez, distribui o treinamento entre vários clientes (agentes), com cada um treinando o modelo em seus próprios dados locais e, em seguida, compartilhando os parâmetros do modelo (não os dados) com o servidor central para atualização do modelo global. A abordagem de aprendizado federado utilizou a biblioteca Flower (Team, 2021), com as seguintes etapas:

1. Distribuição de Dados entre Clientes: Os dados foram divididos entre dois clientes, com cada um recebendo um subconjunto dos dados para treinamento e validação. Com essa configuração, cada cliente treinou localmente em seu próprio conjunto de dados, sem compartilhar os dados com outros, garantindo a privacidade.

2. Treinamento Local: O modelo *Longformer* foi carregado, e os dados foram tokenizados e preparados de maneira similar ao treinamento centralizado. Cada cliente realizou o treinamento com um *batch size* de 4 e acumulou gradientes durante o treinamento para simular um tamanho de *batch* maior. O modelo foi treinado por 3 épocas utilizando o otimizador *AdamW* e o agendador de taxa de aprendizado linear.

3. Envio e Agregação dos Parâmetros: Após o treinamento local, os parâmetros do modelo (pesos) foram compartilhados com o servidor central utilizando a estratégia de agregação *FedAvg* (média ponderada dos parâmetros). O servidor central combinou os parâmetros de todos os clientes e enviou o modelo atualizado de volta para os clientes.

4. Avaliação: Após o treinamento em cada cliente, o modelo foi avaliado localmente no conjunto de validação, e métricas como perda, acurácia, matriz de confusão e relatório de classificação foram geradas. O servidor central então consolidou as métricas de todos os clientes para fornecer uma avaliação global.

5. Resultados: O modelo federado também foi testado e avaliado após as rodadas de treinamento. Similar ao treinamento centralizado, as métricas foram calculadas e salvas para análise.

A principal limitação metodológica deste estudo está relacionada à generalização dos resultados. Como foram utilizados exclusivamente dados oriundos da Justiça Eleitoral, ainda se fazem necessários estudos mais aprofundados para avaliar em que medida o aprendizado federado pode melhorar a capacidade de generalização dos modelos quando comparado a modelos específicos desenvolvidos por cada tribunal em diferentes ramos do Judiciário. Porém, o sucesso da abordagem no âmbito da Justiça Eleitoral é um ótimo indicativo de possibilidade amplificadora para todo o Poder Judiciário, uma vez que a abordagem soluciona problemas comuns entre cada jurisdição.

3. Resultados

Neste estudo, comparamos o desempenho de modelos de aprendizado de máquina treinados de forma centralizada e federada, com o objetivo de avaliar a viabilidade do treinamento federado no âmbito do Poder Judiciário, especificamente na classificação de classes judiciais a partir da petição inicial. Foram realizados experimentos com dois tipos de dados: balanceados e desbalanceados.

A análise focou na acurácia dos modelos, permitindo avaliar as diferenças de desempenho entre as abordagens de treinamento centralizado e federado, conforme tabela a seguir. A **acurácia** mede a proporção de previsões corretas em relação ao total de casos avaliados, oferecendo uma visão geral do desempenho do modelo. No entanto, para cenários com dados desbalanceados, essa métrica pode ser enganosa. Por isso, a **precisão** (proporção de verdadeiros positivos entre todas as previsões positivas) e o **recall** (proporção de verdadeiros positivos que foram corretamente identificados) são essenciais. O F1-score, que é a média harmônica da precisão e do recall, oferece uma avaliação mais equilibrada e robusta do desempenho do modelo, especialmente quando a distribuição das classes é desigual.

Inicialmente, é relevante destacar que a ausência de desempenho de classificação alinhado ao estado da arte nos modelos treinados, assim como a superioridade das avaliações dos modelos em cenários balanceados em relação aos desbalanceados, não constituem fatores centrais para o presente estudo. O objetivo principal da análise reside na comparação entre os desempenhos dos modelos treinados nos modos centralizado e federado. Dessa forma, o foco recai sobre a identificação de resultados comparáveis entre as duas abordagens de treinamento, independentemente das condições específicas de balanceamento dos dados.

Os resultados apresentados evidenciam que o aprendizado federado demonstrou um desempenho consistente e, em alguns casos, superior ao aprendizado centralizado,

Table 2: Desempenho dos Modelos de Classificação nos Diferentes Cenários de Treinamento

Cenário de Treinamento	Acurácia	Precisão	Recall	F1-Score
Centralizado Balanceado	0.79	0.79	0.79	0.78
Federado Balanceado	0.81	0.82	0.81	0.80
Centralizado Desbalanceado	0.46	0.44	0.46	0.39
Federado Desbalanceado	0.42* 0.58**	0.37* 0.47**	0.42* 0.58**	0.32* 0.51**

* Round 1, ** Round 2

especialmente em cenários com dados balanceados. Essa constatação reforça o potencial do aprendizado federado como uma alternativa viável e eficaz, mesmo em contextos mais desafiadores.

4. Conclusão

Este estudo propôs a utilização do aprendizado federado como uma solução inovadora para o desenvolvimento de modelos de IA no âmbito do Poder Judiciário brasileiro, considerando a problemática do sigilo e segredo de justiça. A pesquisa experimental comparou o desempenho de modelos de aprendizado de máquina treinados de forma centralizada e federada na tarefa de classificação de classes judiciais a partir da petição inicial, utilizando dados balanceados e desbalanceados.

Os resultados demonstraram que o aprendizado federado se apresenta como uma alternativa viável ao treinamento centralizado, especialmente em contextos onde a privacidade e a distribuição de dados são cruciais, tanto em cenários de dados balanceados, quanto em dados desbalanceados.

É importante destacar que este estudo representa um passo inicial na exploração do potencial do aprendizado federado no contexto judicial. Pesquisas futuras podem aprofundar a análise de desempenho em diferentes cenários e com conjuntos de dados mais abrangentes, além de explorar técnicas de otimização e segurança para o aprendizado federado em ambientes judiciais. Adicionalmente, a implementação do aprendizado federado no Poder Judiciário demandará a superação de desafios técnicos e de infraestrutura, além da construção de um arcabouço legal e ético sólido para garantir a segurança e a confiabilidade da aplicação da IA nesse contexto.

Os principais desafios práticos para a implementação do aprendizado federado no Poder Judiciário incluem a heterogeneidade de sistemas e dados entre os tribunais, a sobrecarga de comunicação e questões de segurança. A heterogeneidade se manifesta na variação do poder computacional, capacidade de armazenamento e qualidade dos dados entre os dispositivos participantes. Além disso, o processo de aprendizado federado envolve múltiplas rodadas de comunicação entre os dispositivos e o servidor central, o que pode gerar uma sobrecarga significativa, especialmente em redes com largura de banda limitada. Embora o método proteja a privacidade dos dados brutos, ainda existem riscos de segurança, como ataques de inferência de associação, envenenamento de dados e envenenamento de modelo, onde adversários podem manipular os modelos ou inferir informações a partir dos parâmetros atualizados.

Referências

Beltagy, I., Peters, M. E., and Cohan, A. (2020). Longformer: The long-document transformer. Accessed: 2025-01-02.
Cochran, W. G. (1977). *Sampling Techniques*. John Wiley & Sons, New York, 3rd edition.
Conselho Nacional de Justiça (Brasil) (2025). Api pública do datajud. `https://www.cnj.jus.br/sistemas/datajud/api-publica/`. Página oficial com documentação e acesso à API pública que permite consultar metadados de processos judiciais no Brasil. Acesso em [inserir data de acesso].
Conselho Nacional de Justiça (CNJ) (2023). Painel da pesquisa sobre ia em 2023. Acesso em: 2 jan. 2025.
da República, P. (2018). Lei geral de proteção de dados pessoais (lgpd). Lei nº 13.709, de 14 de agosto de 2018. Disponível em: `https://www.planalto.gov.br`. Acesso em: 2 jan. 2025.
Eleitoral, T. S. (2025). Consulta unificada pje - tribunal superior eleitoral. Acesso em: 3 jan. 2025.
Hipp, D. R. (2020). Sqlite: A c library that implements a small, fast, self-contained, high-reliability, full-featured, sql database engine. Accessed: 2025-01-02.
Li, L., Fan, Y., Tse, M., and Lin, K.-Y. (2020). A review of applications in federated learning. *Computers & Industrial Engineering*, 149:106854.
Mammen, P. M. (2021). Federated learning: Opportunities and challenges. *arXiv*.
McMahan, H. B., Moore, E., Ramage, D., Hampson, S., and Agüera y Arcas, B. (2023). Communication-efficient learning of deep networks from decentralized data. *arXiv*.
Patil, S. (2020). pytesseract: Python-tesseract, an ocr tool for python. `https://github.com/madmaze/pytesseract`. Accessed: 2025-01-02.
Reitz, K. (2020). Requests: Http for humans. `https://docs.python-requests.org/en/master/`. Accessed: 2025-01-02.
Team, F. (2021). Flower: A friendly federated learning framework. Accessed: 2025-01-02.

Apêndice A

Federated Learning in the Brazilian Judiciary System: An Interinstitutional Collaboration Approach

Abstract. *The use of artificial intelligence (AI) in the judicial system has led to significant advances. However, the development of these systems is largely carried out in isolation by different courts, resulting in high costs, interoperability limitations, and regionally biased models. Furthermore, the processing of sensitive data poses ethical and legal challenges related to privacy and confidentiality. Given this scenario, this paper proposes an alternative approach based on federated learning, aiming for a distributed AI training model. The presented methodology examines the technical feasibility of federated learning compared to centralized approaches. The results demonstrate that federated learning makes it possible to balance technological innovation and legal compliance, opening up prospects for collaborative and sustainable solutions within the judicial system.*

Keywords: *Federated learning, artificial inteligence, justice*